

PREPARAÇÃO PARA A PARTE II DO TESTE DE **ESTATÍSTICA APLICADA**

1. Numa escola básica e secundária encontram-se alunos com diferentes aptidões físicas, diferentes índices de massa corporal e diferentes hábitos alimentares. Foram obtidos dados pelos professores de Educação Física de duas escolas do Alentejo (0- Escola Básica Dr. Hernâni Cidade de Redondo, 1- Escola Básica Conde de Vilalva de Évora) e uma escola da região Norte (2- Escola Secundária de Castelo de Paiva). Estas variáveis fazem parte de uma base maior que possibilitou um caso de estudo na dissertação de Mestrado intitulada “Análise Estatística da Aptidão Física em Ambiente Escolar”, onde se procurou identificar factores que podem influenciar a aptidão física em ambiente escolar e o rendimento escolar dos alunos (“Mens sana in corpore san”). A variável ZonalMC\_cat categoriza a variável IMC em duas categorias (0 - não pertence à zona saudável; 1 - pertence à zona saudável) enquanto a variável ZonalMC categoriza a mesma variável em 3 categorias (0 - pertence à zona saudável; 1 - acima da zona saudável; 2 - abaixo da zona saudável). A variável idade está categorizada em duas categorias (0 - menos de 15 anos; 1 - 15 ou mais anos). Com base nos *outputs* seguintes:

- ✓ a) Avalie as associações entre o sexo e a ZonalMC e entre a idade e a variável ZN\_IMC\_cat.  
 ✓ b) Pode concluir que a associação entre a idade e o pertencer ou não à zona saudável é homogênea para todas as Escolas?

Pearson's Chi-squared test

data: tc  
 X-squared = 37.742, df = 2, p-value = 6.375e-09

Breslow-Day test on Homogeneity of Odds Ratios

data: tcc  
 X-squared = 11.943, df = 2, p-value = 0.002551

Fisher's Exact Test for Count Data

data: tc  
 p-value = 1.273e-11  
 alternative hypothesis: true odds ratio is not equal to 1  
 95 percent confidence interval:  
1.652493 2.572453  
 sample estimates:  
 odds ratio  
2.057481

> fisher.test(tc) #Escola Básica Conde de Vilalva (Évora)

Fisher's Exact Test for Count Data

data: tc  
 p-value = 1.42e-09  
 alternative hypothesis: true odds ratio is not equal to 1  
 95 percent confidence interval:  
1.874920 3.709396  
 sample estimates:  
 odds ratio  
2.620856

> fisher.test(tc) #Escola Básica Dr. Hernâni Cidade (Redondo)

Fisher's Exact Test for Count Data

data: tc  
 p-value = 0.1915  
 alternative hypothesis: true odds ratio is not equal to 1  
 95 percent confidence interval:  
 0.8663299 2.1823225  
 sample estimates:  
 odds ratio  
 1.367007

|           | Abaixo da zona saudável | Acima da zona saudável | Pertence à zona saudável |
|-----------|-------------------------|------------------------|--------------------------|
| Feminino  | <u>3.403542</u>         | -5.601853              | 1.012525                 |
| Masculino | -3.403542               | <u>5.601853</u>        | -1.012525                |

|           | Abaixo da zona saudável | Acima da zona saudável | Pertence à zona saudável |
|-----------|-------------------------|------------------------|--------------------------|
| Feminino  | 225                     | 80                     | 794                      |
| Masculino | 170                     | 167                    | 798                      |

Não pertence à zona saudável Pertence à zona saudável

|           | Não pertence à zona saudável | Pertence à zona saudável |
|-----------|------------------------------|--------------------------|
| <15 anos  | 506                          | 1025                     |
| >=15 anos | 136                          | 567                      |

Mantel-Haenszel chi-squared test without continuity correction

data: tcc  
 Mantel-Haenszel X-squared = 26.559, df = 1, p-value = 2.556e-07  
 alternative hypothesis: true common odds ratio is not equal to 1  
 95 percent confidence interval:  
 1.426363 2.218258  
 sample estimates:  
 common odds ratio  
 1.778775

> fisher.test(tc) #Escola Secundária de Castelo de Paiva

Fisher's Exact Test for Count Data

data: tc  
 p-value = 0.7429  
 alternative hypothesis: true odds ratio is not equal to 1  
 95 percent confidence interval:  
 0.6896048 1.7157983  
 sample estimates:  
 odds ratio  
 1.084303

|       | Nominal    | Ordinal      | De. origem contínua | De. origem contínua |
|-------|------------|--------------|---------------------|---------------------|
| 1. a) | Sexo - Fem | Zona IMC - 0 | Zona IMC - cat - 0  | Idade - 0           |
|       | Masc       | -1           | 1                   | 1                   |
|       |            | -2           |                     |                     |

• Sexo e Zona IMC (Tabela Contingência  $n \times k$  ( $3 \times 2$ ))

①  $\hookrightarrow$  Pearson  $\rightarrow$  Valor  $p = 6.375e^{-9} < \alpha$

Rejeita-se  $H_0$  logo admitimos que existe associação.  
 $\{ H_0: \text{Há associação entre Zona IMC e Sexo.} \}$   
 $\{ H_1: \dots \}$

③ Há mais 3.40 mulheres abaixo da zona saudável do que homens.

Há mais 5.60 homens acima da zona saudável do que mulheres.

• Idade e Zona IMC-cat (Tabela Contingência  $2 \times 2$ )

①  $\hookrightarrow$  Pearson ??  
 ...

③ Fisher  $\rightarrow$  Valor  $p = 1.275e^{-11} < \alpha$

Rejeita-se  $H_0$ , logo admitimos que existe associação.

Alunos com  $< 15$  anos têm 2.06 vezes mais chances de pertencer à zona saudável do que alunos com  $+ 15$  anos.

Com 95% de confiança, esse aumento estará entre (1.65; 2.57).

$\nearrow$   
 $I_{95\%}$

b) Escolas - 0

-1

-2

(Tabela Contingência  $n \times k$ )

$\{ H_0: \text{Idade (:) IMC | Escola} \}$   
 $\{ H_1: \text{Idade (x) IMC | Escola} \}$

⑤ Teste Mantel-Haenszel  $\rightarrow$  Valor  $p = 2.556e^{-7} < \alpha$

Rejeitamos  $H_0$ , logo idade e pertencer à zona saudável estão associados.

⑥ Assim, estão associados ao teste de Breslow-Day.

$\{ H_0: \text{Associação homogênea} \}$   
 $\{ H_1: \text{Associação depende da escola} \}$

Teste Breslow-Day  $\rightarrow$  Valor  $p = 0.002551 < \alpha$

Rejeitamos  $H_0$ , logo a associação depende da escola.

⑦ Avançamos então para os testes de Fisher

EBCV  $\rightarrow$  Valor  $p = 1.42e^{-9} < \alpha$  Rej.  $H_0$  OR = 2.62

ESCP  $\rightarrow$  Valor  $p = 0.7429 > \alpha$  Ñ Rej.  $H_0$

EBDHC  $\rightarrow$  Valor  $p = 0.1915 > \alpha$  Ñ Rej.  $H_0$



Apenas EBCV apresenta uma associação significativa, o que sugere que o efeito da idade na pertença à zona saudável varia entre escolas.

Assim, na EBCV, alunos com <15 anos têm cerca de 2.62 vezes mais chances de pertencer à zona saudável que alunos com mais de 15 anos.

Com 95% de confiança esse aumento estará entre (1.65, 2.57).

- ✓ c) Classifique, justificando, como verdadeiras ou falsas as seguintes proposições:
- ✓ i. Para avaliar a relação entre a idade (sem estar categorizada) e a o IMC (sem estar categorizado) poderia usar o coeficiente de correlação de Spearman. *Contínua* *Contínua* ✓
  - ✓ ii. Para avaliar a relação entre o IMC (sem estar categorizado) e o sexo deveria usar o coeficiente de correlação bisserial por pontos. *Contínua* *Nominal* ✓
  - ✓ iii. Para avaliar a relação entre o IMC categorizado em 3 categorias e a idade (sem estar categorizada) deveria usar o coeficiente de correlação bisserial. *Ordinal* *Contínua* F
  - ✓ iv. Para avaliar a relação entre o IMC categorizado em 2 categorias e a idade categorizada em duas categorias deveria usar o coeficiente de correlação tetracórico. *dic. origem cont.* *Spearman* ✓
  - ✓ v. Para avaliar a relação entre o IMC categorizado em 3 categorias e a idade categorizada pelos quartis deveria usar o coeficiente de correlação gama de Goodman-Kruskal. *Ordinal 3* *Ordinal 4* ✓

2. Quando um banco recebe um pedido de empréstimo, com base no perfil do requerente, o banco tem de decidir sobre se deve ou não avançar com a aprovação do empréstimo. Há dois tipos de riscos associados à decisão do banco: a) se o requerente apresentar um bom risco de crédito, ou seja, se for suscetível de reembolsar o empréstimo, a não aprovação do empréstimo resulta numa perda de negócio para o banco; 2) se o requerente apresentar um mau risco de crédito, ou seja, não for suscetível de reembolsar o empréstimo, a aprovação do empréstimo resulta numa perda financeira para o banco. Com base numa base de dados de crédito que contém dados sobre várias variáveis e sobre a classificação do risco de crédito de um candidato como bom ou mau para 1000 requerentes de empréstimo, um seu colega ajustou um modelo de regressão logística, tendo obtido, entre outros os *outputs* abaixo. Sabe-se, ainda, que as variáveis no modelo final foram: Account (ref: no account'), Savingnew2 (ref: <100 DM), Pcreditnew (ref: some problems), Lemploymentnew (ref: unemployed or <4 years), Massetnew (ref: none), Typeapartmentnew (ref: free), Purposenew (ref: car (new)), CA (ref: [250,1.370)).

- Gráficos abaixo
- ✓ a) Avalie a linearidade da variável contínua Duração do crédito ("DurationCredit") com o logit.
  - ✓ b) Avalie a bondade de ajustamento do modelo e a sua capacidade discriminativa.
  - ✓ c) Que pode comentar relativamente à possível existência de *outliers* e/ou de observações influentes?
  - ✓ d) Interprete o efeito das variáveis histórico em relação a outros créditos ("Pcreditnew"), objetivo do crédito ("Purposenew") e Duração do emprego atual ("Lemploymentnew"). Para o objetivo do crédito obtenha uma estimativa intervalar do efeito com 95% de confiança.
  - ✓ e) Observe o gráfico que descreve o efeito da duração do crédito solicitado para requerentes que não tiveram problemas com outros créditos. Interprete-o.
  - ✓ f) Estime a probabilidade do risco de crédito de um candidato ser bom (requerente credível) se este tiver solicitado um empréstimo a 36 meses para a compra de um carro novo, tendo este um emprego estável há mais de 7 anos e todas as restantes variáveis de perfil no nível de referência.
  - ✓ g) Aplicou-se este modelo a um conjunto de 300 candidatos, usou-se um ponto de corte de 0.65 e obteve-se a tabela de contingência que se apresenta de seguida. Calcule a sensibilidade, a percentagem de falsos positivos, a probabilidade um candidato que o modelo identifica como credível de facto ser credível (valor preditivo positivo), a percentagem e acertos do modelo e a prevalência estimada pelo modelo.

|            | Reference |       |
|------------|-----------|-------|
| Prediction | Credível  | Risco |
| Credível   | 161       | 25    |
| Risco      | 49        | 65    |



Método dos polinômios fracionários

2. a)  $I\left(\left(\frac{\text{DurationCredit}}{10}\right)^1\right)$

Como o expoente é 1, então é linear

b) Variáveis categóricas + Contínuas

Hosmer  $\rightarrow$  Valor  $p = 0.3309 > \alpha$   $\tilde{N}$  Rej.  $H_0$

Cespe  $\rightarrow$  Valor  $p = 0.19 > \alpha$   $\tilde{N}$  Rej.  $H_0$

$\begin{cases} H_0: \text{O modelo ajusta-se aos dados.} \\ H_1: \text{O modelo não se ajusta aos dados.} \end{cases}$

Assim, não rejeitamos ambos os testes, logo o modelo ajusta-se aos dados.

Através da curva ROC obtemos um  $AUC = 0.816$ , o modelo tem uma capacidade discriminativa muito boa. Com ponto corte de 0.664 obtemos também sensibilidade = 77.7% e especificidade = 73.7%

Também podemos observar pelo teste Delong que  $I_{c_{95\%}}(AUC) = (0.7878, 0.8452)$

c) Através do gráfico resíduos em função das probabilidades estimadas não observamos quaisquer outliers

No gráfico da distância de Cook podemos observar alguns pontos afastados do padrão geral, indicando que há pontos influentes

d) Predict new - No problems

- Some problems

- Previous credit good

Purpose new - car new

$I_{car}$

- car used

- HR Others

Length of new - unemployed or

< 9

- 9-9

- ≥ 9

Purpose New

$OR(\text{car used vs car new}) = \exp(1.625790) = 5.0825$

$I_{c_{95}}(OR) = (0.9, 2.3) \quad 5.0825 \pm 1.96 \times \text{str}$

$OR(\text{HR Other vs car new}) = \exp(0.539434) = 1.715$

$I_{c_{95}}(OR) = (0.16, 0.9)$

Um candidato com objetivo de crédito de "car used" tem 5 vezes mais chances de ser um cliente de risco do que candidato com objetivo de crédito de "car new".

$I_{c...}$

Um candidato com objetivo de crédito "HR Others" tem 1.7 vezes mais chances de ser um cliente de risco do que candidato com objetivo de crédito de "car new".



Leemploymentnew

$$OR(4-7 \text{ vs unemployed or } <4) = \exp(0.804096) = 2.25$$

$$OR(>7 \text{ vs unemployed or } <4) = \exp(0.241963) = 1.27$$

Um candidato com duração de emprego atual entre 4 a 7 anos tem 2.25x mais chances de ter aprovação do empréstimo do que um candidato que esteja desempregado ou que trabalhe à menos de 4 anos no emprego atual.

Um candidato com duração do emprego atual de mais de 7 anos tem 1.27x mais chances de ter aprovação do empréstimo do que um candidato que esteja desempregado ou que trabalhe à menos de 4 anos no emprego atual.

DurationCredit = a

$$\text{logit}(\text{no problem}, a) = \cancel{\beta_9 \times a} + \beta_7 \times 1 + \beta_{20} \times 1 \times a$$

$$\text{d.f.} = \beta_7 + \beta_{20} \cdot a$$

$$\text{logit}(\text{some problem}, a) = \cancel{\beta_9 \times a} + \cancel{\beta_7 \times 0} + \cancel{\beta_{20} \times 0 \times a}$$

$$OR(\text{No problem vs Some problem}) = \exp(1.9534 - 0.0471 \times a) = 0.42$$

a = 60 meses

$$1/OR = 2.4$$

Para um empréstimo de 60 meses aqueles que tiveram alguns problemas o risco de incumprir aumenta 2.4x do que aquele que não tiver.

$$\text{logit}(\text{credito anterior}, a) = \cancel{\beta_9 \times a} + \beta_8 \times 1 + \beta_{21} \times 1 \times a$$

$$\text{logit}(\text{some}, a) = \cancel{\beta_9 \times a} + \cancel{\beta_8 \times 0} + \cancel{\beta_{21} \times 0 \times a}$$

$$OR(\text{credito vs some}) = \exp(3.213 - 0.0751 \times a) =$$

a = 60

$$1/OR = 3.6$$

...

e) O efeito do histórico em relação a outros créditos é significativo entre valores da duração de crédito de 6 a 30, pois  $OR=1$  não se encontra com a banda de confiança nesses valores. Já para valores de 30 a 48 de duração de crédito o efeito do histórico em relação a outro crédito sem problemas não é significativo. Logo, à medida que a duração aumenta existe menos chances de ser aprovada.

f)  $\pi$  (DurationCredit = 36, Purpose = new car, Leemploymentnew = >7, account = noaccount, savingnew2 = < 100 DM, predictnew = some problems, assetnew = none, type of payment new = free, CA = [250, 1370])

$$\text{logit} = \overset{\beta_0}{-2.290745} + \overset{\beta_{10}}{0.241963} + \overset{\beta_1}{0.479636} + \overset{\beta_2}{0.001057} \times 36 = -1.531094$$

$$\pi = \frac{1}{1 + \exp(-(-1.531094))} = 0.1778 \quad \text{A probabilidade é de } 17.78\%$$



g)

|       |    |     |
|-------|----|-----|
| 161   | 25 | 186 |
| 49    | 65 | 114 |
| <hr/> |    |     |
| 210   | 90 | 300 |

$$\text{Sensibilidade} = \frac{65}{90}$$

$$\text{Especificidade} = \frac{161}{210}$$

$$\% \text{ Falsos positivos} = \frac{49}{210}$$

$$\% \text{ Falsos negativos} = \frac{25}{90}$$

$$\text{VDP} = \frac{65}{114}$$

$$\text{VPN} = \frac{161}{186}$$

$$\text{Prevalência} = \frac{90}{300}$$

$$\text{Detection Prevalence} = \frac{114}{300}$$



Coefficients:

|                                               | Estimate  | Std. Error | z value | Pr(> z )     |
|-----------------------------------------------|-----------|------------|---------|--------------|
| (Intercept)                                   | -2.290745 | 0.579427   | -3.953  | 7.70e-05 *** |
| AccountNone                                   | 0.479636  | 0.197018   | 2.434   | 0.014913 *   |
| Account0 - 200 DM                             | 1.124611  | 0.351662   | 3.198   | 0.001384 **  |
| Account>= 200 DM                              | 1.717412  | 0.220884   | 7.775   | 7.53e-15 *** |
| Savingnew2100 - 1000 DM                       | 0.664012  | 0.308942   | 2.149   | 0.031610 *   |
| Savingnew2>= 1000 DM                          | 0.871205  | 0.247075   | 3.526   | 0.000422 *** |
| PcreditnewNo Problems                         | 1.953405  | 0.545576   | 3.580   | 0.000343 *** |
| PcreditnewPrevious Credit Paid                | 3.213016  | 0.632389   | 5.081   | 3.76e-07 *** |
| DurationCredit                                | 0.001057  | 0.018199   | 0.058   | 0.953693     |
| Lemploymentnew4 - 7 years                     | 0.809096  | 0.241573   | 3.349   | 0.000810 *** |
| Lemploymentnew>= 7 years                      | 0.241963  | 0.205778   | 1.176   | 0.239657     |
| Massetnewcar or life insurance                | -0.438998 | 0.200680   | -2.188  | 0.028703 *   |
| Massetnewreal estate                          | -0.804686 | 0.279006   | -2.884  | 0.003925 **  |
| Typeapartmentnewrented or owned               | 0.605302  | 0.208562   | 2.902   | 0.003705 **  |
| Purposenewcar (used)                          | 1.625796  | 0.364610   | 4.459   | 8.23e-06 *** |
| PurposenewHR & Others                         | 0.539434  | 0.191551   | 2.816   | 0.004861 **  |
| CA[1.37e+03,2.32e+03]                         | 0.400779  | 0.238329   | 1.682   | 0.092642 .   |
| CA[2.32e+03,3.97e+03]                         | 0.948175  | 0.257128   | 3.688   | 0.000226 *** |
| CA[3.97e+03,1.84e+04]                         | 0.249811  | 0.291031   | 0.858   | 0.390690     |
| PcreditnewNo Problems:DurationCredit          | -0.047062 | 0.019347   | -2.433  | 0.014992 *   |
| PcreditnewPrevious Credit Paid:DurationCredit | -0.075130 | 0.023044   | -3.260  | 0.001113 **  |


Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Hosmer and Lemeshow goodness of fit (GOF) test

data: as.numeric(credit\$Resp) - 1, fitted(mod35)  
X-squared = 9.1367, df = 8, p-value = 0.3309




95% CI: 0.7878-0.8452 (DeLong)

*Índice de AUC*



| Sum of squared errors | Expected value H0 | SD        | Z          | P                |
|-----------------------|-------------------|-----------|------------|------------------|
| 150.9554706           | 152.2806791       | 1.0022589 | -1.3222218 | <u>0.1860943</u> |


*Cespe van Houdingen*



Coefficients:

|                          | Estimate |
|--------------------------|----------|
| (Intercept)              | -0.66887 |
| AccountNone              | 0.41253  |
| Account0 - 200 DM        | 1.05858  |
| Account>= 200 DM         | 1.61912  |
| I((DurationCredit/10)^1) | -0.40798 |

*a)*



- Uma empresa de vestuário realizou uma experiência para testar os efeitos de diferentes descontos nas vendas por catálogo. As ofertas promocionais foram feitas a clientes selecionados aleatoriamente, sendo registados os números de clientes que realizaram compras. Os *outputs* abaixo registam o ajustamento de três modelos (logit, probit e cloglog). Identifique, justificando, o modelo que melhor se ajusta a estes dados e com este estime a percentagem esperada de clientes que compram se lhes for oferecido um desconto de 60% e aconselhe o CEO da empresa sobre qual o desconto (com respetivo erro de estimativa para uma confiança a 95%) que deve ser oferecido a cada cliente que compre por catálogo para que pelo menos metade dos clientes a quem for oferecido esse desconto decida comprar.

3. AIC

logit 37.112

probit 34.601 ←

dloglog 37.466

Menor valor de AIC e segue bem os pontos observados no gráfico.

Desconto 60% → dloglog


↳ Cerca de 58<sup>??</sup>% dos clientes comprariam

Clientes 50% → Probit

↳ Desconto → 49.26%

$$I_{c95} = (49.25 \pm 1.96 \times 2.11) = (44.1, 53.6)$$





```
glm(formula = cbind(Clientes_que_compraram, Clientes_que_não_compraram) ~
  Desconto, family = binomial(link = logit), data = promo_loja)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -3.653087    0.415589  -8.790 < 2e-16 ***
Desconto     0.061597    0.007874   7.823 5.17e-15 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 88.5483  on 6  degrees of freedom
Residual deviance:  8.3507  on 5  degrees of freedom
AIC: 35.712
```

```
glm(formula = cbind(Clientes_que_compraram, Clientes_que_não_compraram) ~
  Desconto, family = binomial("probit"), data = promo_loja)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.174976    0.221024  -9.840 <2e-16 ***
Desconto     0.036819    0.004375   8.416 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 88.5483  on 6  degrees of freedom
Residual deviance:  7.2401  on 5  degrees of freedom
AIC: 34.601
```

```
glm(formula = cbind(Clientes_que_compraram, Clientes_que_não_compraram) ~
  Desconto, family = binomial("cloglog"), data = promo_loja)

Coefficients:
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -3.316860    0.353840  -9.374 < 2e-16 ***
Desconto     0.048115    0.005957   8.077 6.63e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 88.548  on 6  degrees of freedom
Residual deviance: 10.105  on 5  degrees of freedom
AIC: 37.466
```

```
> dose.p(modlogit,p=c(0.4, 0.5, 0.6))
      Dose      SE
p = 0.4: 43.75145 2.195004
p = 0.5: 49.25247 2.211228
p = 0.6: 54.75348 2.380848
```

```
> dose.p(modprobit,p=c(0.4, 0.5, 0.6))
      Dose      SE
p = 0.4: 43.47452 2.079815
p = 0.5: 49.25634 2.114710
p = 0.6: 55.03817 2.294636
```

```
> dose.p(modloglog,p=c(0.4, 0.5, 0.6))
      Dose      SE
p = 0.4: 46.68388 2.264219
p = 0.5: 52.62927 2.052392
p = 0.6: 58.06581 2.009658
```