



Amostras Independentes



Amostras Emparelhadas



Anova 1 Fator

Normalidade

Shapiro-Wilk

H_0 Admite normalidade
valor $p > 0.05$

H_1 Rejeita normalidade
valor $p \leq 0.05$

D'Agostino

Anscombe-Glynn

Ambos
valor $p > 0.05$

Pelo menos 1 falha
valor $p \leq 0.05$

Admite normalidade

Rejeita normalidade

Anscombe - Glynni

- H_0 : rs mesocêntrica
- H_1 : rs não mesocêntrica

Avaliação do qqplot:

Para admitir a normalidade os pontos devem estar aproximadamente alinhados com a diagonal, pequenos desvios nas extremidades podem ser aceitáveis, não podem existir outliers significativos.

Homocedasticidade

Levene

H_0 Admite homocedasticidade
valor $p > 0.05$

H_1 Rejeita homocedasticidade
valor $p \leq 0.05$

Avaliação gráfica dos resíduos:

Para admitir a homocedasticidade não deve existir afunilamento.

- Normalidade ✓ Homocedasticidade ✓
- Tukey, Dunnett, Scheffé ou LSD.
- Normalidade ✓ Homocedasticidade ✗
- Anova com conexão Welch.
- Tukey com estimativas robustas de variância.
- Normalidade ✗ Homocedasticidade ✓
- Kruskal - Wallis (valor $p < 0.05$) → ~~se~~ Dunn
- Normalidade ✗ Homocedasticidade ✗
- Transformar a variável resposta ($\ln y$, $\sqrt{y}$, $1/y$)
- Games-Howell

Anova 1 Fator em Blocos

- Normalidade Shapiro-Wilk e qqplot
- Homocedasticidade Levene e gráfico dos resíduos
- Aditividade Tukey para aditividade
 - valor $p > 0.05 \rightarrow$ Anova
 - valor $p \leq 0.05 \rightarrow$ Transformações
 $\rightarrow$ Modelo Misto

Pressupostos verificam: Tukey A. Paramétrica

Normalidade falha: - Friedman

- Nemeny: (Comparações múltiplas)
A. N. Paramétrica

Anova com Blocos como Efeito Aleatório (Modelo Misto)

- Verificar efeito dos blocos Anova
 - valor $p > 0.05 \rightarrow$ Considerar modelo sem blocos
 - valor $p \leq 0.05 \rightarrow$ Blocos apresentam variação significativa
- Normalidade dos efeitos dos blocos
- Homocedasticidade - Não aditividade (valor $p \leq 0.05$)
- Teste de razão de verossimilhança LRT

Quadrado Latino

- Normalidade
- Homocedasticidade
- Aditividade
 - Interação Região * Trimestre
 - Interação Trimestre * Estratégia
 - Interação Região * Estratégia

Pressupostos verificam $\rightarrow$ Tukey

Se falham $\rightarrow$ transformações

? [Normalidade $\times \rightarrow$ Friedman ou Kruskal-Wallis
Homocedasticidade $\times \rightarrow$ Welch

1 Anova 2 Fatores

- Normalidade
- Homocedasticidade

Normalidade ✓ Homocedasticidade ✓ → Tukey.
Normalidade ✓ Homocedasticidade ✗ → White / HC3
Normalidade ✗ Homocedasticidade ✓ → ART
Normalidade ✗ Homocedasticidade ✗ → Transformações

Anova Medidas Repetidas

- Outliers
 - Existem Transformações ou métodos robustos
 - Não existem Análise paramétrica
- Normalidade
- Homocedasticidade
- Esfericidade
 - ~~Mauchly~~
 - (valor $p > 0.05$) → Anova
 - (valor $p \leq 0.05$) → $\epsilon < 0.75$ → Corrige por Greenhouse-Geiser
 - $\epsilon \geq 0.75$ → Corrige por Huynh-Feldt
 - $\epsilon = 1$ → Existe esfericidade

? ~~Normalidade ✗ → D'Agostino~~
~~Simétricas → Wilcoxon~~
~~Assimétricas → Sign~~

Normalidade ✗ → Friedman (comparar os períodos)
→ Corover com correção Holm (comparações múltiplas)
Homocedasticidade ✗ → Modelo Misto
Ambos ✗ → Quade
→ ART (interações complexas)

2 Fator Within e 1 Fator Between

1) Correr a anova e comparações múltiplas (holm para within e tukey para between)

✓ Normalidade

✓ Homocedasticidade

✓ Esfericidade

2) Se falhar a esfericidade corrigir o valor p do fator within e da interação por GG ($E < 0.75$) ou HF ($E \geq 0.75$)

3) Se falhar a normalidade usar ART (não paramétrica)

4) Se falhar a homocedasticidade usar modelo linear misto com pesos para corrigir a heterocedasticidade.

5) Se falharem todos os pressupostos transformar a variável resposta.

Within $\rightarrow$ Onde ocorre as medidas repetidas

Between $\rightarrow$ Grupo (ocorre amostras independentes)

1 Fator Within

1) Correr a anova e comparações múltiplas (holm)

✓ Normalidade

✓ Homocedasticidade

✓ Esfericidade

2) Se falhar a esfericidade corrigir o valor p do fator within
GG ($E < 0.75$) ou HF ($E \geq 0.75$)

3) Se falhar a normalidade usar Friedman (não paramétrica) e comparações múltiplas de conover.

4) Se falhar a homocedasticidade aplicar modelo misto com pesos.

5) Se falharem ambos usar Quade e comparações múltiplas de conover. (Apenas se não conseguirmos uma transformação)

Ancova

- Normalidade
- Homocedasticidade
- Linearidade entre a covariável e a variável dependente
Testada com um gráfico de dispersão e uma linha de regressão?
- Homogeneidade de declives
Testada com um modelo que inclui a interação entre a covariável e o fator?
- Independência entre a covariável e o fator
Testada com uma Anova da covariável em função do fator.
(Apenas temos este pressuposto em conta se for medido após a experiência)

Tabelas de contingência 2x2

→ Relação entre duas ou + variáveis categóricas

X - nominal Y - nominal } Y - variável resposta - coluna
 X - ordinal Y - ordinal } X - variável explicativa - linha

① Teste Pearson's chi-squared { H_0 : Não há associação entre X e Y .
 valor p para Rejeita-se H_0 { H_1 : Existe uma associação entre X e Y .

② Ver se $e_{ij} \geq 1$ em todos j ; pelo menos 80% $e_{ij} \geq 5$ (apenas se lançar warning).

③ Caso falhe nos pressupostos → teste exato de Fisher (testa a mesma hipótese) e tirar OR e $I_{95\%}(OR)$. se não for significativo não fazer OR.
 $OR < 1 \rightarrow$ Inverter

... tem menos $(1 - OR)\%$ de chances de ... do que ... e essa redução com 95% de confiança estará entre ...

$OR > 1$

... tem cerca de OR vezes mais possibilidades ... do que ... e com 95% de confiança esse aumento ~~est~~ estará entre ...

Risco Relativo (caso corte)

Ex. Risk ratio with 90%

Exposição	estimative	lower	upper
Placebo	1	NA	NA
Aspirina	0.55	0.45	0.67

$RR = 0.55$ ($RR < 1$) $\leftarrow$ Inverter Probabilidade de ter um enfarte no miocárdio reduz $(1 - RR)$ 0.45.

$11 \leftarrow$ inversa

$RR = 1.82$ ($RR > 1$) Probabilidade de ter enfarte no miocárdio é 1.8 vezes superior para quem tomou placebo.

Tabelas de Contingência $n \times k$ (Ex: 5×2)

- ① Teste Pearson's chi-squared
- ② Fazer eij apenas se lançar warning
- ③ Fazer resíduos standardizados, ou seja, ver se a categoria é significativa, fora de $(-2, 2)$ $(-1.96, 1.96)$

Ex:	1x	2-4x	5 ou +	Nunca
Fem	1.2	1	2.67	-2.66
Masc	-1.2	-1	-2.67	2.66

∴ Há mais mulheres (2.67) a fazerem 5 ou + vezes uma dieta drástica do que os homens e há mais homens (2.66) que nunca fizeram uma dieta drástica do que mulheres.

- ④ Ver força da relação através de V. Cramer
...muito longe do 1, existe uma associação significativa, mas fraca (ex: 0.28). Quanto mais próximo do 1 mais forte é

- ⑤ Teste Mantel-Haenszel $\begin{cases} H_0: X(i) \perp Y \text{ condicional a } Z \\ \text{(associação condicional)} \\ H_1: X(i) \not\perp Y \text{ condicional a } Z \\ \text{(independência condicional)} \end{cases}$

- ⑥ Rejeita-se H_0 ^{Mantel-Haenszel}

Conclui que estão associadas a teste de Breslow-Day

$\begin{cases} H_0: \text{Associação } XY \text{ é homogênea} \\ H_1: \text{Associação depende das categorias de } Z \end{cases}$

Não se Rejeita H_0 ^{Mantel-Haenszel}

Ver OR e a sua significância

- ⑦ Rejeita-se H_0 ^{Breslow-Day}

Vários testes de Fisher

Não se Rejeita H_0 ^{Breslow-Day}

OR e Ic no teste Mantel-Haenszel, interação entre as 3 variáveis não é significativa. Tirar conclusões $OR < 1$ ou $OR > 1$.

Coeficientes de Correlação

• Pearson

- Contínua vs Contínua (ambas normais) Ex: Altura, peso, horas de sono, ...

• ρ de Spearman ou T. de Kendall ^{→ Ordinal vs Ordinal} Ex: Idade vs Grau Satisfação Idade vs Tempo Redes Sociais ↳ Para outliers e/ou amostras pequenas

- Contínua vs Contínua (pelo menos uma X normal)

- Contínua vs Ordinal (sem estar em categorias ou com muitas categorias)

- Ordinal vs Ordinal (sem categorias ou muitas categorias)

Ex: Nível de Escolaridade, Grau de Dor, Frequência

• Gamma de Goodman-Kruskal

- Ordinais vs Ordinais (ambos com poucas categorias)

Ex: Classe Etária (min, 22-26, max)

• Bisserial por Pontos

- Contínua vs Nominal Ex: Cor de olhos, ^{M/F} Sexo, Nacionalidade

• Bisserial

- Contínua vs Categoria dicotômica com origem numa contínua

• Tetracórica

- Dicotômica c/ origem numa contínua vs Dicotômica c/ origem numa contínua

Ex: 2 se Horas sono ≤ 9

0 se Horas sono > 9

$|r| \leq 0.3 \rightarrow$ Correlação fraca

$0.3 \leq |r| \leq 0.5 \rightarrow$ Mediamente fraca

$0.5 \leq |r| \leq 0.75 \rightarrow$ Mediamente forte

$|r| > 0.75 \rightarrow$ Forte

$$\begin{cases} H_0: r = 0 \\ H_1: r \neq 0 \end{cases}$$

• Medidas de Concordância

- 2 ordinais $\Rightarrow$ Coef. de concordância de Kendall

$w_t = 0.856$ $\begin{cases} H_0: w_t = 0 \rightarrow \text{Não há concordância} \\ H_1: w_t \neq 0 \rightarrow \text{Há concordância} \end{cases}$

$p = \dots$

- Nominal $\Rightarrow$ Coef. de concordância de Cohen

$K = 0.545$ $\begin{cases} H_0: K = 0 \\ H_1: K \neq 0 \end{cases}$

$p =$

Kappa de Cohen

$< 0.2 \rightarrow$ Pobre

$0.2 - 0.4 \rightarrow$ Razoável

$0.4 - 0.6 \rightarrow$ Moderado

$0.6 - 0.8 \rightarrow$ Bom

$> 0.8 \rightarrow$ Muito Bom

Vinho	Provedor
$\frac{1}{3}$ A	$\frac{1}{3}$:
$\frac{2}{3}$ B	$\frac{2}{3}$:
$\frac{3}{3}$ C	$\frac{3}{3}$:

	Médico1	Médico2
1	D ₁	D ₁
2	D ₂	D ₂
3	D ₃	D ₃

Modelos de Dose Resposta

Logit

$$\text{logit}(\pi) = \ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 x$$

Probit

$$\text{probit}(\pi) = \beta_0 + \beta_1 x$$

Cloglog

$$\text{cloglog}(\pi) = \beta_0 + \beta_1 x$$

Dose	Logit	Probit	Cloglog	Observado
1.86	0.95	0.959	0.98	0.98

Previsões para a dose de 1.86 entre os 3 modelos e comparadas com a proporção observada de mortos para esta dose $\hat{\pi}(\text{cloglog}) = 98\%$

	ld-logit	ld-probit	ld-cloglog
$p = 0.01$	1.6	1.6	1.58
$p = 0.25$	1.7	1.7	1.7
$p = 0.50$	1.77	1.77	1.77
$p = 0.75$	1.8	1.8	1.8
$p = 0.99$	1.9	1.89	1.86

=> Doses associadas a diferentes percentagens de mortalidade
Ex: Probit a 99% estima uma dose de 1.89

AIC e BIC

	df	AIC	ou BIC
mod-logit	2	43.8	
mod-probit	2	42.8	
mod-cloglog	2	35.8	

Para o R^2 o melhor é o maior.

o modelo com o menor AIC é o cloglog, sugerindo que, para os dados, ele é o + adequado entre os 3 modelos
Igual para BIC

Curvas de probabilidade com bandas de confiança a 95%

=> Avaliar o ajuste do modelo e a qualidade das previsões feitas pelos modelos

Regressão Logística

$$\text{logit} = \ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k$$

$$OR = \exp(\beta_i)$$

Pressuposto - Chave $\Rightarrow$ Variáveis contínuas têm que ser lineares com o logit.

Passo 1 ^(Anova) Ajustar modelos de regressão simples e comparar por teste de razão de verossimilhança com modelo nulo (Interpretar todas as sig.)

Passo 2 Ajustar o modelo com todas as variáveis sig. do Passo 1 (se houver poucas variáveis (até 20), $\alpha = 20\% = 0.2$, se houver 20+ usar $\alpha = 10\% = 0.10$).

Passo 3 Retirar por ordem decrescente dos valores p, as variáveis não sig. no Passo 2.

Passo 4 Incluir, por ordem crescente dos valores p, as variáveis que ficaram de fora no Passo 2.

Passo 5 Validar o pressuposto da linearidade das variáveis contínuas com o logit + tornar, se possível, o modelo mais parcimonioso.

Pelo gráfico com duas linhas (azul e rosa), é linear se a curva rosa seguir aproximadamente a curva azul

E (caso passe ou não na linearidade)

Método dos polinómios fracionários, que dá uma transformação

Passo 6 Procurar interações significativas $\rightarrow$ Incorporar no modelo todas as sig. e ir retirando uma a uma as que não forem, com o teste de verossimilhança

OBS: Se muitas sig. usar $\alpha = 1\%$

Passo 7 Avaliar a bondade do ajustamento

{ H_0 : O modelo ajusta-se aos dados

{ H_1 : O modelo não se ajusta aos dados

- Só variáveis categóricas $\rightarrow$ Teste de Hosmer

- Se variáveis contínuas $\rightarrow$ Juntamos teste de Cressie van Houwelingen

* Avaliar a capacidade discriminatória $\rightarrow$ Através da curva ROC

$0.5 \leq AUC < 0.6 \rightarrow$ Acaso (não presta)

$0.6 \leq AUC \leq 0.7 \rightarrow$ Pobre

$0.7 \leq AUC \leq 0.8 \rightarrow$ Boa

$0.8 \leq AUC \leq 0.9 \rightarrow$ Muito boa

$AUC \geq 0.9 \rightarrow$ Excelente

Ex: Para um $AUC = 0.868$, o modelo tem uma capacidade discriminatória muito boa. Para um ponto corte igual a 0.393 obtém-se uma sensibilidade de 74.5% e uma especificidade de 85.1%.

$P(\text{Não corre evento} | \text{Não evento})$

$P(\text{Prever Não} | \text{Não})$

$P(\text{corre evento} | \text{evento})$

$P(\text{Prever Sim} | \text{Sim})$

95% CI: 0.8292 - 0.9061 $\rightarrow$ Teste DeLong (intervalo de confiança para AUC)

$I_{95\%}(AUC) = (0.8292, 0.9061)$

Para aumentar especificidade $\rightarrow$ Aumentar ponto corte

Para aumentar sensibilidade $\rightarrow$ Diminuir ponto corte

Passo 8 Realizar uma análise de resíduos para identificar possíveis outliers e/ou observações influentes e avaliar o seu impacto no modelo.

(gráfico do raio)

$\hookrightarrow$ O maior raio é o mais influente

Nº de falsos positivos é sig. diferente do número de falsos negativos?

- Teste McNemar é sig. 0.0001 ✓

Prevalence → Percentagem de pessoas na amostra que pensa vir a ter filhos.

Média entre sensitivity e specificity é 78.6%

60.25% → $P(\text{Não} | \text{Previsto Não})$

90.14% → $P(\text{Sim} | \text{Previsto Sim})$

147	97	244
49	448	497
146	545	741

DR → 60.46% ($\frac{448}{741}$) → Proporção de sim previsto pelo modelo corretamente.

DP → 67.07% ($\frac{49+448}{741}$) → Proporção de sim que o modelo detetou

Falsos positivos → 49 → sim mas afinal foi não ($\frac{49}{146}$)% Falsos positivos

Falsos negativos → 97 → não mas afinal foi sim ($\frac{97}{545}$)% Falsos negativos

Valores baixos
Modelo bom

Para tornar o modelo + parcimonioso (Passo 5)

No summary do modelo

Ex: Nível escolaridade: 3 categorias

	estimate	stdError
Sec+	0.58	0.14
Sup	0.89	0.14

Diferença = 0.31 > 0.14

↓
maior desvio padrão
Logo, não se junta

Se diferença < maior desvio padrão, junta-se as categorias e é possível tornar o modelo + parcimonioso.

Para comparar 2 modelos:

AIC e BIC → o menor valor é o melhor


Multicolinearidade (vif):

> 10 → há problemas de multicolinearidade

> 5 → pode haver problemas

Interpretação dos coeficientes

→ Gráfico com bandas de confiança sombreadas



Quanto mais velha a mulher menor a chance de querer ter filhos.

Aos 40 anos cai mais de 90%

Banda muito pequena, confiança muito grande.

Curvas ROC dos modelos logísticos $\Rightarrow$ avaliar a capacidade discriminativa do modelo.

Ex: Se se observar apenas uma linha é indiferente qual modelo usar, pois todos têm a mesma capacidade discriminativa.

2º Posterior Predictive Check $\Rightarrow$ O modelo reproduz a distribuição da variável resposta se a linha verde estiver na mancha azul.

2º Binned Residuals $\Rightarrow$ Outliers a vermelho.

2º Influential Observations $\Rightarrow$ Pontos devem ficar dentro das linhas de contorno, intervalo aceitável. Se estiverem fora há observações influentes.

2º Uniformity of residuals $\Rightarrow$ Se os resíduos se distribuírem de forma uniforme e sem padrões, devem-se alinhar ao longo da linha reta. Se os pontos se desviarem, modelo não especificado, má especificação.

2º Distância de Cook por observação $\Rightarrow$ outliers, acima da linha vermelha.

1º Component + Residuals vs Dose $\Rightarrow$ Linearidade $\rightarrow$ Linhas próximas e sem curvaturas.
Sem padrões de não linearidade $\rightarrow$ Pontos distribuem-se de forma simétrica em torno da linha.

2º Comparação do Modelo $\Rightarrow$ Verificar se um ponto específico é influente.
do log com e sem Se a exclusão do ponto resultar em uma grande diferença então é ponto influente.
Ponto 8

Pressupostos:

1º $\Rightarrow$ Linearidade

2º $\Rightarrow$ Observação de pontos influentes (4 gráficos e gráfico com e sem um ponto).