

Aula 21/02

2.5.

y - vendas

x - preço

a) $\hat{y} = b_0 + b_1 x$

$$S_{xy} = \text{cov}(x, y) = \sum_{i=1}^n \underbrace{(x_i - \bar{x})(y_i - \bar{y})}_{n-1} = -17.816$$

$$S_x^2 = \text{var}(x) = \sum_{i=1}^n \underbrace{(x_i - \bar{x})^2}_{n-1} = 0.01129$$

$$b_1 = \frac{-17.816}{0.01129} \approx -1577.581$$

$$b_0 = \bar{y} - b_1 \bar{x} = 924.1667 - (-1577.581) \times 1.1975 \approx 2813.32$$

$$\text{vendas} = 2813.32 - 1577.581 \times \text{preço}$$

c) $e_i = y_i - \hat{y}_i$

d) Pressupostos:

1) Linearidade entre x e y

2) Resíduos têm que ser independentes

3) Resíduos com homogeneidade das variâncias

4) Resíduos com distribuição normal

5) Resíduos têm média nula

↳ Teste de Shapiro

$\left\{ \begin{array}{l} H_0 : \text{Resíduos} \sim \text{Normal} \end{array} \right.$

$\left\{ \begin{array}{l} H_1 : \text{Resíduos} \not\sim \text{Normal} \end{array} \right.$

$p\text{-value} = 0.538$ não rejeita H_0

$$f) \hat{\sigma}^2 = \frac{SQRE}{n-2} = \frac{QMRE}{12.2} = \frac{26437.23}{12.2} = 2643.723$$

h) IC para β_0

$$n=12$$

$$\hat{\beta}_0 = 2813.32$$

$$QMRE = 2643.723$$

$$\bar{x} \approx 1.1975$$

$$S_x^2 = 0.01129$$

$$\hat{\sigma}_{\beta_0} = \sqrt{2643.723 \left(\frac{1}{12} + \frac{1.1975^2}{12(12-1) \times 0.01129} \right)} = 175.3$$

$$\hat{\sigma}_{\beta_0} = \sqrt{\frac{QMRE}{(n-1)S_{xx}}} = \sqrt{\frac{2643.723}{(12-1) \times 0.001129}} = 145.9$$

$$\beta_0 \rightarrow]2813.32 \pm 3.169 \times 175.3[\\ =]2257.671; 3368.969[$$

$$\beta_1 \rightarrow \dots$$

$$j) H_0: \beta_0 = 0 \quad \text{vs} \quad \beta_0 \neq 0 \quad (\text{teste bilateral})$$

E.T.:

$$T = \frac{\hat{\beta}_0 - (\beta_0)_0}{\hat{\sigma}_{\hat{\beta}_0}} \sim t_{n-2}$$

$$t_{obs} = \frac{2813.3 - 0}{175.3} = 16.05$$


$$p\text{-value} = P(t_{obs} \in R.R.) = 2 \times P(T > |t_{obs}|) = \\ = 2 \times P(T > 16.05) \approx 0.0001$$

$$K) H_0: \beta_1 = 0 \quad \text{vs.} \quad H_1: \beta_1 \neq 0 \quad (\text{teste bilateral})$$

não influencia *influencia*

$$E.T.: T = \frac{\hat{\beta}_1 - (\beta_1)_{H_0}}{\hat{\sigma}_{\hat{\beta}_1}} \sim t_{(n-2)=10}$$

$$t_{obs} = \frac{-1577.6 - 0}{145.9} = -10.81$$



$$RC:]-\infty; -3.169[\cup]3.169; +\infty[$$

$$t_{obs} = -10.81 \in RC$$

$$\Rightarrow \text{Rej. } H_0, \alpha = 1\%$$

$\therefore$ influencia

$$l) R^2 = 0.9212$$

$$m) x = 1.23 \text{ €}$$

$$\hat{y} = 2813.3 - 1577.581 \times 1.23 = 872.895 \approx 872.9 \text{ unidades}$$

IC a 95% para $E(y)$

$$\text{predict}(\text{reta}, \text{new} = \text{data.frame}(x = 1.23), \text{int} = "conf", \text{level} = 0.95)$$

$$]838.177; 907.614[$$

n)] 753.186 ; 992.605 [

Regressão não linear

$$y = a_0 \cdot e^{a_1 x} \Leftrightarrow$$

$$\Leftrightarrow \ln y = \ln(a_0) + \ln(e^{a_1 x}) \Leftrightarrow$$

$$\Leftrightarrow \ln y = \ln(a_0) + a_1 \cdot x \cdot \ln(e) \xrightarrow{1}$$

$$\Leftrightarrow y^* = b_0 + b_1 \cdot x$$

2.7. $y = \text{brain}$

$x = \text{body}$

c) $g1 \leftarrow ggplot(...$

$g2 \leftarrow ...$

$g3 \leftarrow ...$

$$R_1 = 0.083$$

$$R_2 = 0.405$$

$$R_3 = 0.779$$

extra i)

$x = \text{body}$, em Kg

$$\log(y) \sim x$$

$y = \text{brain}$, em g

$$\rightarrow \log(\hat{y}) = 4.374 + 0.00001203 \cdot \text{body}$$

$$\hookrightarrow \ln(\log(\text{brain})) \sim \text{body}, \text{ data} = \text{dados}$$

ou
Animals

na escala não logarítmica:

$$\hat{y} = \exp(4.374) \times \exp(0.00001203) =$$

$$= 79.359 \times 1.000012$$

ou

$$y = \exp(4.374) \times e^{0.00001203 \times \text{body}}$$

extra ii)

$$y \sim \log(x)$$

$$\hat{\text{brain}} = 33.13 + \underbrace{143.55}_{\frac{143.55}{100} = 1.4355 \text{ gr}} \times \log(\text{body})$$

for 1% ↑
body

extra iii)

$$\log(y) \sim \log(x)$$

$$d) \log(y) = 2.555 + 0.496 \times \log(x)$$

↓

$$\hat{\text{brain}} = \exp(2.555) \times \text{body}^{0.496}$$

e) i) $R = 0.7794 \rightarrow \text{cor}(x, y)$

$R^2 = 0.6076 \rightarrow \text{summary}(rda)$

f) já foi feito conjuntamente à d)

Regressão linear múltipla

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \dots + \beta_p \cdot x_p + \varepsilon$$

forward

backward

step

$$x_1 = \text{sexo} \begin{cases} M \\ F \end{cases}$$

$$x_1 = \begin{cases} 1 & \text{se } M \\ 0 & \text{c.c.} \end{cases}$$

$$y = \beta_0 + \beta_1 \cdot x_1$$

$$x = \begin{cases} A \\ B \\ C \end{cases}$$

$$x_1 = \begin{cases} 1 & \text{se } A \\ 0 & \text{c.c.} \end{cases} \quad x_2 = \begin{cases} 1 & \text{se } B \\ 0 & \text{c.c.} \end{cases}$$

1º estudar correlação entre variáveis preditoras

2º estudar a relação entre y e as preditoras

3º Escolher método de seleção de variáveis x

4º Ajustar modelo com variáveis selecionadas

5º Avaliar possibilidade de transformação de variáveis

6º Avaliar possíveis interações entre x

7º Análise de resíduos, outliers e pontos influentes

$$y = \beta_0 + \beta_1 \cdot x_1 + \beta_2 \cdot x_2 + \beta_{12} \cdot x_1 \cdot x_2 + \varepsilon$$

Aula 06/03

3.

$$e) 1) H_0: \beta_1 = 0 \quad \text{vs} \quad H_1: \beta_1 \neq 0$$

$$\text{E.T.} \quad T = \frac{\hat{\beta}_1 - (\beta_1)_{H_0}}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_1)}} \sim t_{n-(p+1)}$$

$$2) H_0: \beta_2 = 0 \quad \text{vs} \quad H_1: \beta_2 \neq 0$$

$$\text{E.T.} \quad T = \frac{\hat{\beta}_2 - (\beta_2)_{H_0}}{\sqrt{\widehat{\text{Var}}(\hat{\beta}_2)}}$$

$$\text{extra:} \quad H_0: \beta_1 = 2 \quad \text{vs} \quad H_1: \beta_1 \neq 2$$

$$t_{\text{obs}} = \frac{1.4217 - 2}{0.142} = -4.073$$

$$p\text{-value} = 2 \times \underbrace{P(T < -4.073)}_{\substack{\uparrow \\ \text{pt}(-4.073, 22)}} < 0.001$$

$\uparrow$
 $n - (p+1)$
 "25" "=3"

$$\text{extra:} \quad \beta_2 > 3 \quad \text{vs} \quad \beta_2 < 3$$

$$t_{\text{obs}} = \frac{0.0197 - 3}{0.00262} = -1137.519$$

$$j) \text{ tempo} = 4.462 + 2.161 \text{ caixas}$$

$$\text{Tempo} = 8.735 + 0.038 \text{ distância}$$

Aula 07/03

3.2. a) $\hat{\text{sales}} = \hat{\beta}_0 = b_0 + \hat{\beta}_1 = b_1 \text{ youtube} + \hat{\beta}_2 = b_2 \text{ facebook} - \hat{\beta}_3 = b_3 \text{ newspaper}$
(todas em milhares de dólares)

b) $H_0: \beta_0 = \beta_1 = \beta_2 = \beta_3 = 0$ vs $H_1: \text{Há pelo menos um } \beta_j \neq 0, j=1,2,3$

Teste F

$t_{obs} = 570.3$

$p\text{-value} < 0.001 \Rightarrow \text{rejeito, } \alpha = 5\%$

c) $H_0: \beta_0 = 0$ vs $H_1: \beta_0 \neq 0$

Teste T: $t_{obs} = 9.422$

$p\text{-value} < 0.001 \Rightarrow \text{rej. } H_0$

$\Rightarrow$ manter intercepto no modelo

$H_0: \beta_1 = 0$ vs $H_1: \beta_1 \neq 0$

$t_{obs} = 32.809$

$p\text{-value} < 0.001 \Rightarrow \text{rej. } H_0$

$\Rightarrow$ manter preditor youtube no modelo

$H_0: \beta_2 = 0$ vs $H_1: \beta_2 \neq 0$

...

$H_0: \beta_3 = 0$ vs $H_1: \beta_3 \neq 0$

$t_{obs} = 0.177$

$p\text{-value} = 0.860 \Rightarrow \text{não rej. } H_0$

$\Rightarrow$ Remover newspaper do modelo

d) $\hat{\text{sales}} = 3.50532 + 0.04575 \text{ youtube} + 0.18799 \text{ facebook}$

e) método backward:

Iniciar c/ modelo completo

`drop1(modelo1, test="F")`

$\Rightarrow$ remover variável newspaper

Ajustar novo modelo $\rightarrow$ modelo1

`drop1(modelo1, test="F")`

Todas as variáveis significativas $\Rightarrow$ modelo

método forward:

`modelo0 <- lm(sales ~ 1, data = dados)`

?

iv) `lm(sales ~ facebook + youtube`

Aula 13/03

Pressupostos:

→ Linearidade

→ $\varepsilon_i \sim N(0, \sigma^2)$

→ ε_i independentes

4.1.		x	y	z
	A	7	6	3
	B	6	8	4
	C	3	2	4
	D	5	6	2
	E	4	1	2

a) D

	Inicial				
	A	B	C	D	E
A	0				
B	2.45	0			
C	5.74	6.71	0		
D	2.24	3.00	4.90	0	
E	5.92	7.55	2.45	5.10	0

$$d_{AB} = \sqrt{(7-6)^2 + (6-8)^2 + (3-4)^2} \approx 2.45$$

...

b)	i)	etapa	distância	grupos
		1	0	A , B, C, D, E
		2	2.24	(A, D), B, C, E
		3	2.45	(A, D,B) , C, E
		4	2.45	(A, D, B), (C,E)
		5	4.90	(A, D, B, C, E)

		2ª			
		(A,D)	B	C	E
(A,D)		0			
B		2.45	0		
C		4.90	6.71	0	
E		5.10	7.55		0
		3ª			
		(A,B,D)	C	E	
(A,B,D)		0			
C		4.90	0		
E		5.10	2.45	0	
		4ª			
		(A,B,D)	(C,E)		
(A,B,D)		0			
(C,E)		4.90	0		

ii)	etapa	distância	grupos
	1	0	A , B, C, D, E
	2	2.24	(A, D), B, C, E
	3	2.45	(A, D),B, (C, E)
	4	3.00	(A, D, B), (C,E)
	5	7.55	(A, D, B, C, E)

	2ª			
	(A,D)	B	C	E
(A,D)	0			
B	3	0		
C	5.74	6.71	0	
E	5.92	7.55	2.45	0
	3ª			
	(A,D)	B	(C,E)	
(A,D)	0			
B	3	0		
(C,E)	5.92	7.55	0	

	(A,D,B)	(C,E)
(A,D,B)	0	
(C,E)	7.55	0

Aula 10/04

lda - análise discriminante linear

- normalidade multivariada

- igualdade das matrizes de variâncias-covariâncias

- ausência de multicolinearidade

→ qda - análise discriminante quadrática

→ transformar as variáveis x

850 clientes - 700 não cumpridores / cumpridores
- 150 ?
75% cumpridores 25% não cumpridores

Regressão multinomial (e logística)
3a + cat 2 cat.

y - variável dependente ou resposta é uma variável categórica

$x_1, x_2, \dots, x_p$ - variáveis independentes ou preditoras

$$P(Y=y) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

A e B independentes $P(A \cap B) = P(A)P(B)$

6.1

H_0 : A gravidade não está relacionada (é independente) de local

H_1 : A gravidade está relacionada com o local

$$\text{E.T. } \chi^2 = \sum_{i=1}^L \sum_{j=1}^C \frac{(O_{ij} - E_{ij})^2}{E_{ij}} \sim \chi^2_{(L-1)(C-1)}$$

correção de continuidade

chisq.test (tabela)

em tabelas 2x2

$$\chi^2_{\text{obs}} = 88.612$$

fisher.test (tabela)

$$g1 = 1$$

p-value < 0.001 → rej. $H_0 \Rightarrow$ estão relacionadas

6.2

chances = # positivos / # negativos = odds

Dentro local.: chances de local. = $\frac{1046}{4229} \approx 0.247$
ter vítimas

Fora localidade: chances de ter = $\frac{599}{1381} \approx 0.434$
localidade c/ vítimas

$$\text{Razão de chances} = OR = \frac{\text{odds dentro}}{\text{odds fora}} = \frac{0.247}{0.434} \approx 0.569 < 1$$

$$\frac{1}{OR} = \frac{0.434^F}{0.247^D} = 1.757$$

$$S/\text{Vítimas} : \text{Odds}_{S/} = \frac{\# \text{ Dentro}}{\# \text{ Fora}} = \frac{4229}{1381} \approx 3.06$$

$$C/\text{Vítimas} : \text{Odds}_{C/} = \frac{\# \text{ Dentro}}{\# \text{ Fora}} = \frac{1046}{599} \approx 1.75$$

$$\text{OR} = \frac{3.06}{1.75} \approx 1.754$$

y = caminhada

x = $c(\underset{\substack{\uparrow \\ \text{quant.} \\ \text{cont.}}}{\text{idade}}, \underset{\substack{\uparrow \\ \text{cat.} \\ \text{nom.}}}{\text{sexo}}, \underset{\substack{\uparrow \\ \text{cat.} \\ \text{ord.}}}{\text{instrução}})$

$$\text{caminhada} = \beta_0 + \beta_1 \cdot \text{idade} + \beta_2 \text{ Masc.} + \beta_3 \text{ 2º cdo}$$

$$\text{logit}(P(\text{caminhada} = \text{Sim})) = \beta_0 + \beta_1 \cdot \text{idade} + \beta_2 \text{ Masculino} + \beta_3 \text{ 2º cdo} + \\ + \beta_4 \text{ 3º cdo} + \beta_5 \text{ Sec.} + \beta_6 \text{ Sup.}$$

$$\text{logit}(P(\text{caminhadas} = \text{Sim})) = -2.846 + 0.057 \cdot \text{idade} - 0.985 \text{ Masc.}$$

Exp. $\rightarrow$ interpretar como OR