

## 1ª Frequência (b) – 25 de Outubro 2023

### Questão 1: Definições

Faça corresponder os termos à sua definição:

- Termos: atributo, tipo do atributo, conj de treino, valor, conj de teste, modelo, regularização, problema de classificação, regressão, generalização.

| Termo | Definição (Correspondência)                                                                                     |
|-------|-----------------------------------------------------------------------------------------------------------------|
| ...   | Componente adicionada ao algoritmo de aprendizagem para reduzir o erro de generalização, mas não erro de treino |
| ...   | Output de um algoritmo de aprendizagem                                                                          |
| ...   | Problema de aprendizagem supervisionada onde o valor a prever é um valor numérico                               |
| ...   | Conjunto utilizado na construção do modelo                                                                      |
| ...   | Problema de aprendizagem supervisionada onde o valor a prever é uma etiqueta                                    |
| ...   | Valor de uma característica de uma instância específica                                                         |
| ...   | Domínio dos valores que um atributo pode ter                                                                    |
| ...   | Característica específica (descriptor) das instâncias                                                           |
| ...   | Capacidade do modelo prever corretamente valores para novos dados                                               |
| ...   | Conjunto utilizado para avaliar o desempenho do modelo                                                          |

### Questão 2: Algoritmos (Naïve Bayes e KNN)

Considere o seguinte conjunto de dados assumindo que estão presentes todos os valores possíveis de cada atributo.

| id | program     | enrol  | complete | grade | Classe |
|----|-------------|--------|----------|-------|--------|
| 1  | nursing     | high   | medium   | C     | ok     |
| 2  | nursing     | medium | medium   | B     | ok     |
| 3  | informatics | low    | low      | A     | fail   |
| 4  | nursing     | low    | low      | A     | ok     |
| 5  | nursing     | low    | low      | C     | fail   |
| 5* | nursing     | high   | high     | B     | ok     |
| 6  | Informatics | medium | low      | C     | fail   |
| 7  | informatics | high   | high     | A     | ok     |
| 8  | informatics | high   | medium   | B     | ok     |
| 10 | nursing     | medium | low      | C     | fail   |

- a) Se o conjunto for apresentado ao algoritmo Naïve Bayes com estimador de Laplace, a que classe pertence o exemplo (**nursing, high, low, B**)?

Justifique a resposta apresentando os cálculos. O estimador de Laplace é dado pela fórmula:

$$P(x) = \frac{n_x + 1}{total + n_{val}}$$

onde  $n_x$  é o número de exemplos com valor  $x$ ,  $n_{val}$  é o nº de valores que o atributo pode tomar, e  $total$  é o nº total de exemplos.

b) Se o conjunto for apresentado ao algoritmo k-vizinhos-mais-próximos (KNN) com distância de Manhattan, qual a classe do exemplo quando:

i)  $k = 1$


ii)  $k = 3$

Justifique a resposta. A distância de Manhattan é dada pela fórmula  $D(X, Y) = \sum |x_i - y_i|$ . Para atributos nominais a distância é 0 se os valores dos atributos forem iguais e 1 se forem diferentes. Caso aconteça os vizinhos  $k$  e  $k + 1$  terem a mesma distância e etiquetas diferentes, escolha aquele que aparece primeiro no conjunto de treino.

c) Enumere os testes a realizar para escolher o atributo para a raiz da árvore de decisão?

### Questão 3: SVM e Regularização


As figuras seguintes representam a fronteira de decisão de modelos SVM com núcleo RBF, cada uma com um valor diferente do parâmetro gamma, para um problema com 2 atributos.



- a) Considera que existe sub-ajustamento em algum modelo? Justifique.
- b) Qual o modelo mais complexo? Justifique.
- c) Sabendo que  $\gamma \in \{0.01, 1, 100\}$  e que valores maiores de gamma fazem diminuir a regularização, indique o valor de gamma de cada modelo (identifique-os usando esquerda, meio, direita). Justifique a resposta.

#### Questão 4: Regressão Ridge

Considere um problema de regressão para um conjunto com 100 atributos numéricos. O gráfico seguinte apresenta a magnitude dos diferentes coeficientes (modelo) calculada pelo algoritmo Ridge para diferentes valores do parâmetro alfa.



Sabendo que quanto maior o alfa, maior a regularização, faça corresponder a legenda (triângulos, quadrados, triângulos invertidos, círculos) aos valores de  $\alpha = (0.0001, 0.01, 1, 100)$ . Justifique a resposta.

#### Questão 5: Ajustamento do Modelo

Se constatar que um modelo gerado por um algoritmo sofre de sub-ajustamento, que procedimentos deve tomar para gerar um modelo mais adequado? Risque o que não interessa, justificando.

- a. aumentar/diminuir o  $n^\circ$  de exemplos do conj. de treino
- b. aumentar/diminuir o  $n^\circ$  de exemplos do conj de teste
- c. aumentar/diminuir a regularização

### Questão 6: Matriz de Confusão

Considere a seguinte matriz de confusão.

| real \ previsão | verde | vermelho | azul |
|-----------------|-------|----------|------|
| verde           | 10    | 0        | 5    |
| vermelho        | 2     | 15       | 7    |
| azul            | 1     | 0        | 10   |

- a) Quantos exemplos tem a classe verde?
- b) Quantos exemplos foram classificados na classe vermelho?
- c) Indique o número de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos para a classe azul. Justifique apresentando os cálculos realizados.
- d) Calcule a exatidão do modelo.

## 2ª Frequência (b) – 11 de Dezembro 2024


### Questão 1: Árvore de Decisão e Índice de Gini

Considere o conjunto de dados seguinte para a construção de uma árvore de atributos e o índice de Gini como função de impureza.

| id | elevacao | aspeto | inclinacao | incendio | floresta    |
|----|----------|--------|------------|----------|-------------|
| 1  | 24       | 72     | 7          | 56       | Pseudotsuga |
| 2  | 21       | 22     | 9          | 44       | Pseudotsuga |
| 3  | 24       | 54     | 8          | 56       | Pseudotsuga |
| 4  | 22       | 71     | 10         | 51       | Pseudotsuga |
| 5  | 23       | 23     | 5          | 46       | Pseudotsuga |
| 6  | 25       | 105    | 7          | 55       | Pseudotsuga |
| 7  | 28       | 130    | 1          | 58       | Pinus       |
| 8  | 30       | 148    | 16         | 34       | Pinus       |
| 9  | 26       | 117    | 24         | 60       | Pseudotsuga |
| 10 | 26       | 120    | 30         | 61       | Pseudotsuga |

- Calcule a impureza da raiz da árvore.
- Considere que escolhe o atributo aspeto como raiz.
  - Qual deve ser o teste feito sobre o atributo? Justifique a resposta.
  - Calcule a impureza da partição.
- Considere que escolhe o atributo inclinação como raiz. Que pontos de corte devem ser testados na construção de uma árvore de decisão? Justifique a resposta.

- d. Dada a árvore de atributos seguinte, como seria classificado o exemplo (29, 100, 35, 50)? Justifique a resposta.



### Questões: Validação

1. Em que situações deve utilizar uma divisão treino-validação durante o processo de construção de um modelo. Justifique a resposta.
2. Em que situações deve utilizar uma validação cruzada durante o processo de construção de um modelo. Justifique a resposta.

### Questão 2: Métricas de Avaliação

Considere um conjunto de dados com 10000 exemplos e 2 classes (positiva e negativa).

- a. Se tivermos um classificador com uma exatidão de 99.9%, é seguro afirmar que o classificador tem um bom desempenho? Justifique a resposta.
- b. O que significa o classificador apresentar uma precisão igual a 100% para a classe positiva?

### Questão 3: Matriz de Confusão e Cobertura

Considere que um modelo dá origem à seguinte matriz de confusão sobre um conjunto de teste.


- Calcule a cobertura (recall) de cada uma das classes.
- Calcule a micro-cobertura e macro-cobertura ponderada do modelo.

| real \ previsão | Laranja | Maçã | Marmelo |
|-----------------|---------|------|---------|
| Laranja         | 10      | 0    | 3       |
| Maçã            | 2       | 15   | 5       |
| Marmelo         | 0       | 0    | 10      |


### Redes Neurais e Ensembles

- Considere um perceptron com pesos ( $w_1 = 1, w_2 = 1, w_3 = 0, w_4 = 2, b = -0.2$ ) e um exemplo descrito pelos atributos ( $x_1 = 0.6, x_2 = 0.2, x_3 = 0.2, x_4 = -0.4$ ) pertencente à classe +1. Utilizando a regra do perceptron com um ritmo de aprendizagem de 0.1, qual o novo valor dos pesos após a apresentação do exemplo? Considere que o bias está associado a um atributo  $x_0$  com valor 1.
- Considere uma rede neuronal multi-camada. Se durante o processo de construção do modelo encontrar indícios de sobre-ajustamento, que alterações poderá fazer à rede? Justifique a resposta.

6. A figura seguinte representa uma estratégia para criação de comités de classificadores. Identifique-a, justificando a resposta.



7. A figura seguinte representa uma estratégia para criação de comités de classificadores. Identifique-a, justificando a resposta.



8. O que distingue o algoritmo Random Forest do algoritmo Extremely Randomized Trees?

**Formulário de Apoio (Anexo nos Documentos)**

- Índice de Gini:  $gini(D) = 1 - \sum_{c=1}^n p_c^2$
- Modelo linear:  $y = w_1x_1 + \dots + w_nx_n + b$
- Regra perceptrão:  $w_i = w_i + \eta(t - o)x_i$

# 1 Exame – 6 de Janeiro 2025


## Questão 1: Definições

Faça corresponder os termos seguintes à sua definição: atributo, cobertura, conj treino, conj teste, conj validação, exatidão, instância, modelo, precisão, tipo do atributo, valor.

| Termo | Definição                                                                                    |
|-------|----------------------------------------------------------------------------------------------|
| ...   | Unidade de entrada de um sistema de aprendizagem automática                                  |
| ...   | Característica específica (descriptor) das instâncias                                        |
| ...   | Valor de uma característica de uma instância específica                                      |
| ...   | Output de um algoritmo de aprendizagem, dado um conjunto de dados                            |
| ...   | Domínio dos valores que um atributo pode ter                                                 |
| ...   | Conjunto para construir o modelo                                                             |
| ...   | Conjunto para avaliar o desempenho do modelo                                                 |
| ...   | Conjunto para escolher os melhores parâmetros de um algoritmo para um problema em particular |
| ...   | Proporção de instâncias corretamente classificadas                                           |
| ...   | Proporção de verdadeiros positivos entre os classificados como positivos                     |
| ...   | Proporção de instâncias positivas classificadas corretamente                                 |

## Questão 2: SVM RBF

A figura seguinte representa a fronteira de decisão de um modelo SVM com núcleo RBF ( $\gamma = 5, C = 1000$ ). Se considerarmos que existe sobre-ajustamento ao conjunto de treino, que alteração deverá ser feita a  $C$  na pesquisa de um melhor modelo? Justifique a resposta.




### Questão 3: Dataset Florestal

Considere o seguinte conjunto de dados.

| id | elevacao | aspeto | inclinacao | incendio | floresta    |
|----|----------|--------|------------|----------|-------------|
| 1  | 24       | 72     | 7          | 56       | Pseudotsuga |
| 2  | 21       | 22     | 9          | 44       | Pseudotsuga |
| 3  | 24       | 54     | 8          | 56       | Pseudotsuga |
| 4  | 22       | 71     | 10         | 51       | Pseudotsuga |
| 5  | 23       | 23     | 5          | 46       | Pseudotsuga |
| 6  | 25       | 105    | 7          | 55       | Pseudotsuga |
| 7  | 28       | 130    | 1          | 58       | Pinus       |
| 8  | 30       | 148    | 16         | 34       | Pinus       |
| 9  | 26       | 117    | 24         | 60       | Pseudotsuga |
| 10 | 26       | 120    | 30         | 61       | Pseudotsuga |

- a. Se o conjunto for apresentado ao algoritmo k-vizinhos-mais-próximos, como seria classificado o exemplo  $(29, 100, 35, 50)$  quando  $k = 1$ ? Como função de distância, utilize a distância de Manhattan. Justifique a resposta apresentando os cálculos.
- b. Dada a árvore de atributos seguinte, como seria classificado o exemplo  $(29, 100, 35, 50)$ ? Justifique a resposta.



- c. Se quisermos construir uma árvore de decisão, qual a impureza da raiz usando o índice de Gini como função de impureza. Justifique a resposta apresentando os cálculos.
- d. Que pontos de corte devem ser testados na construção de uma árvore de decisão ao considerar o atributo incendio como raiz? Justifique a resposta.

#### Questão 4: Análise de Previsões

Considere que o conjunto de teste apresenta as seguintes etiquetas e previsões. Indique o número de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos para a classe A.

| ID   | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 | 13 | 14 | 15 | 16 | 17 | 18 | 19 | 20 |
|------|---|---|---|---|---|---|---|---|---|----|----|----|----|----|----|----|----|----|----|----|
| Real | A | A | B | B | B | B | A | A | A | A  | A  | A  | B  | A  | A  | A  | A  | A  | A  | B  |
| Prev | A | B | A | B | B | B | A | A | B | B  | A  | A  | A  | B  | A  | A  | A  | A  | A  | B  |

#### Questão 5: Matriz de Confusão e Métricas

Considere que um modelo dá origem à seguinte matriz de confusão. Justifique as respostas.

| real \ previsão | Laranja | Maçã | Marmelo |
|-----------------|---------|------|---------|
| Laranja         | 10      | 0    | 3       |
| Maçã            | 2       | 15   | 5       |
| Marmelo         | 0       | 0    | 10      |

- Quantos exemplos tem a classe Laranja?
- Quantos exemplos foram classificados na classe Maçã?
- Qual o erro do modelo?
- Calcule a precisão de cada uma das classes.

### Questão 6: Perceptrão

Considere um perceptrão com pesos ( $w_1 = -1, w_2 = 1, w_3 = 2, w_4 = 0, b = 0.1$ ) e um exemplo descrito pelos atributos ( $x_1 = 0.6, x_2 = 0.2, x_3 = 0.4, x_4 = -0.1$ ) pertencente à classe -1. Considere que o bias está associado a um atributo  $x_0$  com valor 1. Utilizando a regra do perceptrão com um ritmo de aprendizagem de 0.1, qual o novo valor dos pesos após a apresentação do exemplo?

### Questão 7: Sobre-ajustamento

Se constatar que um modelo gerado por um algoritmo sofre de sobre-ajustamento, que procedimentos deve tomar para gerar um modelo mais adequado. Para cada alínea escolha, justificando, entre: "aumentar", "diminuir", "nenhum", "ambos".

|                    | Procedimento | Justificação |
|--------------------|--------------|--------------|
| Nº exs. cj. treino |              |              |
| Nº exs. cj. teste  |              |              |
| Regularização      |              |              |

### Questão 8: K-Means

Explique como funciona o algoritmo de agrupamento k-means?

### Questão 9: Lasso Regression

Considere um problema de regressão para um conjunto com 100 atributos numéricos. O gráfico seguinte apresenta a magnitude dos coeficientes de um modelo Lasso para diferentes valores do parâmetro  $\alpha$ . Faça corresponder a legenda (triângulos, quadrados, triângulos invertidos, círculos) aos valores de  $\alpha$  (0.0001, 0.01, 1, 100). Justifique a resposta.

