

Aprendizagem Automática


Questões (parte 1)

K-vizinhos mais próximos

1. Considere o seguinte conjunto de dados, onde cada exemplo é caracterizado por 4 atributos e pertence a uma de 3 classes. Se o conjunto for fornecido ao algoritmo dos K-vizinhos-mais-próximos, com $K=3$ e a distância euclidiana como métrica de distância, a que classe pertence o exemplo $\{5.9, 3.0, 5.1, 1.3\}$? Justifique a resposta apresentando os cálculos realizados.

ID	Atr1	Atr2	Atr3	Atr4	Classe
1	4.6✓	3.2✓	1.4✓	0.2✓	Iris-setosa
2	5.3✓	3.7✓	1.5✓	0.2✓	Iris-setosa
3	5.0✓	3.3✓	1.4✓	0.2✓	Iris-setosa
4	6.2✓	2.9✓	4.3✓	1.3✓	Iris-versicolor
5	5.1✓	2.5✓	3.0✓	1.1✓	Iris-versicolor
6	5.7✓	2.8✓	4.1✓	1.3✓	Iris-versicolor
7	6.3✓	2.5✓	5.0✓	1.9✓	Iris-virginica
8	6.5✓	3.0✓	5.2✓	2.0✓	Iris-virginica
9	6.2✓	3.4✓	5.4✓	2.3✓	Iris-virginica

2. Numa função de regressão, testou-se o algoritmo KNN com 3 valores diferentes de número de vizinhos, $N=\{1, 3, 9\}$ com os valores de desempenho sobre o conjunto de treino e teste indicados na figura.



Indique em qual das situações considera que existe sobre-ajustamento, e justifique.

Distância Euclidiana

Distância de Manhattan → sem $\sqrt{\dots^2}$
sem $\dots^2$

1. ID1 → $\sqrt{(5.9-4.6)^2 + (3.0-3.2)^2 + (5.1-1.4)^2 + (1.3-0.2)^2} \approx 4.078$

ID2 → ... ≈ 3.876

ID3 → ... ≈ 3.975

ID4 → ... $\approx \underline{0.860}$ Iris-versicolor

ID5 → ... ≈ 2.311

ID6 → ... ≈ 1.039

ID7 → ... $\approx \underline{0.883}$

ID8 → ... $\approx \underline{0.927}$

ID9 → ... ≈ 1.158

K=3
↓

Iris-virginica

Iris-virginica

Ficando 2 contra 1, concluímos que o exemplo pertence à Iris-virginica.

2. Considero que existe sobre-ajustamento em $K=1$ pois as predições do modelo ajustam-se na perfeição aos dados de treino, resultando em má performance quando avança para a fase de testes, sendo isto corroborado pelos valores apresentados, enquanto a pontuação de treino foi 1.0, a pontuação de testes foi 0.35, sinal claro de sobre-ajustamento, dada a fraca generalização do modelo.

Generalização e Complexidade de modelos


1. Considere que os seguintes valores de exatidão foram obtidos utilizando o algoritmo de **Regressão Logística** com norma L1 e diferentes valores para o parâmetro C (parâmetro de regularização).

	0.1 C1	1 C2	100 C3
treino	0.84	0.93	1
teste	0.85	0.96	0.9

1. Faça corresponder {C1, C2, C3} aos elementos do conjunto {0.1, 1, 100}. Justifique a resposta.
2. Existem indícios de sobre-ajustamento em alguma configuração? Qual? Justifique a resposta.

2. Considere um conjunto de dados com duas classes {vermelho, azul}. A imagem seguinte apresenta a fronteira de decisão dos modelos gerados por um algoritmo de aprendizagem sobre um conjunto de dados e apresenta o erro associado aos conjuntos de treino e teste.

1. Que modelo poderá estar em situação de sobre-ajustamento? ³
2. Que modelo poderá estar em situação de sub-ajustamento? ¹
3. Que modelo escolheria para o classificador? ²



3. Se constatar que um modelo gerado por um algoritmo sofre de sobre-ajustamento, que procedimentos deve tomar para gerar um modelo mais adequado? Risque o que não interessa, justificando.

- 1.1. $C1 \rightarrow 0.1$ dada a fraca influência sobre a decisão com menor treino/teste, existe maior regularização, logo $C1 = 0.1$.
- $C2 \rightarrow 1$ dada a influência na decisão que levou a uma melhoria significativa e tendo este treino/teste intermediário, então $C2 = 1$.
- $C3 \rightarrow 100$ dada a forte influência sobre a decisão com treino=1 e teste=0.9, com declínio/influência elevada na decisão, então $C3 = 100$.

1.2. Sim, em $C3$ ($C=100$), pois obtem exatidão perfeita no treino mas pontuação inferior no teste, tendo sido esta pontuação inferior à pontuação de teste em $C2$, em que o modelo generalizou melhor do que em $C3$.

- 2.1. Modelo 3, possuindo exatidão perfeita no treino mas valor inferior no teste.
- 2.2. Modelo 1, possuindo erro alto tanto no treino como no teste.
- 2.3. Modelo 2, possuindo valores bons e equilibrados entre treino/teste.

- 3.1. Deve aumentar o número de exemplos do conjunto de treino pois mais dados ajudam a reduzir a variância.
- 3.2. Deve manter o número de exemplos do conjunto de teste, sendo que estes não são relevantes para a melhoria do modelo.
- 3.3. Deve aumentar a regularização pois ajuda a penalizar a complexidade do modelo.

1. aumentar/~~diminuir~~ o nº de exemplos do conj. de treino
2. aumentar/~~diminuir~~ o nº de exemplos do conj. de teste
3. aumentar/~~diminuir~~ a regularização

Construção e avaliação de modelos

1. Considere os seguintes comandos:

```

5 a: print(" A exactidão é ", svc.score(x_train,y_train))
2 b: x_train, x_test, y_train, y_test = train_test_split(x_data, y_data)
3 c: svc = SVC()
6 d: print(" A exactidão é ", svc.score(x_test,y_test))
e: svc.fit(x_test,y_test)
1 f: x_data, y_data = load_data_XYZ()
4 g: svc.fit(x_train,y_train)

```

Selecione e ordene as instruções de modo apresentar o desempenho do modelo construído com o algoritmo de máquina de vetores de suporte para classificação aplicado ao conjunto de dados "XYZ".

2. Considere a seguinte matriz de confusão, e a classe "maligno" como classe positiva.

real/classificador	Pos	↓
	maligno	benigno
Pos	43	10
benigno	0	90

1. Qual o nº total de exemplos positivos? 53
 2. Qual o número de Falsos Negativos? 10
 3. Indique o valor da exatidão. 93%
3. Seja VP e FP o nº de verdadeiros positivos e falsos positivos, respectivamente. Sabendo que a precisão é calculada pela fórmula $VP/(VP+FP)$, qual das seguintes definições corresponde à precisão?
 - a. Proporção de verdadeiros positivos entre os classificados como positivos.
 - b. Proporção de instâncias positivas classificadas corretamente.
 - c. Proporção de instâncias negativas classificadas corretamente
 - d. Proporção de instâncias corretamente classificadas
 4. Considere um problema de classificação com 2 classes. Uma com 100 instância e outra com 9900 instâncias. Obteve um classificador com 99% de exatidão. Indique se cada uma das afirmações é Verdadeira ou Falsa. Justifique.
 - a. O desempenho do sistema é claramente muito bom.

1. f → Corregge os dados
2. b → Divide os dados
3. c → Inicia o classificador
4. g → Treina o modelo com o conj. de treino
5. a → Exatidão do treino
6. d → Exatidão do teste

2.1. 53 Positivos

2.2. 10 Falsos Negativos

2.3. Exatidão = 0.93 → 93%

3. a) Correta → Precisão = $\frac{VP}{VP+FP}$

3. b) Errada → Sensibilidade = $\frac{VP}{VP+FN}$

3. c) Errada → Especificidade = $\frac{VN}{VN+FP}$

3. d) Errada → Exatidão = $\frac{VP+VN}{\text{Total}}$

4. a) Falso, pois sendo que as classes estão desequilibradas, então a exatidão não garante um bom desempenho na classe rara.

4. b) Verdadeiro, pois seriam necessárias mais medidas para avaliar o classificador.

4. c)

4. d) Falso, pois escolher sempre a classe majoritária leva a uma exatidão igual à proporção da classe majoritária.

- b. Não tenho informação para saber se o desempenho é bom.
- c. Se usasse um classificador aleatório o desempenho seria muito inferior.
- d. Se optasse por escolher a classe majoritária esperaria uma exatidão de 50%.

Vários

1. Classifique como Verdadeiro ou Falso. Justifique a resposta.
 - a. Os dados de treino influenciam o modelo do classificador
 - b. Os dados de teste não influenciam o desempenho do classificador
 - c. Um modelo de classificação em funcionamento gera um conjunto de atributos
 - d. O algoritmo de aprendizagem gera um conjunto de resultados
 - e. O classificador é um modelo para previsão de números reais e depende dos dados de teste
 - f. Um classificador Naive Bayes exige que os atributos sejam correlacionados entre si
 - g. Uma tarefa de classificação é uma tarefa de aprendizagem não supervisionada

- 1.a) Verdadero, pois o modelo é ajustado consoante os dados de treino.
- 1.b) Verdadero, pois os dados de teste apenas servem como métrica para avaliar o modelo, não o influenciando diretamente.
- 1.c) Falso, gera uma previsão com base nos atributos de entrada.
- 1.d) Verdadero, o algoritmo de aprendizagem produz um modelo e previsões/resultados.
- 1.e) Falso, o classificador prevê classes, não necessariamente números reais.
- 1.f) Falso, Naive Bayes assume o oposto, a independência condicional entre atributos, ou seja, que não sejam correlacionados entre si.
- 1.g) Falso, uma tarefa de classificação é uma tarefa de aprendizagem supervisionada, por conta dos rótulos.