


Aprendizagem Automática

Questões

Árvores de atributos

1. Considere os seguintes conjunto de dados e a árvore de atributos construída com o mesmo:

ID	Atr1	Atr2	Atr3	Atr4	Classe
1	4.6	3.2	1.4	0.2	<u>Iris-setosa</u>
2	5.3	3.7	1.5	0.2	<u>Iris-setosa</u>
3	5.0	3.3	1.4	0.2	<u>Iris-setosa</u>
4	6.2	2.9	4.3	1.3	<u>Iris-versicolor</u>
5	5.1	2.5	3.0	1.1	<u>Iris-versicolor</u>
6	5.7	2.8	4.1	1.3	<u>Iris-versicolor</u>
7	6.3	2.5	5.0	1.9	<u>Iris-virginica</u>
8	6.5	3.0	5.2	2.0	<u>Iris-virginica</u>
9	6.2	3.4	5.4	2.3	<u>Iris-virginica</u>



- Indique o grau de pureza na Folha 4 considerando a entropia como função de impureza.
 - Indique a distribuição das classes das instâncias classificadas na Folha 4.
 - Indique qual deverá ser o resultado da árvore de decisão na Folha 4.
2. Considere o conjunto de dados seguinte e responda às perguntas:
- Se quisermos construir uma árvore de atributos com o conjunto de dados, qual a profundidade máxima possível da árvore? Justifique a resposta.
 - Dada a árvore de atributos seguinte, qual a impureza da folha f2? Utilize o índice de Gini como função de impureza. Para um conjunto D, o índice de Gini é calculado pela fórmula

Árvores de Atributos

- 1.1.
- Exclui os IDs 4, 7, 8 e 9 no primeiro ramo.
 - Não exclui nenhum ID no segundo ramo.
 - Portanto, chegam à Folha 4 os IDs 1, 2, 3, 5 e 6.
 - Assim:

$$P(\text{sétosa}) = \frac{3}{5}$$

$$P(\text{versicolor}) = \frac{2}{5}$$

$$\text{Entropia}(D) = -\sum p_c \times \log_2(p_c) =$$

$$= -\left(\frac{3}{5} \times \log_2\left(\frac{3}{5}\right) + \frac{2}{5} \times \log_2\left(\frac{2}{5}\right) \right) \approx 0.971$$

2. Iris-sétosa = 3

Iris-versicolor = 2

3. Classe Maioritária $\rightarrow$ Iris-sétosa

2.a) Uma árvore para atributos nominais apenas realiza um teste por atributo, logo a profundidade máxima será igual ao número de atributos, ou seja, 4.

b) **Árvore de atributos seguinte??**

Resolução com base no exercício 1:

- Exclui os IDs 1, 2, 3, 5 e 6 no primeiro ramo.
- Exclui os IDs 8 e 9 no segundo ramo.
- Portanto, chegam à Folha 2 os IDs 4 e 7.
- Assim:

$$P(\text{versicolor}) = \frac{1}{2}$$

$$P(\text{virginica}) = \frac{1}{2}$$

$$\text{Gini}(D) = 1 - \sum p_c^2$$

$$= 1 - (0.5^2 + 0.5^2) = 0.5$$

A impureza da folha 2 é $\frac{1}{2}$.

c) **Falta a árvore de atributos**

A maioria dos vizinhos mais próximos tem classe 'no', logo o exemplo deve ser classificado como 'no'.

seguinte onde n é o número de classes e p_c a probabilidade da classe c . Justifique apresentando os cálculos.

$$gini(D) = 1 - \sum_{c=1}^n p_c^2$$

- c. Como seria classificado o exemplo {young, hypermetrope, yes, reduced}? Justifique a resposta.

age	prescrip	astigm	tears	Classe
young	myope	yes	normal	yes
young	myope	yes	reduced	no
young	hypermetrope	yes	normal	no
young	myope	no	normal	yes
pre-presbyopic	hypermetrope	yes	reduced	no
pre-presbyopic	hypermetrope	yes	reduced	no
presbyopic	myope	no	reduced	no
presbyopic	myope	no	normal	no

Naïve de Bayes

1. Considere o seguinte conjunto de dados, onde cada exemplo é caracterizado por 3 atributos, tendo associada uma classe. Se o conjunto for fornecido ao algoritmo Naive Bayes com estimador suavizado de Laplace qual a classificação para o exemplo {low, T, teen}? Justifique a resposta, apresentando os cálculos realizados

ID	income	student	age	buy-phone
1	low	T	teen	no
2	low	T	teen	yes
3	low	T	child	no
4	high	F	teen	yes
5	low	F	adult	no
6	low	F	teen	no
7	high	F	child	yes
8	high	F	adult	no
9	high	T	adult	yes

Construção e avaliação de modelos

1. Considere que um modelo dá origem à seguinte matriz de confusão sobre o conjunto de teste.
- a. Alguma classe tem precisão igual a 1? Justifique a resposta.

Naïve Bayes

1. Estimador de Laplace: $P(x) = \frac{n_x + \alpha}{\text{total} + \alpha \times \text{nvals}}$; $\alpha = 1$

$\{low, T, teen\}$

$$P(yes) = \frac{4 + 1}{9 + 1 \times 2} = \frac{5}{11}$$

$$P(no) = \frac{5 + 1}{9 + 1 \times 2} = \frac{6}{11}$$

$$P(low | yes) = \frac{1 + 1}{4 + 1 \times 2} = \frac{2}{6} = \frac{1}{3}$$

$$P(low | no) = \frac{4 + 1}{5 + 1 \times 2} = \frac{5}{7}$$

$$P(T | yes) = \frac{2 + 1}{4 + 1 \times 2} = \frac{3}{6} = \frac{1}{2}$$

$$P(T | no) = \frac{2 + 1}{5 + 1 \times 2} = \frac{3}{7}$$

$$P(teen | yes) = \frac{2 + 1}{4 + 1 \times 3} = \frac{3}{7}$$

$$P(teen | no) = \frac{2 + 1}{5 + 1 \times 3} = \frac{3}{8}$$

$$P(yes) = \frac{5}{11} \times \frac{1}{3} \times \frac{1}{2} \times \frac{3}{7} = \frac{5}{154} = 0.0325$$

$$P(no) = \frac{6}{11} \times \frac{5}{7} \times \frac{3}{2} \times \frac{3}{8} = \frac{135}{2156} = 0.0626$$

$0.0626 > 0.0325$, logo a classe escolhida é 'no'.

- b. Alguma classe tem cobertura igual a 1? Justifique a resposta.
c. Calcule a macro-cobertura (simples) do modelo.

real\previsão	A	B	C	D
A	10	0	3	5
B	2	15	5	10
C	0	0	10	0
D	4	0	2	10

2. Considere os seguintes casos, e responda às questões para cada um deles.
- 2 algoritmos treinados num conjunto de treino, foram testados com conjunto de validação; uma vez escolhido o melhor, criaram-se 2 novos modelos com o conjunto de treino+teste e 2 parâmetros diferentes, tendo sido testados com o conjunto de teste. Escolheu-se o modelo com melhor desempenho apresentando-o como desempenho final.
O procedimento é correto? Será que existe drenagem de informação do conjunto de teste? O resultado poderá ser enviesado (biased)?
 - 1 algoritmo foi testado com validação cruzada (10 folds) sobre um conjunto de dados, repetindo-se o procedimento com 4 valores diferentes do parâmetro X de regularização; selecionou-se o modelo com melhor desempenho, apresentando esse valor como desempenho.
O procedimento é correto? Será que existe drenagem de informação? O resultado poderá ser enviesado (biased)?
 - 4 algoritmos foram treinados e testados com validação cruzada (10 folds) num conjunto de dados; selecionou-se o melhor modelo, apresentando o desempenho calculado como estimativa do desempenho futuro.
O procedimento é correto? Será que existe drenagem de informação? O resultado poderá ser enviesado (biased)?

3. Indique qual das definições corresponde à macro média de F1 para avaliação de desempenho multiclasse:

→ média não pesada de F1 de cada classe

- média de F1 ~~pesada~~ pelo nº de exemplos de cada classe (real)
- média de F1 ~~pesada~~ pelo nº de exemplos de cada classe (no resultado do classificador)
- cálculo de F1 depois de somar o nº total de verdadeiros positivos; e para falsos positivos, e falsos negativos somar o nº total de casos mal classificados, de todas as classes.
- média não ponderada entre F0 e F2 ? ✗

4. Calcule a macro-média ponderada de F1, para a seguinte matriz de confusão

		True/Actual		
		Cat (🐱)	Fish (🐟)	Hen (🐔)
Predicted	Cat (🐱)	4	6	3
	Fish (🐟)	1	2	0
	Hen (🐔)	1	2	6

Construção e Avaliação de Modelos

1.a) $\text{Precisão} = \frac{VP}{VP+FP}$

Classe B tem precisão = 1 pois $FP = 0$.

b) $\text{Cobertura} = \frac{VP}{VP+FN}$

Classe C tem cobertura = 1 pois $FN = 0$.

c) $\text{Cobertura Macro} = \frac{Cob_A + Cob_B + Cob_C + Cob_D}{4} =$
$$= \frac{\frac{10}{18} + \frac{15}{32} + 1 + \frac{10}{16}}{4} \approx 0.662$$

- 2.a) • O procedimento não é correto pois o conjunto de teste deve ser usado apenas na avaliação final, mas foi usado duas vezes, na construção e na seleção.
- Existe drenagem de informação porque o desempenho do conjunto teste foi utilizado para selecionar o modelo final, ao invés de servir apenas como avaliação final.
- O resultado pode ser enviesado porque a drenagem de informação leva a uma estimativa otimista do desempenho.
- b) • O procedimento não é correto pois o desempenho deverá ser avaliado com um conjunto de teste, não com o próprio conjunto de dados.
- Existe drenagem de informação pois a seleção foi feita com base no desempenho do próprio conj. de dados, devia ser com conj. teste.
- O resultado pode ser enviesado porque a drenagem de informação leva a uma estimativa otimista do desempenho.
- c) • O procedimento não é correto pois o desempenho deverá ser avaliado com um conjunto de teste, não com o próprio conjunto de dados.
- Existe drenagem de informação pois a seleção foi feita com base no desempenho do próprio conj. de dados, devia ser com conj. teste.
- O resultado pode ser enviesado porque a drenagem de informação leva a uma estimativa otimista do desempenho.

3. Média não pesada de F1 de cada classe.

4. Macro-Média Ponderada de $F_1 = F_{1A} \times W_A + F_{1B} \times W_B + \dots$

$$F_0 = (1 + \beta^2) \times \frac{\text{Prec} \times \text{Cob}}{(\beta^2 \times \text{Prec}) + \text{Cob}}$$

$$F_1 = 2 \times \frac{\text{Prec} \times \text{Cob}}{\text{Prec} + \text{Cob}}$$

$$\text{Prec} = \frac{VP}{VP + FP}$$

$$\text{Cob} = \frac{VP}{VP + FN}$$

$$\text{Prec}_{\text{cat}} = \frac{4}{13}$$

$$\text{Cob}_{\text{cat}} = \frac{4}{6} = \frac{2}{3}$$

$$W_{\text{cat}} = \frac{6}{25} = 0.24$$

$$\text{Prec}_{\text{fish}} = \frac{2}{3}$$

$$\text{Cob}_{\text{fish}} = \frac{2}{10} = \frac{1}{5}$$

$$W_{\text{fish}} = \frac{10}{25} = \frac{2}{5} = 0.40$$

$$\text{Prec}_{\text{hen}} = \frac{6}{9} = \frac{2}{3}$$

$$\text{Cob}_{\text{hen}} = \frac{6}{9} = \frac{2}{3}$$

$$W_{\text{hen}} = \frac{9}{25} = 0.36$$

$$F_{1\text{ cat}} = 2 \times \frac{\frac{4}{13} \times \frac{2}{3}}{\frac{4}{13} + \frac{2}{3}} = \frac{8}{19} = 0.421$$

$$F_{1\text{ fish}} = 2 \times \frac{\frac{2}{3} \times \frac{1}{5}}{\frac{2}{3} + \frac{1}{5}} = \frac{4}{13} = 0.308$$

$$F_{1\text{ hen}} = 2 \times \frac{\frac{2}{3} \times \frac{2}{3}}{\frac{2}{3} + \frac{2}{3}} = \frac{2}{3} = 0.667$$

$$F_1 \text{ Ponderada} = 0.421 \times 0.24 + 0.308 \times 0.40 + 0.667 \times 0.36 = 0.464$$