

Resumos Detalhados de Aprendizagem Automática (Por Slide)

1 Introdução e Conceitos Básicos

O que é Aprendizagem Automática (AA)?

Estudo sistemático de algoritmos e sistemas que melhoram o seu desempenho com a experiência.

Terminologia AA (Q. Vários 1)

- **Instâncias (Objetos):** Unidades de entrada de um sistema AA.
- **Atributos (Características):** Descritores dos objetos. Os atributos certos são determinantes para o sucesso de uma aplicação.
- **Modelo:** Resultado da aplicação do algoritmo a um conjunto de instâncias (dados de treino).
- **Saída:** Grupo, classe ou valor real associado ao objeto de entrada.

Tarefas de AA (Q. Vários 1)

- **Classificação:** Prevê um conjunto de classes discretas. (*Aprendizagem Supervisionada*)
- **Regressão:** Prevê um número real. (*Aprendizagem Supervisionada*)
- **Agrupamento (Clustering):** Agrupa dados sem informação a priori. (*Aprendizagem Não Supervisionada*)

Aprendizagem Profunda (Deep Learning)

Baseia-se em Redes Neurais Artificiais (RNA) com várias camadas escondidas, usadas quando há grande volume de dados e alto custo computacional.

2 Aprendizagem Supervisionada e Avaliação

Conceito

Constrói-se um modelo a partir de pares entrada/resultado (dados de treino) para prever novos objetos.

Tipos de Problemas de Classificação

- **Binário:** Duas classes (positiva/negativa).
- **Multi-classe:** K classes exclusivas.
- **Multi-etiqueta:** K classes não exclusivas.

Construção e Avaliação (Q. Construção 1)

1. Carregar os dados.
2. Dividir em treino (75%) e teste (25%).
3. Instanciar o classificador.
4. Treinar o modelo no treino.
5. Avaliar o desempenho no treino e no teste.

Matriz de Confusão e Métricas

- Verdadeiros Positivos (VP), Verdadeiros Negativos (VN), Falsos Positivos (FP), Falsos Negativos (FN).
- Positivos Reais: $\text{Positivos} = \text{VP} + \text{FN}$
- Exatidão: $\text{Acc} = \frac{\text{VP} + \text{VN}}{\text{Total}}$
- Precisão: $\text{Prec} = \frac{\text{VP}}{\text{VP} + \text{FP}}$

Classes Desequilibradas: A exatidão pode ser enganadora — o modelo pode apenas prever a classe majoritária.

3 K-Vizinhos Mais Próximos

Conceito

Algoritmo *lazy learning*: guarda os dados de treino e usa-os na previsão.

Influência do Número de Vizinhos (K)

- $K = 1$: Modelo muito complexo (sobre-ajustamento).
- K alto: Fronteira mais suave (sub-ajustamento se demasiado grande).
- Existe um K ótimo que maximiza o desempenho.

Regressão KNN

Coefficiente de determinação:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

- $R^2 = 1$: previsão perfeita.
- $R^2 = 0$: modelo constante.

4 Generalização, Complexidade e Ajustamento

Generalização

Capacidade do modelo de prever corretamente dados novos.

Sobre-ajustamento (Overfitting)

Modelo demasiado complexo:

- Desempenho excelente no treino, mau no teste.
- Mitigação: mais dados, maior regularização.

Sub-ajustamento (Underfitting)

Modelo demasiado simples:

- Desempenho mau no treino e teste.

Dilema Enviesamento–Variância

- Baixa complexidade $\rightarrow$ enviesamento elevado, baixa variância.
- Alta complexidade $\rightarrow$ enviesamento baixo, alta variância.

5 Modelos Lineares, Regressão e Classificação

Modelos Lineares

- **Regressão Linear:** $\hat{y}$ é combinação linear dos atributos.
- **Classificação Linear:** Fronteira linear entre classes.

Regularização

- **Ridge (L2):** Penaliza $\sum w_i^2$.
- **Lasso (L1):** Penaliza $\sum |w_i|$, faz seleção automática de atributos.

Hiperparâmetros

- α : maior $\Rightarrow$ mais regularização (modelos mais simples).
- C : inverso da regularização (maior $C \Rightarrow$ menos regularização).

Exemplo de Regularização (Q. Generalização 1)

- $C = 0.1$ — mais simples (treino 0.84).
- $C = 1$ — equilibrado (treino 0.93).
- $C = 100$ — sobre-ajustado (treino 1.0, teste 0.9).

6 Máquinas de Vetores de Suporte (MVS)

MVS e Kernel Trick

Permite fronteiras complexas através de projeção implícita em espaços de alta dimensão.

- **Núcleo RBF (Gaussiano):** dimensão infinita.
- **Vetores de Suporte:** instâncias próximas da fronteira de decisão.

Hiperparâmetros

- C — regularização: menor $C \Rightarrow$ modelo mais simples.
- γ — largura do núcleo: maior $\gamma \Rightarrow$ fronteira mais irregular.

Sensibilidade e Pré-processamento

- Normalização é essencial (atributos na mesma escala).
- MVS não escala bem para conjuntos muito grandes.
- Baixa interpretabilidade.