

Resumo de Aprendizagem Automática

1. Aprendizagem Automática: Naïve Bayes

1.1. Algoritmo Naïve Bayes

O objetivo da Aproximação de Bayes é, dados os valores dos atributos $\{a_1, a_2, \dots, a_n\}$, atribuir a classe c_j mais provável, utilizando o teorema de Bayes.

- **Suposição Central (Naïve):** Assume a **independência condicional dos valores dos atributos dada a classe**.
- **Construção do Modelo:** Consiste em estimar as seguintes probabilidades:
 1. Probabilidade de cada classe: $P(c_j)$.
 2. Probabilidade do valor de cada atributo dada a classe: $P(a_i|c_j)$.
- **Previsão:** Escolher a classe que maximiza a expressão (implícita no teorema de Bayes, assumindo a independência).

1.2. Estimadores de Probabilidades

- **Estimador Simples:** $P(x) = n_x / \text{total}$, onde n_x é o número de vezes que x ocorre.
- **Problema do Zero:** Se o valor estimado for 0 (um valor de atributo não aparece no conjunto de treino), esse termo domina o classificador.
- **Estimador Suavizado (Smoothing):** Utiliza-se um estimador suavizado para evitar probabilidades nulas.
- **Estimador de Laplace:** É um estimador suavizado onde o parâmetro $\alpha = 1$.

1.3. Características e Variações

- **Características:**
 - Considera cada atributo individualmente, assumindo independência entre eles (dada a classe).
 - Calcula estatísticas simples de cada atributo por classe.
- **Pontos Fortes:**
 - Algoritmos de aprendizagem e classificação **rápidos**.
 - Processo de aprendizagem de fácil compreensão.
 - Produz bons resultados em dados de **muitas dimensões**.
 - Requer um número relativamente pequeno de exemplos.
 - Bom *baseline*.
- **Variações (Algoritmos):** Utilizam outros estimadores ou regras de decisão.
 - **Multinomial Naive Bayes:** Para atributos inteiros.
 - **Gaussian Naive Bayes:** Para atributos contínuos.
 - **Bernoulli Naive Bayes:** Para atributos binários.
 - **Complement Naive Bayes:** Útil para conjuntos de dados desequilibrados (proporção desequilibrada entre classes).

2. Aprendizagem Automática: Árvores de Atributos (Decisão)

2.1. Conceitos Fundamentais

- **Popularidade:** Um dos modelos mais populares de AA por serem expressivas e fáceis de perceber.
- **Natureza:** Utiliza uma abordagem de "divisão-e-conquista".
- **Estrutura:**
 - Cada **nó interno** é etiquetado com um atributo.
 - Cada **arco** é etiquetado com um literal (valor do atributo); o conjunto de literais é chamado de **divisão** (*split*).
- **Geração de Regras:** A árvore pode ser facilmente transformada numa expressão lógica (disjunção de todos os caminhos da raiz até às folhas).

2.2. Algoritmo de Construção

O algoritmo *CresceArvore* assume a definição de três funções principais:

- **Homogeneo(D):** *True* se as instâncias em *D* são homogêneas o suficiente para atribuir uma única etiqueta.
- **Etiqueta(D):** Devolve a etiqueta mais apropriada para o conjunto *D*.
- **MelhorParticao(D, A):** Devolve o melhor atributo para colocar na raiz.

Características do Algoritmo

- **Estratégia Gulosa (*Greedy*):** Na escolha da melhor divisão, a melhor alternativa é selecionada com base na informação disponível, e essa escolha **nunca é reconsiderada**. Isso pode levar a escolhas sub-ótimas.

Árvore de Decisão (Classificação)

- **Homogeneidade:** *D* é homogêneo se todos os exemplos forem de uma única classe.
- **Etiquetagem:** Etiqueta com a classe majoritária.
- **Melhor Partição:** Pesquisa a partição com **maior pureza**. Um nó "puro" tem todos os seus exemplos a pertencerem à mesma classe.

2.3. Partição de Atributos

- **Atributos Nominais:** Um ramo para cada valor do atributo. No máximo, um teste a cada atributo é feito em cada caminho da raiz às folhas.
- **Atributos Contínuos:** É feita uma discretização binária usando um **ponto de corte** ($a \leq \text{limiar}$). Podem existir vários testes ao mesmo atributo em cada caminho, com outros pontos de corte. Os pontos de corte estão na fronteira entre classes.

2.4. Função de Impureza

A função de impureza mede o grau de mistura de classes num nó, sendo 0 para um nó puro (mínimo) e 1 (máximo) para a impureza máxima. Deve ser máxima quando a proporção de classes é 1/2.

- **Funções (2 classes):**
 - **Razão do Erro (Classe Minoritária):** $\min(p, 1 - p)$.
 - **Índice de Gini:** $2p(1 - p)$. Usado também para múltiplas classes.
 - **Entropia:** $-p \log_2 p - (1 - p) \log_2 (1 - p)$ (informação esperada em bits). Usada também para múltiplas classes.
- **Impureza de uma Partição:** Calculada como a impureza de um conjunto de nós mutuamente exclusivos, geralmente ponderada.

2.5. Árvores de Regressão

- **Algoritmo:** Utiliza o mesmo algoritmo da classificação, mas a função `Homogeneo()` difere.
- **Previsão:** O resultado é o **valor médio** dos exemplos de treino da folha alcançada.
- **Limitação:** A **extrapolação não é possível**; o modelo não pode prever valores fora do intervalo do conjunto de treino.

2.6. Poda da Árvore (*Pruning*)

O sobre-ajustamento (*overfitting*) ocorre quando árvores muito complexas refletem ocorrências casuais (ruído ou variação residual) e não as relações subjacentes.

- **Objetivo da Poda:** Identificar e remover os ramos menos confiáveis para obter um **modelo mais geral**. Isto aumenta os erros no treino, mas diminui-os no teste.
- **Tipos de Poda:**
 - **Pré-Poda (*Pre-pruning*):** Limita o crescimento da árvore durante a construção, através de parâmetros como profundidade máxima ou número mínimo de exemplos em cada nó.
 - **Pós-Poda (*Post-pruning*):** O corte é feito após a árvore completa ser construída. É necessário um **conjunto de poda** distinto do conjunto de teste para a seleção da melhor árvore podada.
- **Métodos de Pós-Poda:**
 - **Cost-Complexity:** Considera o erro de classificação $R(T)$ e a complexidade da árvore $|T|$ (número de folhas). Produz uma série de árvores podadas e seleciona a que tiver menor erro no conjunto de poda.
 - **Reduced-Error:** Poda nós internos se o nó se tornar uma folha e isso diminuir o erro no conjunto de poda. Produz a versão mais pequena da árvore mais correta sobre o conjunto de poda.

2.7. Algoritmos e Características

- **Pontos Fortes:** Modelo facilmente visualizável e inteligível; algoritmo invariante à escala dos dados; rápido para criar modelo e prever classes.
- **Pontos Fracos:** Tendência para sobre-ajustamento; não garante a criação da melhor árvore (guloso); pode ser tendenciosa se os dados forem desequilibrados; modelo instável (pequenas variações nos dados geram árvores diferentes).
- **Algoritmos Notáveis:**
 - **ID3 (1986):** Classificação, utiliza entropia, apenas atributos nominais.
 - **C4.5 (1993):** Extensão do ID3, classificação, lida com atributos nominais e contínuos, valores desconhecidos, e possui pós-poda.
 - **CART (1984):** Classificação e regressão, árvores binárias, utiliza o Índice de Gini, possui pré- e pós-poda.

3. Avaliação de Modelos

3.1. Generalização e Divisão de Dados

- **Objetivo:** Verificar quão bem o modelo generaliza em dados não observados.
- **Divisão Treino-Teste:** O modelo é treinado no conjunto de treino e avaliado no conjunto de teste. O foco está na previsão em dados não observados.

3.2. Validação Cruzada (*Cross-Validation*)

É uma forma mais **robusta, estável e completa** de avaliar a generalização.

- **k-Pastas (*k-Fold*):** O conjunto de dados é dividido em k subconjuntos (pastas), usualmente 5 ou 10. k modelos são treinados, onde em cada iteração uma pasta é o conjunto de teste e as restantes são o treino. A estimativa final é a média das k medidas de desempenho.

Benefícios: Cada exemplo serve como teste uma vez; fornece informação sobre a sensibilidade do modelo à seleção do conjunto de treino; permite um tamanho maior do conjunto de treino (uso mais efetivo dos dados).

Desvantagem: Custo computacional acrescido.

- **Validação Estratificada:** Mantém a proporção entre classes do conjunto completo em cada pasta, resultando em estimativas mais confiáveis.
- **Leave-One-Out (LOO):** k é igual ao número de exemplos. Demorada para conjuntos grandes, mas útil para conjuntos pequenos.

3.3. Ajuste de Hiperparâmetros

- **Objetivo:** Encontrar os valores dos hiperparâmetros que originam o melhor desempenho de generalização.
- **Conjunto de Validação:** A avaliação de modelos com diferentes hiperparâmetros deve ser feita com um conjunto de validação (distinto do treino e do teste).
- **Processo de Divisão (Boa Prática):**
 1. Dividir os dados em **Treino, Validação, Teste**.
 2. Usar Treino para construir modelos.
 3. Usar Validação para selecionar o modelo (escolha dos hiperparâmetros).
 4. Reconstruir o modelo final com os melhores hiperparâmetros usando **Treino + Validação** (para usar o máximo de dados possível).
 5. Usar o **Teste** apenas para a avaliação final do desempenho futuro.
- **Grid Search (*Pesquisa em Grelha*):** Método que tenta todas as combinações possíveis de hiperparâmetros. É frequentemente combinado com validação cruzada para obter uma estimativa mais robusta do desempenho de cada combinação.
- **Drenagem de Informação:** Quaisquer escolhas baseadas no desempenho do conjunto de teste "drenam" informação, resultando numa estimativa otimista. Deve-se reservar o conjunto de teste **APENAS** para a avaliação final.

3.4. Medidas de Desempenho (Métricas)

Classificação Binária

- **Matriz de Confusão:**
 - **VN:** Verdadeiros Negativos; **FP:** Falsos Positivos.
 - **FN:** Falsos Negativos; **VP:** Verdadeiros Positivos.
- **Dados Não Balanceados:** Conjuntos onde o número de exemplos de uma classe é muito maior que o da outra (muito comuns na realidade). Nestes casos, a **Exatidão (*Accuracy*)** não é a medida adequada, pois um classificador *dummy* que prevê sempre a classe majoritária pode ter exatidão alta (e.g., 0.90).
- **Indicadores Chave** (Calculados a partir da Matriz de Confusão):
 - **Exatidão:** Proporção de instâncias corretamente classificadas.
 - **Taxa de Verdadeiros Positivos (Cobertura / Sensibilidade):** Proporção de instâncias positivas corretamente classificadas ($VP/(FN + VP)$). Usada quando é importante evitar **Falsos Negativos** (FN).
 - **Taxa de Verdadeiros Negativos (Especificidade):** Proporção de instâncias negativas corretamente classificadas.
 - **Precisão (*Precision* / Confiança):** Proporção de verdadeiros positivos entre os classificados como positivos ($VP/(FP + VP)$). Usada quando se quer limitar o número de **Falsos Positivos** (FP).
- **Medida F_β :** Considera o compromisso entre precisão e cobertura.
 - **$F_1(\beta = 1)$:** Média harmónica de precisão e cobertura, dando o mesmo peso a ambas. É uma **melhor medida que a exatidão** para dados não balanceados.
 - **$\beta = 2$:** Dá mais peso à cobertura.
 - **$\beta = 0.5$:** Dá mais peso à precisão.

Classificação Multi-Classe

Para métricas multi-classe, a medida é calculada para cada classe (tratando-a como positiva e as restantes como negativas) e depois é calculada uma média.

- **Macro-Média (Simples):** Média não pesada. Usar quando **todas as classes têm a mesma importância**.
- **Micro-Média:** Soma-se o número de FP, FN e VP de todas as classes e depois calcula-se a medida. Usar quando **todos os exemplos têm a mesma importância**.

Regressão

- **R^2 (Coeficiente de Determinação):** Proporção da variância explicada. O melhor valor é 1, mas pode ser negativo.
- **Erro Quadrado Médio (*Mean Squared Error*).**
- **Erro Absoluto Médio (*Mean Absolute Error*).**

Formulário:

1. Naïve Bayes

Fórmula de classificação usando o Teorema de Bayes

$$\arg \max_{c_j \in C} \frac{P(a_1, a_2, \dots, a_n | c_j) \cdot P(c_j)}{P(a_1, a_2, \dots, a_n) \rightarrow \text{constante}}$$

$$\text{Logo: } \arg \max_{c_j \in C} P(a_1, a_2, \dots, a_n | c_j) \cdot P(c_j)$$

$$P(a_1, a_2, \dots, a_n | c_j) = P(a_1 | c_j) \cdot P(a_2 | c_j) \cdot \dots \cdot P(a_n | c_j)$$

Teorema de Bayes

$$P(A | B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Previsão:

$$P(c_j) \cdot \prod_{i=1}^n P(a_i | c_j)$$

Estimador de Probabilidades:

Estimador Simples:

$$P(x) = \frac{n_x}{\text{total}}$$

Estimador Suavizado:

$$P(x) = \frac{n_x + \alpha}{\text{total} + \alpha \cdot \text{nvals}}$$

Estimador de Laplace:

$$P(x) = \frac{n_x + \alpha}{\text{total} + \alpha \cdot \text{nvals}} ; \quad \alpha = 1$$

2. Árvores de Atributos (Decisão)

Funções de Impureza:

Razão do Erro:

$$\min(p, 1 - p)$$

Índice de Gini:

$$2 \cdot p \cdot (1 - p)$$

$$Gini(D) = 1 - \sum_{c=1}^n p_c^2$$

Entropia:

$$-p \cdot \log_2 p - (1 - p) \cdot \log_2 (1 - p)$$

$$Entropia(D) = - \sum_{c=1}^n p_c \cdot \log_2 p_c$$

Impurezas:

Impureza de um nó:

$$Imp(D_j)$$

Impureza de uma partição:

$$Imp(D_1, \dots, D_n) = \sum_{j=1}^n \frac{|D_j|}{|D|} \cdot Imp(D_j)$$

Medida de cost-complexity:

$$R_\alpha(T) = R(T) + \alpha \cdot |T|$$

- $R(T)$: erro de classificação nas folhas da árvore T .
- $|T|$: número de folhas da árvore.
- α : parâmetro de penalização pela complexidade.

3. Avaliação de Modelos

Indicadores de Desempenho:

Métrica	Descrição	Fórmula
Exatidão	Proporção de instâncias de teste corretamente classificadas.	$Acc = \frac{VP+VN}{Total}$
Taxa de Erro	Proporção de instâncias incorretamente classificadas.	$Err = \frac{FP+FN}{Total}$
Sensibilidade / Cobertura	Proporção de instâncias positivas classificadas corretamente.	$Rec = \frac{VP}{VP+FN}$
Especificidade / Cobertura Negativa	Proporção de instâncias negativas classificadas corretamente.	$TNR = \frac{VN}{VN+FP}$
Taxa de Falsos Negativos	Proporção de instâncias positivas mal classificadas.	$FNR = \frac{FN}{Pos}$
Taxa de Falsos Positivos / Falso Alarme	Proporção de instâncias negativas mal classificadas.	$FPR = \frac{FP}{Neg}$
Precisão / Confiança	Proporção de verdadeiros positivos entre os classificados como positivos.	$Prec = \frac{VP}{VP+FP}$

Medida F_β :

- β : parâmetro que valoriza a precisão ou cobertura quando comparadas.

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}$$

- $\beta = 1$: Dá o mesmo peso à precisão e cobertura.
- $\beta = 2$: Dá mais peso à cobertura.
- $\beta = 0.5$: Dá mais peso à precisão.

Medida de Desempenho para Multi-Classe:

Micro-Média:

$$\text{Precisão}_{Micro} = \text{Cobertura}_{Micro} = F_{1\ Micro} = \frac{\sum VP}{\text{Total}}$$

Macro-Média (Simples)

A Macro-média (simples) é a média não pesada das métricas individuais por classe, assumindo que todas as classes têm a mesma importância.

$$\text{Precisão}_{Macro} = \frac{Prec_A + Prec_B + Prec_C}{N^\circ \text{ de Classes}}$$

$$\text{Cobertura}_{Macro} = \frac{Cob_A + Cob_B + Cob_C}{N^\circ \text{ de Classes}}$$

$$F_{1\ Macro} = \frac{F_{1\ A} + F_{1\ B} + F_{1\ C}}{N^\circ \text{ de Classes}}$$

Macro-Média Ponderada (Weighted Macro-average)

A Média Ponderada utiliza o peso (W_i) de cada classe, proporção de exemplos reais, para calcular a média.

$$W_A = \frac{N^\circ \text{ de Exemplos da Classe } A}{N^\circ \text{ Total de Exemplos}} \quad W_B = \dots \quad W_C = \dots$$

$$\text{Precisão}_{Ponderada} = (Prec_A \cdot W_A) + (Prec_B \cdot W_B) + (Prec_C \cdot W_C)$$

$$\text{Cobertura}_{Ponderada} = (Cob_A \cdot W_A) + (Cob_B \cdot W_B) + (Cob_C \cdot W_C)$$

$$F_{1\ Ponderada} = (F_{1\ A} \cdot W_A) + (F_{1\ B} \cdot W_B) + (F_{1\ C} \cdot W_C)$$

Métricas para Regressão:

R-Squared:

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Erro Quadrático Médio (MSE):

$$MSE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Erro Absoluto Médio (MAE):

$$MAE(y, \hat{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Resolução Ficha 6:

B. Naïve Bayes:

Considere o seguinte conjunto de dados:

Id	Atr1	Atr2	Atr3	Atr4	Classe
1	F	V	F	F	setosa
2	F	V	F	F	setosa
3	F	V	F	F	setosa
4	V	F	F	F	versicolor
5	F	F	F	F	versicolor
6	F	F	F	F	versicolor
7	V	F	F	V	virginica
8	V	F	V	V	virginica
9	V	V	V	V	virginica

1. Calcule (à mão) a que classe pertence o exemplo $\{Atr1, Atr2, Atr3, Atr4\} = \{F, F, V, F\}$ se o conjunto for apresentado ao algoritmo Naïve Bayes. Deverá usar o estimador simples ou um estimador “suavizado” como o estimador de Laplace?

Resolução:

Não seria útil usar o estimador simples visto que nas das combinações para o exemplo dado obteríamos valores nulos, na classe ‘setosa’, por exemplo, o $\{Atr2\}$ seria nulo dado que não existem elementos no conjunto de treino que sejam Falsos tal como no exemplo em estudo, retornando um valor nulo para a probabilidade do mesmo, impossibilitando então o uso do estimador simples.

Usando portanto o estimador de Laplace:

Estimador de Laplace: $P(x) = \frac{n_x + \alpha}{\text{total} + \alpha \cdot \text{nvals}}$; $\alpha = 1$

Probabilidade das Classes:

$$P(\text{setosa}) = \frac{3+1}{9+1 \cdot 3} = \frac{4}{12} = \frac{1}{3} \quad P(\text{versicolor}) = \frac{3+1}{9+1 \cdot 3} = \frac{4}{12} = \frac{1}{3} \quad P(\text{virginica}) = \frac{3+1}{9+1 \cdot 3} = \frac{4}{12} = \frac{1}{3}$$

Probabilidade dos Atributos dadas as Classes:

$$P(Atr1 = F | \text{setosa}) = \frac{3+1}{3+1 \cdot 2} = \frac{4}{5}$$

$$P(Atr1 = F | \text{versicolor}) = \frac{2+1}{3+1 \cdot 2} = \frac{3}{5}$$

$$P(Atr1 = F | \text{virginica}) = \frac{0+1}{3+1 \cdot 2} = \frac{1}{5}$$

$$P(Atr2 = F | \text{setosa}) = \frac{0+1}{3+1 \cdot 2} = \frac{1}{5}$$

$$P(Atr2 = F | \text{versicolor}) = \frac{3+1}{3+1 \cdot 2} = \frac{4}{5}$$

$$P(Atr2 = F | \text{virginica}) = \frac{2+1}{3+1 \cdot 2} = \frac{3}{5}$$

$$P(Atr3 = V | \text{setosa}) = \frac{0+1}{3+1 \cdot 2} = \frac{1}{5}$$

$$P(Atr3 = V | \text{versicolor}) = \frac{0+1}{3+1 \cdot 2} = \frac{1}{5}$$

$$P(Atr3 = V | \text{virginica}) = \frac{2+1}{3+1 \cdot 2} = \frac{3}{5}$$

$$P(Atr4 = F | \text{setosa}) = \frac{3+1}{3+1 \cdot 2} = \frac{4}{5}$$

$$P(Atr4 = F | \text{versicolor}) = \frac{3+1}{3+1 \cdot 2} = \frac{4}{5}$$

$$P(Atr4 = F | \text{virginica}) = \frac{0+1}{3+1 \cdot 2} = \frac{1}{5}$$

$$P(\text{setosa}) = \frac{1}{3} \cdot \frac{4}{5} \cdot \frac{1}{5} \cdot \frac{1}{5} \cdot \frac{4}{5} = \frac{16}{1875}$$

$$P(\text{versicolor}) = \frac{1}{3} \cdot \frac{3}{5} \cdot \frac{4}{5} \cdot \frac{1}{5} \cdot \frac{4}{5} = \frac{48}{1875} \leftarrow$$

$$P(\text{virginica}) = \frac{1}{3} \cdot \frac{1}{5} \cdot \frac{3}{5} \cdot \frac{3}{5} \cdot \frac{1}{5} = \frac{9}{1875}$$

A classe que maximiza a expressão é a

‘versicolor’, logo o exemplo $\{F, F, V, F\}$

pertence à classe ‘versicolor’.

Resolução Ficha 8:

A. Desempenho de Modelos:

1. Considere a seguinte matriz de confusão:

Real \ Prevista	A	B	C
A	11	9	5
B	3	17	0
C	4	11	40

- a. Quantos exemplos tem cada classe?

Resolução:

$$\text{Classe A : } 11 + 9 + 5 = 25$$

$$\text{Classe B : } 3 + 17 + 0 = 20$$

$$\text{Classe C : } 4 + 11 + 40 = 55$$

$$\text{Total : } 25 + 20 + 55 = 100$$

- b. Considerando a classe B, calcule o nº de verdadeiros positivos, verdadeiros negativos, falsos positivos, falsos negativos.

Resolução:

Considerando B :

$$N^{\circ} \text{ de Verdadeiros Positivos : } 17$$

$$N^{\circ} \text{ de Verdadeiros Negativos : } 11 + 5 + 4 + 40 = 60$$

$$N^{\circ} \text{ de Falsos Positivos : } 9 + 11 = 20$$

$$N^{\circ} \text{ de Falsos Negativos : } 3 + 0 = 3$$

- c. Calcule a exatidão.

Resolução:

$$\text{Exatidão : } \frac{11+17+40}{100} = \frac{68}{100} = 0.68 \text{ ou seja, } 68\%$$

- d. Calcule a precisão, cobertura e F1 para **cada uma das classes**.

Resolução:

- Classe A :

$$\text{Precisão : } \frac{VP}{VP+FP} = \frac{11}{11+3+4} = \frac{11}{18} \approx 0.611$$

$$\text{Cobertura : } \frac{VP}{VP+FN} = \frac{11}{11+9+5} = \frac{11}{25} = 0.44$$

$$F_1 : F_{\beta} = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}; \beta = 1 \iff$$

$$\iff F_1 = (1 + 1^2) \cdot \frac{0.611 \cdot 0.44}{(1^2 \cdot 0.611) + 0.44} = 0.512$$

- *Classe B :*

$$Precisão : \frac{VP}{VP+FP} = \frac{17}{17+9+11} = \frac{17}{37} \approx 0.459$$

$$Cobertura : \frac{VP}{VP+FN} = \frac{17}{17+3} = \frac{17}{20} = 0.85$$

$$F_1 : F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}; \beta = 1 \iff$$

$$\iff F_1 = (1 + 1^2) \cdot \frac{0.459 \cdot 0.85}{(1^2 \cdot 0.459) + 0.85} = 0.596$$

- *Classe C :*

$$Precisão : \frac{VP}{VP+FP} = \frac{40}{40+5} = \frac{40}{45} \approx 0.889$$

$$Cobertura : \frac{VP}{VP+FN} = \frac{40}{40+4+11} = \frac{40}{55} \approx 0.727$$

$$F_1 : F_\beta = (1 + \beta^2) \cdot \frac{\text{precision} \cdot \text{recall}}{(\beta^2 \cdot \text{precision}) + \text{recall}}; \beta = 1 \iff$$

$$\iff F_1 = (1 + 1^2) \cdot \frac{0.889 \cdot 0.727}{(1^2 \cdot 0.889) + 0.727} = 0.800$$

- e. Calcule a precisão, cobertura e F1 do **classificador** usando micro-média, macro-média e média ponderada.

Resolução:

1. Micro – Média (*Micro – average*)

A Micro-média é calculada pela agregação global das contagens, e é igual à Exatidão, uma vez que $\sum VP = 11 + 17 + 40 = 68$. Este método é usado quando todos os exemplos têm a mesma importância.

$$Precisão_{Micro} = Cobertura_{Micro} = F1_{Micro} = \frac{\sum VP}{Total} = \frac{68}{100} = \mathbf{0.68}$$

2. Macro – Média (*Simple*)

A Macro-média (simple) é a média não pesada das métricas individuais por classe, assumindo que todas as classes têm a mesma importância.

$$Precisão_{Macro} = \frac{Prec_A + Prec_B + Prec_C}{3} \approx \frac{0.611 + 0.459 + 0.889}{3} \approx \mathbf{0.653}$$

$$Cobertura_{Macro} = \frac{Cob_A + Cob_B + Cob_C}{3} \approx \frac{0.440 + 0.850 + 0.727}{3} \approx \mathbf{0.672}$$

$$F1_{Macro} = \frac{F1_A + F1_B + F1_C}{3} \approx \frac{0.512 + 0.596 + 0.800}{3} \approx \mathbf{0.636}$$

3. Média Ponderada (*Weighted Macro – average*)

A Média Ponderada utiliza o peso (W_i) de cada classe, proporção de exemplos reais, para calcular a média.

$$W_A = \frac{25}{100} = 0.25 \quad W_B = \frac{20}{100} = 0.20 \quad W_C = \frac{55}{100} = 0.55$$

$$Precisão_{Ponderada} = (Prec_A \cdot W_A) + (Prec_B \cdot W_B) + (Prec_C \cdot W_C)$$

$$Precisão_{Ponderada} \approx (0.611 \cdot 0.25) + (0.459 \cdot 0.20) + (0.889 \cdot 0.55) \approx \mathbf{0.734}$$

$$Cobertura_{Ponderada} = (Cob_A \cdot W_A) + (Cob_B \cdot W_B) + (Cob_C \cdot W_C)$$

$$Cobertura_{Ponderada} \approx (0.440 \cdot 0.25) + (0.850 \cdot 0.20) + (0.727 \cdot 0.55) \approx \mathbf{0.680}$$

$$F1_{Ponderada} = (F1_A \cdot W_A) + (F1_B \cdot W_B) + (F1_C \cdot W_C)$$

$$F1_{Ponderada} \approx (0.512 \cdot 0.25) + (0.596 \cdot 0.20) + (0.800 \cdot 0.55) \approx \mathbf{0.687}$$

2. Considere um conjunto de dados com a seguinte distribuição de exemplos por classe $c_1=30000$, $c_2=1000$, $c_3=500$. Assuma que pretende calcular uma estimativa do desempenho para o melhor modelo entre árvores de decisão, k -vizinhos mais próximos e SVM, pesquisando, para cada algoritmo, quais os melhores parâmetros.

- a. Indique uma divisão de dados adequada e o objetivo de cada subconjunto.

Resolução:

- A divisão de dados mais adequada para este problema, que requer a pesquisa dos melhores parâmetros para diferentes algoritmos, é a divisão em três subconjuntos: Treino, Validação e Teste.
 - **Conjunto de:**
 - **Treino:** Utilizado para construir o modelo de Aprendizagem Automática.
 - **Validação:** Utilizado para a seleção do modelo e escolha dos hiperparâmetros (*ex: Grid Search ou Validação Cruzada k -pastas*) que originam o melhor desempenho de generalização.
 - **Teste:** Reservado apenas para a avaliação final do desempenho futuro do modelo selecionado. É crucial para obter uma estimativa não enviesada da generalização.
 - Dado que o conjunto de dados está desequilibrado ($c_1=30000$, $c_2=1000$, $c_3=500$), é recomendado utilizar a Validação Estratificada (*k -pastas estratificadas*) para garantir que a proporção entre as classes é mantida em cada subconjunto (Treino, Validação e Teste).
- b. Considera a exatidão a medida de desempenho mais adequada para o problema? Justifique a resposta.

Resolução:

- Não, a Exatidão não é a medida de desempenho mais adequada para este problema pois o conjunto de dados é altamente desbalanceado ($c_1: 30000$, $c_2: 1000$, $c_3: 500$). Em conjuntos de dados onde o número de exemplos de uma classe é muito maior que o das outras qualquer classificador que simplesmente preveja a classe maioritária (c_1) para todos os exemplos atingiria uma exatidão superior, ou seja, uma exatidão alta neste contexto seria enganadora e não indicaria se o modelo está de facto a aprender a distinguir as classes minoritárias (c_2 e c_3).
- Para problemas de classificação multi-classe com dados desequilibrados, devem ser utilizadas métricas que lidam melhor com as diferentes taxas de erro (Falsos Positivos e Falsos Negativos), como a Precisão, Cobertura e Medida F1.