

Análise de Dados em Larga Escala com Spark

Trabalho Prático Final de Ciência de Dados e Big Data

Universidade de Évora - 2025/2026

Objetivo:

Desenhar e implementar um pipeline completo de análise de grandes volumes de dados utilizando **Hadoop MapReduce**, **Spark (RDDs, DataFrames, Spark SQL)** e **Spark MLlib** para processamento, análise e modelação preditiva. O aluno deverá escolher e justificar a escolha do conjunto de dados com base em critérios de volume, variedade e adequação aos métodos estudados.

Parte 1 (50%)

Fase 1: Escolha e Justificação do Conjunto de Dados

- Escolher um conjunto de dados simulado ou real de domínio aberto (ex.: redes sociais, e-commerce, sensores, logística, clima, saúde, etc.).
- **Justificar** a escolha com base em:
 - Volume (adequação a processamento distribuído).
 - Variedade (dados estruturados/semi-estruturados).
 - Potencial para aplicação de MapReduce, Spark e ML.

Fase 2: Processamento e Transformação com Spark RDDs

- Pre-processamento dos dados (caso seja necessário)
- Carregar os dados em **RDDs**.
- Aplicar **transformações e ações** para limpeza, enriquecimento, etc
- Demonstrar o uso de **cache** e **particionamento**.
- Implementar pelo menos uma tarefa de **MapReduce** (ex.: contagem, filtragem, agregação) relevante para o domínio.

Fase 3: Análise Estruturada com Spark SQL e DataFrames

- Converter os dados para **DataFrames**.
- Formular e executar consultas analíticas com **Spark SQL**.
- Comparar desempenho entre RDDs e DataFrames.

Parte 2 (50%)

Fase 1: Modelação com Spark MLlib / Python

- Implementar pelo menos **um algoritmo de Machine Learning** estudado, como, por exemplo, **K-means / Decision Trees**.
- Construir um **pipeline completo** para uma abordagem global e se possível outro para local.

Fase 2: Análise de Escalabilidade

- Testar o pipeline com subconjuntos de dados de diferentes tamanhos.
 - Medir e analisar:
 - **Speed-up, Size-up, Scale-up**.
 - Impacto de caching e número de partições.\
-

Entregáveis:

1. **Código fonte** (Python/PySpark, MapReduce).
 2. **Dataset** ou referência à fonte pública utilizada.
 3. **Relatório** contendo:
 - Descrição e justificação do dataset.
 - Explicação de cada etapa com referência aos tópicos da disciplina.
 - Análise crítica dos resultados e desempenho.
 - Gráficos e tabelas comparativas.
 - Reflexão sobre limitações e melhorias futuras.
-

Datas:

- Entrega: 13 de janeiro (20h)
- Apresentação: 14 de janeiro / 15 de janeiro