

1. Processos Estocásticos

O estudo de Processos Estocásticos surge da necessidade de modelar fenómenos que não são estáticos. Ao contrário da estatística clássica, que muitas vezes lida com amostras independentes, os processos estocásticos focam-se na construção de modelos matemáticos para descrever o comportamento de variáveis aleatórias que:

- Evoluem ao longo do tempo (dinâmicos);
- Não são independentes entre si (possuem uma estrutura de dependência);
- Apresentam padrões aleatórios que necessitam de ser captados para fins de previsão e simulação.

Aplicações Práticas

A versatilidade dos processos estocásticos permite a sua aplicação em diversas áreas científicas e práticas. Exemplos notáveis incluem:

- **Epidemiologia:** Modelação de taxas de incidência de doenças infecciosas (ex: COVID-19, Tuberculose, Malária).
- **Biologia:** Modelação de crescimento populacional bacteriano e modelos de crescimento/extinção (humano ou animal).
- **Gestão Hospitalar:** Previsão do número de doentes admitidos em urgências (ex: diariamente).
- **Controlo de Qualidade:** Monitorização do número de defeitos ou falhas em processos de fabrico (por unidade de tempo ou lote).
- **Ciências Ambientais:** Análise de concentrações de poluentes atmosféricos (diárias, semanais).
- **Finanças:** Modelação de retornos financeiros e volatilidade de mercados.
- **Engenharia:** Análise de tráfego em sistemas de comunicação.

Definição Formal de Processo Estocástico

Um Processo Estocástico (p.e.) pode ser entendido, de forma intuitiva, como uma coleção de observações indexadas por um parâmetro (geralmente o tempo) onde a ordem dos registos é fundamental.

Estrutura Matemática

Seja $(\Omega, \mathcal{A}, P)$ um espaço de probabilidades.

- Uma **Variável Aleatória (v.a.)** clássica é uma função mensurável $X : \Omega \rightarrow S$.
- Um **Processo Estocástico** introduz o tempo t , que assume valores num conjunto T (Espaço Parâmetro ou Espaço dos Índices).

O modelo matemático é definido como uma aplicação X de $T \times \Omega$ no Espaço de Estados S :

$$X : T \times \Omega \rightarrow S$$

Notação e Terminologia

- **Notação:** Representa-se por $\{X_t, t \in T\}$ se o tempo for discreto, ou $\{X(t), t \in T\}$ se o tempo for contínuo.
- **Fixando o tempo (t):** Para um $t \in T$ fixo, a aplicação $\omega \rightarrow X_t(\omega)$ é uma **Variável Aleatória** sobre o espaço de probabilidades.
- **Fixando o acaso (ω):** Para um $\omega \in \Omega$ fixo, a aplicação $t \rightarrow X_\omega(t)$ chama-se uma **Trajetória** ou **Realização** do processo.

Uma série temporal observada (como um gráfico de vendas mensais) é, na prática, apenas *uma* única trajetória (realização) de um processo estocástico subjacente.

Propriedades: Estacionariedade

A estacionariedade é uma propriedade fundamental que indica que o comportamento estatístico do processo não se altera com o deslocamento no tempo. Existem dois tipos principais:

1. Estacionariedade Forte (Sentido Estrito)

Um processo $\{X_t\}_{t \in T}$ diz-se fortemente estacionário se a distribuição conjunta de qualquer conjunto finito de variáveis é invariante no tempo. Ou seja, para qualquer $n \geq 1$, qualquer deslocamento $k \geq 0$ e qualquer escolha de índices $(t_1, t_2, \dots, t_n) \in T$, a distribuição do vetor:

$$(X_{t_1}, X_{t_2}, \dots, X_{t_n})$$

é idêntica à distribuição do vetor deslocado:

$$(X_{t_1+k}, X_{t_2+k}, \dots, X_{t_n+k})$$

Em termos de função de distribuição acumulada:

$$F_{t_1, \dots, t_n}(x_1, \dots, x_n) = F_{t_1+k, \dots, t_n+k}(x_1, \dots, x_n)$$

2. Estacionariedade de Segunda Ordem (Frac)

Um processo diz-se estacionário de segunda ordem (ou estacionário em covariância) se satisfizer três condições relativas aos seus momentos (assumindo que $E[X_t^2] < +\infty$):

1. **Média Constante:** O valor esperado não depende de t .

$$E[X_t] = m \quad (\text{constante}), \quad \forall t \in T$$

2. **Variância Constante:** A variância não depende de t .

$$\text{Var}[X_t] = \sigma^2 \quad (\text{constante}), \quad \forall t \in T$$

3. **Covariância Dependente apenas do "Lag"**: A covariância entre duas observações depende apenas da distância temporal entre elas ($|t - s|$), e não do momento em que ocorrem.

$$\text{Cov}(X_t, X_s) = \text{Cov}(X_{t+k}, X_{s+k}) = \gamma(|t - s|)$$

Nota Importante: Na literatura científica, quando o termo "estacionário" é usado sem qualificação, refere-se habitualmente à **Estacionariedade de Segunda Ordem**.

Exemplos Teóricos de Estudo

Para consolidar o conceito de estacionariedade, considerem-se os seguintes casos teóricos típicos na modelação de séries:

Caso 1: Passeio Aleatório (Random Walk)

Considere um processo Z_t definido pela soma acumulada de ruídos brancos X_n (onde X_n são i.i.d. com média 0 e variância σ^2):

$$Z_t = Z_{t-1} + X_t = \sum_{i=0}^t X_i$$

Análise: Este processo **não** é estacionário. Embora a média possa ser constante (zero), a variância cresce linearmente com o tempo ($\text{Var}(Z_t) = t\sigma^2$), violando a condição de variância constante.

Caso 2: Processo de Médias Móveis (MA)

Considere um processo que modela, por exemplo, o crescimento do PIB:

$$X_t = \mu + Z_t + \theta_1 Z_{t-1} + \theta_2 Z_{t-2}$$

Onde Z_t é ruído branco (não correlacionado, média nula, variância σ_Z^2). **Análise:** Este processo tende a ser estacionário, pois:

- A média é constante (μ).
- A variância é uma combinação linear finita das variâncias dos termos de erro Z , logo é constante.
- A autocovariância dependerá apenas da defasagem temporal entre os termos Z .

2. Modelos de Previsão e Modelos Lineares Generalizados (GLMs)

Nota: Última matéria abordada.

Os Modelos Lineares Generalizados (MLGs ou GLMs) constituem uma vasta classe de modelos flexíveis que generalizam o Modelo de Regressão Linear Clássico. Introduzidos por Nelder e Wedderburn (1972), estes modelos permitem analisar a influência de variáveis explicativas (X) sobre uma variável resposta (Y) que não segue necessariamente uma distribuição Normal.

Os GLMs englobam:

- Modelo de regressão linear (clássico);
- Modelos de regressão logística (logit, probit);
- Modelos de regressão de Poisson e log-lineares.

Comparação: Modelo Clássico vs. GLM

Modelo Linear Clássico

No modelo linear múltiplo clássico com p preditores, assume-se que:

- A variável dependente Y é contínua;
- Os erros ϵ_i são independentes e identicamente distribuídos (i.i.d.) com distribuição Normal de média zero e variância constante σ^2 ;
- O valor esperado de Y é uma função linear direta das covariáveis:

$$E[Y_i|X] = \mu_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi} = X\beta^T$$

- A função de ligação é a **identidade**: $g(\mu) = \mu$.

Generalização nos GLMs

Nos GLMs, a relação entre a média da variável resposta (μ) e o preditor linear não precisa de ser identidade. Existe uma **função de ligação** (link function) g , diferenciável e monótona, tal que:

$$g(\mu_i) = \beta_0 + \beta_1 X_{1i} + \dots + \beta_p X_{pi}$$

Isto permite modelar dados onde a variável resposta segue qualquer distribuição da **Família Exponencial**.

Componentes Fundamentais de um GLM

Um GLM é definido por três componentes estruturais:

1. Componente Aleatória

Refere-se à variável resposta Y .

- São n observações independentes.
- A distribuição de Y pertence à família exponencial (ex: Normal, Poisson, Binomial, Gama).
- A variância da resposta depende da média (ao contrário do modelo clássico onde é constante).

2. Componente Sistemática (Estrutural)

Refere-se às variáveis explicativas (preditores) $X_1, \dots, X_p$.

- Define-se o **preditor linear** η_i como:

$$\eta_i = \sum_{j=0}^p \beta_j X_{ji} = X_i \beta^T$$

3. Função de Ligação (Link Function)

É a função $g(\cdot)$ que conecta a componente aleatória à sistemática:

$$g(\mu_i) = \eta_i$$

Como g é invertível, temos que $\mu_i = g^{-1}(\eta_i)$. **Nota Importante:** Nos GLMs não existe um termo de erro aditivo (ϵ) explícito como na regressão linear. A variação aleatória é inerente à distribuição de probabilidade assumida para Y .

A Família Exponencial de Distribuições

Uma variável aleatória Y pertence à família exponencial se a sua função densidade (ou massa) de probabilidade puder ser escrita na forma:

$$f(y|\theta, \phi) = \exp \left\{ \frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right\}$$

Onde:

- θ : Parâmetro canónico (de localização).
- ϕ : Parâmetro de dispersão (conhecido ou a estimar).
- $b(\theta)$, $a(\phi)$, $c(y, \phi)$: Funções reais conhecidas.

Exemplos de Dedução da Família Exponencial

1. **Distribuição Normal** ($Y \sim N(\mu, \sigma^2)$) A densidade pode ser reescrita como:

$$f(y) = \exp \left\{ \frac{y\mu - \mu^2/2}{\sigma^2} - \frac{y^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2) \right\}$$

Parâmetros identificados:

- $\theta = \mu$
- $\phi = \sigma^2$
- $b(\theta) = \theta^2/2$
- $a(\phi) = \phi$

2. **Distribuição de Poisson** ($Y \sim P(\lambda)$)

$$f(y) = \exp\{y \ln(\lambda) - \lambda - \ln(y!)\}$$

Parâmetros identificados:

- $\theta = \ln(\lambda) \Rightarrow \lambda = e^\theta$
- $\phi = 1$
- $b(\theta) = e^\theta$

3. **Distribuição de Bernoulli** ($Y \sim Ber(p)$)

$$f(y) = \exp \left\{ y \ln \left(\frac{p}{1-p} \right) + \ln(1-p) \right\}$$

Parâmetros identificados:

- $\theta = \ln \left(\frac{p}{1-p} \right)$ (Logit)
- $b(\theta) = \ln(1 + e^\theta) = -\ln(1-p)$

Funções de Ligação Canônicas

A função de ligação é dita **canônica** quando $g(\mu) = \theta$.

Distribuição	Média (μ)	Função Canônica $g(\mu)$	Nome
Normal	μ	μ	Identidade
Poisson	λ	$\ln(\lambda)$	Logarítmica
Bernoulli/Binomial	p	$\ln \left(\frac{p}{1-p} \right)$	Logit
Gama	μ	$1/\mu$	Recíproca

Modelos GLM para Dados Discretos (Binários)

Quando a variável resposta é binária ($Y \in \{0, 1\}$), modela-se a probabilidade de sucesso $p = E[Y]$. As funções de ligação mapeiam o intervalo $[0, 1]$ para a reta real $\mathbb{R}$.

1. Regressão Logística (Link Logit)

- **Link:** $g(p) = \ln\left(\frac{p}{1-p}\right) = X\beta^T$.
- **Inversa:** $p = \frac{e^{X\beta^T}}{1+e^{X\beta^T}} = \frac{1}{1+e^{-X\beta^T}}$.
- Baseada na Função de Distribuição Acumulada (FDA) Logística.
- Simétrica em torno de $p = 0.5$ (ponto de inflexão em $X\beta^T = 0$).

2. Regressão Probit

- **Link:** $g(p) = \Phi^{-1}(p)$, onde Φ é a FDA da Normal Standard $N(0, 1)$.
- **Inversa:** $p = \Phi(X\beta^T)$.
- Também é simétrica, semelhante ao logit mas com caudas mais leves.

3. Regressão Complementar Log-Log (Cloglog)

- **Link:** $g(p) = \ln(-\ln(1-p))$.
- **Inversa:** $p = 1 - \exp(-\exp(X\beta^T))$.
- Baseada na distribuição de Gumbel (valores extremos).
- **Não simétrica:** O crescimento da probabilidade é abrupto numa direção e suave noutra. Ponto de inflexão em $p \approx 0.63$.

Etapas de Modelação e Estimação

Processo

1. **Formulação:** Escolha da distribuição (família), covariáveis e função de ligação.
2. **Estimação:** Método de Máxima Verosimilhança (MV) via métodos numéricos iterativos.
3. **Seleção:** Avaliação da significância dos parâmetros.
4. **Validação:** Análise de resíduos e qualidade de ajustamento.

Implementação em R

Usa-se a função `glm()`. O argumento `family` define a distribuição e o link.

- Logística: `family = binomial(link = "logit")` (ou apenas `binomial`).
- Probit: `family = binomial(link = "probit")`.
- Poisson: `family = poisson`.

Avaliação da Qualidade do Modelo e Inferência

Ao contrário da soma dos quadrados dos resíduos (SQR) clássica, nos GLMs utiliza-se o conceito de **Verosimilhança** e **Deviance** (Desvio).

Conceitos de Modelo

- **Modelo Nulo:** Apenas a constante (intercepto). Nenhuma variação explicada.
- **Modelo Saturado:** Tantos parâmetros quantas observações (n). Ajuste perfeito (L_T), sem graus de liberdade para erro.
- **Modelo Ajustado:** O modelo proposto (L_M).

Deviance (Desvio)

A Deviance mede a distância entre o modelo ajustado e o modelo saturado (perfeito).

$$D = -2[\ln L_M(\hat{\beta}_M) - \ln L_T(\hat{\beta}_T)]$$

- **Desvio Reduzido (D^*):** Se $\phi = 1$ (Bernoulli, Poisson), o Desvio é chamado de "Residual Deviance" no R.
- Menores valores de Deviance indicam melhor ajustamento.
- **Desvio Nulo:** Compara o Modelo Nulo com o Saturado.

Critério de Akaike (AIC)

Utilizado para seleção de modelos (comparação entre modelos não encaixados).

$$AIC = -2\ln L_M + 2(p + 1)$$

Penaliza a complexidade do modelo (número de parâmetros). Quanto **menor** o AIC, melhor o modelo.

Testes de Significância

- **Teste de Wald:** Para coeficientes individuais $H_0 : \beta_j = 0$. Estatística $z \sim N(0, 1)$ ou χ^2 .
- **Teste da Razão de Verosimilhanças:** Compara a diferença de Deviances entre modelos encaixados. Sob H_0 , $\Delta D \sim \chi^2$.

Análise de Resíduos

Nos GLMs, existem diferentes definições de resíduos devido à ausência de erro aditivo simples.

Tipos de Resíduos

- **Resíduos de Pearson (RP_i):** Versão escalada da diferença bruta.

$$RP_i = \frac{Y_i - \hat{\mu}_i}{\sqrt{Var(\hat{\mu}_i)}}$$

- **Resíduos Deviance (RD_i):** Baseados na contribuição de cada observação para a Deviance total.

$$RD_i = \text{sign}(Y_i - \hat{\mu}_i) \sqrt{d_i}$$

Para modelo Bernoulli, envolve termos logarítmicos das probabilidades estimadas.

Recomenda-se o uso de resíduos standardizados (adimensionais) e preferencialmente os resíduos Deviance para diagnóstico gráfico.

Diagnóstico Gráfico

- **Resíduos vs. Valores Ajustados (transformados):** Curvaturas sugerem função de ligação errada.
- **Resíduos vs. Preditores:** Padrões indicam necessidade de transformação da variável X .
- **Resíduos vs. Ordem:** Deteta correlação serial (falta de independência).
- **Resíduos Absolutos vs. $\hat{\mu}$:** Banda horizontal deve ser constante; caso contrário, a função de variância foi mal escolhida.

Observações Influentes e Outliers

- **Leverage (Repercussão):** Medido pela diagonal da *Hat Matrix*.
- **Distância de Cook (D):** Mede a influência de uma observação no modelo todo.
- **Regra Prática:** Investigar pontos com $D > 4/n$.

Interpretação dos Coeficientes (Regressão Logística)

A interpretação baseia-se na razão de chances (*Odds Ratio* - OR).

$$\text{Odds} = \frac{p}{1-p} \Rightarrow \ln(\text{Odds}) = \beta_0 + \beta_1 X$$

Relação com β

- Coeficiente β_1 : Representa a variação no **log-odds** para um aumento unitário em X .
- Odds Ratio: $OR = \exp(\beta_1)$.

Interpretação Prática

- Se $\beta_1 > 0 \Rightarrow OR > 1$: A chance de sucesso aumenta.
- Se $\beta_1 < 0 \Rightarrow OR < 1$: A chance de sucesso diminui.
- **Variável Contínua:** Para cada aumento de 1 unidade em X , o risco (chance) multiplica-se por $\exp(\beta_1)$. Para aumento de k unidades, multiplica-se por $\exp(k\beta_1)$.
- **Variável Dicotômica/Categórica:** O OR compara a categoria de interesse com a categoria de referência (cujo $\beta = 0$).

$$OR = \frac{\text{Chance (Grupo 1)}}{\text{Chance (Grupo 0)}} = e^{\beta_{grupo1}}$$

3. Modelos de Previsão e Séries Temporais

A análise de séries temporais distingue-se da estatística clássica pela natureza dos dados. Enquanto a abordagem clássica assume frequentemente que as observações são independentes e identicamente distribuídas (i.i.d.), a análise temporal foca-se explicitamente na **interdependência** entre observações recolhidas sequencialmente.

Definição Geral: Uma série temporal (ou cronológica) é uma sequência de observações que evoluem no tempo, geralmente igualmente espaçadas, onde a ordem de recolha é fundamental.

Objetivos Principais:

- **Descrição:** Identificar a natureza do fenómeno e os seus padrões (tendência, sazonalidade).
- **Modelação:** Encontrar o modelo matemático que capte a estrutura de correlação (dependência entre observações vizinhas).
- **Previsão:** Estimar valores futuros com base no histórico.

Exemplos de Aplicação: Variáveis aleatórias quantitativas (univariadas ou multivariadas) tais como taxas de incidência de doenças, admissões hospitalares, concentrações de poluentes ou retornos financeiros.

Classificação de Fenómenos e Modelos

Os fenómenos estocásticos podem ser classificados quanto ao seu domínio em: temporais, espaciais ou espaço-temporais.

Tipos de Modelos Temporais

A escolha do modelo depende da natureza do espaço de estados e do espaço de índices (tempo):

1. Espaço de Estados Contínuo:

- Modelos lineares: SARIMA.
- Modelos não-lineares: ARCH e GARCH (comuns em finanças).
- Tempo contínuo: CAR (Continuous-time AutoRegressive), CARMA.

2. Espaço de Estados Discreto (Séries de Contagem):

- INAR (INteger AutoRegressive).
- DSINAR (Doubly Stochastic INAR).
- RCINAR (Random Coefficient INAR).

3. Equações Diferenciais Estocásticas (EDEs):

- Consideram o tempo contínuo (mais realista em muitos fenómenos naturais).
- Exemplos em epidemiologia: Modelos SIS e SIR.

Padrões em Séries Temporais

A análise visual (gráfica) é o primeiro passo para identificar componentes:

- **Estacionariedade:** A série varia em torno de uma média constante, com variabilidade constante. O comportamento é idêntico independentemente do período observado.
- **Tendência (Trend):** Evolução sistemática (crescente ou decrescente) da média ao longo do tempo. Indica não-estacionariedade.
- **Sazonalidade:** Padrão de repetição regular e previsível em intervalos fixos (períodos constantes).
- **Ciclicidade:** Flutuações (subidas e descidas) em torno da tendência, mas sem um período fixo (geralmente com duração superior a 2 anos). É crucial distinguir de sazonalidade.
- **Quebras Estruturais (Séries Interrompidas):** Alterações abruptas devido a eventos externos.

Definição Matemática de Processo Estocástico

Um Processo Estocástico (p.e.) é o modelo matemático que descreve a evolução de um sistema aleatório ao longo de um parâmetro (geralmente o tempo).

Seja $\mathcal{T}$ um conjunto de índices (espaço temporal) e $(\Omega, \mathcal{A}, P)$ um espaço de probabilidade. Um p.e. é uma aplicação $X : \mathcal{T} \times \Omega \rightarrow E$ (espaço de estados).

Interpretações Duplas:

- **Fixando o tempo t (X_t):** É uma variável aleatória sobre Ω .
- **Fixando o acaso ω (X_ω):** É uma trajetória ou realização do processo.

Nota: Uma série temporal observada é apenas **uma** única realização do processo estocástico gerador.

Estacionariedade

A estacionariedade é uma propriedade fundamental para a inferência estatística em séries temporais.

1. Estacionariedade Forte (Sentido Estrito)

Um p.e. $\{X_t\}$ é fortemente estacionário se a distribuição conjunta de qualquer vetor finito de variáveis é invariante no tempo.

$$F_{t_1, \dots, t_n}(x_1, \dots, x_n) = F_{t_1+k, \dots, t_n+k}(x_1, \dots, x_n)$$

Isto implica que todas as propriedades estatísticas são constantes no tempo.

2. Estacionariedade Fraca (Segunda Ordem)

Um p.e. é estacionário de segunda ordem (ou em covariância) se:

1. $E[X_t^2] < \infty$ (segundos momentos finitos).
2. $E[X_t] = \mu$ (Média constante).
3. $Var[X_t] = \sigma^2$ (Variância constante).
4. $Cov(X_t, X_{t+k}) = \gamma(|k|)$ (A covariância depende apenas do desfasamento/lag k , e não do tempo t).

Relação entre os tipos:

- Forte $\Rightarrow$ Fraca (se existirem segundos momentos).
- Fraca $\nRightarrow$ Forte (geralmente).
- **Exceção:** Num Processo Gaussiano, Estacionariedade Fraca implica Estacionariedade Forte (pois a distribuição Normal é totalmente definida pela média e covariância).

Processos Específicos

Ruído Branco (White Noise - WN)

Um processo $\{\epsilon_t\}$ é puramente aleatório ou ruído branco, denotado $\epsilon_t \sim WN(0, \sigma_\epsilon^2)$, se:

- Média nula: $E[\epsilon_t] = 0$.
- Variância constante: $Var[\epsilon_t] = \sigma_\epsilon^2$.
- Não correlacionado: $Cov(\epsilon_t, \epsilon_{t+k}) = 0$ para todo $k \neq 0$.

Passeio Aleatório (Random Walk)

Definido por $Z_t = Z_{t-1} + X_t$, onde X_t são i.i.d. (ruído).

$$Z_t = \sum_{i=0}^t X_i$$

Este processo **não é estacionário** (a variância cresce com o tempo).

Funções de Correlação

Estas funções quantificam a estrutura de dependência temporal.

Função de Autocovariância ($\gamma(k)$)

$$\gamma(k) = Cov(X_t, X_{t+k}) = E[(X_t - \mu)(X_{t+k} - \mu)]$$

Propriedades:

- $\gamma(0) = Var[X_t]$ (Variância do processo).
- $|\gamma(k)| \leq \gamma(0)$.
- É uma função par: $\gamma(k) = \gamma(-k)$.

Função de Autocorrelação (FAC ou ACF) - $\rho(k)$

Mede a correlação linear entre observações separadas por k instantes.

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}$$

Propriedades:

- $\rho(0) = 1$.
- $|\rho(k)| \leq 1$.
- É uma função par.

Função de Autocorrelação Parcial (FACP ou PACF) - $\phi(k, k)$

Mede a correlação entre X_t e X_{t+k} removendo a influência linear das variáveis intermédias ($X_{t+1}, \dots, X_{t+k-1}$). Pode ser interpretada como o coeficiente $\phi(k, k)$ na regressão linear múltipla de X_{t+k} sobre as k variáveis anteriores.

Ergodicidade

A ergodicidade permite deduzir as propriedades do processo estocástico (média do "ensemble") a partir de uma única série temporal (média temporal). Um processo é ergódico para a média se a média temporal converge para a média do processo quando $n \rightarrow \infty$. Uma condição suficiente é $\sum_{i=0}^{\infty} |\gamma(i)| < \infty$.

Estimação

Considerando uma amostra $(X_1, \dots, X_n)$:

Estimador da Média:

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{t=1}^n X_t$$

É um estimador centrado (não enviesado).

Estimador da Autocovariância: Existem dois estimadores usuais. O mais utilizado (preferido por ter menor erro quadrático médio, apesar de enviesado) é:

$$\hat{\gamma}(k) = \frac{1}{n} \sum_{t=1}^{n-k} (X_t - \bar{X})(X_{t+k} - \bar{X})$$

Nota: Usa-se o divisor n e não $n - k$ para garantir que a matriz de covariância seja definida não-negativa.

Estimador da Autocorrelação (ACF):

$$\hat{\rho}(k) = \frac{\hat{\gamma}(k)}{\hat{\gamma}(0)}$$

Resultados Assintóticos e Testes

Para um Ruído Branco (Gaussian White Noise), para n grande:

- $\hat{\rho}(k)$ tem distribuição aproximadamente Normal: $N(0, 1/n)$.
- Isto permite criar bandas de confiança (ex: $\pm 1.96/\sqrt{n}$) nos correlogramas para testar a significância das correlações. Se $\hat{\rho}(k)$ estiver dentro destas bandas, aceita-se a hipótese de que a correlação é nula.
- Analogamente, para a PACF, se o processo for ruído branco, $\hat{\phi}(k, k) \sim N(0, 1/n)$.

4. Modelação e Previsão de Séries Temporais (SARIMA)

Modelos Lineares Estacionários: Processos Auto-Regressivos (AR)

Um processo $\{X_t\}$ diz-se um processo auto-regressivo de ordem p , denotado por $AR(p)$, quando o valor atual é uma função linear dos p valores passados mais um termo de erro (ruído branco).

O Processo $AR(1)$

A equação fundamental é:

$$X_t = \mu + \phi X_{t-1} + \epsilon_t$$

Onde $\epsilon_t \sim WN(0, \sigma_\epsilon^2)$.

- **Condição de Estacionariedade:** $|\phi| < 1$. Se $|\phi| = 1$, temos um passeio aleatório (não estacionário).
- **Média:** $E[X_t] = \frac{\mu}{1-\phi}$. Se $\mu = 0$, a média é zero.
- **Variância:** $Var[X_t] = \frac{\sigma_\epsilon^2}{1-\phi^2}$.
- **FAC (Função de Autocorrelação):** Decresce exponencialmente (ou de forma sinusoidal amortecida) para zero: $\rho(k) = \phi^k$.
- **FACP (Função de Autocorrelação Parcial):** Apresenta um corte abrupto após o lag 1 ($\phi_{11} = \phi$ e $\phi_{kk} = 0$ para $k > 1$).

O Processo $AR(p)$

Generalização para p lags: $X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \epsilon_t$.

- **Identificação:** A FACP corta no lag p .

Processos de Médias Móveis (MA)

Um processo diz-se de Médias Móveis de ordem q , $MA(q)$, quando o valor atual depende linearmente do ruído branco atual e dos q ruídos passados.

O Processo $MA(1)$

Equação: $X_t = \mu + \epsilon_t + \theta \epsilon_{t-1}$.

- **Estacionariedade:** Um processo MA é sempre estacionário para qualquer valor de θ .
- **Invertibilidade:** $|\theta| < 1$. A invertibilidade permite expressar o ruído em função dos valores passados da série.
- **Média:** $E[X_t] = \mu$.
- **Variância:** $Var[X_t] = \sigma_\epsilon^2(1 + \theta^2)$.
- **FAC:** Apresenta um corte abrupto após o lag 1.
- **FACP:** Decresce exponencialmente para zero.

Modelos ARMA(p, q)

Combinam componentes auto-regressivas e de médias móveis:

$$\phi(B)X_t = \theta(B)\epsilon_t$$

Onde B é o operador de atraso ($BX_t = X_{t-1}$).

- **FAC:** Decréscimo exponencial a partir do lag $(q - p)$.
- **FACP:** Decréscimo exponencial a partir do lag $(p - q)$.

Modelos Não Estacionários: ARIMA(p, d, q)

Quando uma série apresenta tendência, não é estacionária na média. O modelo ARIMA utiliza **diferenciação** para tornar a série estacionária.

- **d:** Ordem de diferenciação necessária para estabilizar a média.
- Operador diferença: $\nabla X_t = X_t - X_{t-1} = (1 - B)X_t$.
- Se a série tem tendência linear, geralmente $d = 1$. Se tem tendência quadrática, $d = 2$.

Modelos Sazonais: SARIMA(p, d, q) $\times$ (P, D, Q)_s

Para séries com padrões repetitivos em períodos s (ex: $s = 12$ para meses), utilizam-se operadores sazonais.

- **Diferenciação Sazonal:** $\nabla_s X_t = X_t - X_{t-s}$. Ajuda a remover o padrão sazonal da média.
- **Parâmetros Sazonais (P, Q):** Captam a dependência entre observações separadas por múltiplos de s (ex: este Janeiro vs Janeiro do ano passado).

Metodologia de Box-Jenkins

O processo de modelação segue três etapas iterativas:

1. Identificação

- Estabilizar a variância (ex: transformação logarítmica se a variância cresce com a média).
- Estabilizar a média através de diferenciações (d e D).
- Analisar os correlogramas (FAC e FACP) da série estacionária para sugerir ordens p, q, P, Q .

2. Estimação e Diagnóstico

- Estimação dos parâmetros por Máxima Verosimilhança.
- **Significância:** Testar $H_0 : \beta_i = 0$ (Teste t ou Wald). Devem remover-se parâmetros não significativos ($p\text{-value} > 0.05$).
- **Análise de Resíduos:** Os resíduos devem comportar-se como **Ruído Branco**.
 - Teste de Ljung-Box: Testa se as autocorrelações dos resíduos são globalmente nulas.
 - Normalidade: Histogramas e testes de Shapiro-Wilk.

3. Seleção de Modelos

Comparação através de critérios de informação:

- **AIC (Akaike Information Criterion)** e **BIC (Bayesian Information Criterion)**.
- Prefere-se o modelo com o **menor** valor de AIC/BIC (princípio da parcimónia).

Previsão (Forecasting)

O objetivo final é prever X_{t+k} com base na informação até ao instante t .

CrITÉRIOS de Avaliação de Erro

Para comparar o desempenho de previsão entre modelos:

1. **RMSE (Root Mean Squared Error):** Raiz quadrada do erro quadrático médio.
2. **MAE (Mean Absolute Error):** Média dos erros em valor absoluto.
3. **MAPE (Mean Absolute Percentage Error):** Útil para comparar séries com escalas diferentes (em %).
4. **MaxAPE / MaxAE:** Erros percentuais ou absolutos máximos.

Intervalos de confiança para a previsão são construídos assumindo normalidade dos erros:

$$\hat{X}_t(k) \pm z_{1-\alpha/2} \sigma_e$$

5. Análise de Código

PARTE 1: Séries Temporais (ARIMA, SARIMA e Decomposição)

O objetivo desta secção é fornecer uma metodologia passo-a-passo para modelar dados que dependem do tempo, garantindo a sua estacionariedade e prevendo valores futuros com precisão.

1. Preparação e Visualização Inicial

Antes de iniciar qualquer modelação, é crucial entender a estrutura e o comportamento dos dados.

Comandos Essenciais e Interpretação

- `ts(dados, start=c(Ano, Mês), frequency=f)`: Transforma o conjunto de dados brutos num objeto de série temporal reconhecido pelo R.
 - **Frequência (f)**: Define a periodicidade dos dados. Use 12 para dados mensais, 4 para trimestrais e 1 para anuais.
- `ts_plot(dados.ts)`: Gera um gráfico interativo da série.
 - **Análise Visual**: Procure por tendências (crescimento ou decréscimo consistente) e padrões sazonais (repetições em intervalos fixos). A presença de qualquer um destes indica não-estacionariedade.
- `ts_seasonal(dados.ts, type="all")`: Decompõe a série para visualizar a sazonalidade.
 - **Interpretação**: Gráficos consistentes ao longo dos ciclos sugerem uma sazonalidade forte e estável. Variações irregulares podem indicar sazonalidade evolutiva.

2. Tratamento de Missings e Outliers

Dados incompletos ou anómalos podem enviesar significativamente as previsões.

Estratégias de Tratamento

- **Missings (Valores em Falta)**:
 - `ggplot_na_distribution()`: Visualiza onde estão os missings.
 - `na_interpolation(option="spline")`: Método preferencial para séries temporais suaves, pois preenche os vazios mantendo a curvatura natural da série.
- **Outliers (Valores Anómalos)**:
 - `tsoutliers()`: Identifica estatisticamente os pontos anómalos.
 - `tsclean()`: Substitui os outliers por valores interpolados e remove a sazonalidade para suavizar a série.
 - **Tratamento Manual**: Substituir valores problemáticos pela média dos períodos homólogos (ex: média do mesmo mês em anos adjacentes) é frequentemente mais robusto em séries com sazonalidade forte.

3. Estacionariedade e Diferenciação

A maioria dos modelos clássicos, como o ARIMA, exige que a série seja estacionária, ou seja, que a sua média e variância sejam constantes ao longo do tempo.

Testes e Transformações

- **Teste ADF (`adf.test`):** Verifica a presença de raízes unitárias.
 - **H0:** A série não é estacionária.
 - **Decisão:** Se $p < 0.05$, rejeita-se H0 e assume-se que a série é estacionária. Caso contrário, é necessária diferenciação.
- **Função `ndiffs`:** Indica o número de diferenciações simples (**d**) necessárias para remover a tendência. Se o resultado for > 0 , aplique `diff()`.
- **Função `nsdiffs`:** Indica se é necessária diferenciação sazonal (**D**) para remover padrões cíclicos.
- **Transformação Box-Cox (`BoxCox.lambda`):** Estabiliza a variância.
 - Se o valor de lambda (λ) for próximo de 0, uma transformação logarítmica é recomendada.
 - Se $\lambda \approx 1$, a transformação não é necessária.

4. Identificação do Modelo (ACF e PACF)

A análise dos correlogramas é fundamental para determinar as ordens p, d, q e P, D, Q do modelo SARIMA.

Regras de Bolso

- **ACF (Autocorrelação):**
 - Decaimento lento: Indica não-estacionariedade (necessidade de diferenciação).
 - Corte abrupto após o lag q : Sugere um componente de Médias Móveis de ordem q ($MA(q)$).
 - Picos significativos nos lags múltiplos da frequência ($s, 2s, \dots$): Sugere um componente sazonal $MA(SMA(Q))$.
- **PACF (Autocorrelação Parcial):**
 - Corte abrupto após o lag p : Sugere um componente Auto-Regressivo de ordem p ($AR(p)$).
 - Picos significativos nos lags múltiplos da frequência: Sugere um componente sazonal $AR(SAR(P))$.

5. Ajuste e Diagnóstico do Modelo

Após identificar os parâmetros candidatos, ajusta-se o modelo e verifica-se a sua validade.

Diagnóstico de Resíduos

Um bom modelo deve deixar resíduos que se comportem como Ruído Branco (aleatórios, não correlacionados, média zero e variância constante).

- **Significância dos Coeficientes (confint):** Verifique se os intervalos de confiança dos parâmetros não incluem o zero. Se incluírem, o parâmetro não é significativo e deve ser removido (fixado em 0).
- **Teste Ljung-Box (checkresiduals):** Testa a autocorrelação global dos resíduos.
 - **H0:** Os resíduos são independentes (Ruído Branco).
 - **Objetivo:** Queremos $p > 0.05$ para não rejeitar a aleatoriedade dos resíduos. Se $p < 0.05$, o modelo ainda tem estrutura por explicar.
- **Normalidade (shapiro.test, lillie.test):** Verifica se os resíduos seguem uma distribuição normal. Embora desejável, a falta de normalidade é menos crítica se a amostra for grande, mas afeta a precisão dos intervalos de previsão.
- **Média Nula (t.test):** Garante que o modelo não é enviesado. Queremos $p > 0.05$.

6. Seleção e Previsão

- **Critérios de Informação (AIC/BIC):** Entre modelos válidos (que passaram nos testes de resíduos), escolher aquele com o **menor AIC** ou BIC. O AIC penaliza a complexidade do modelo, favorecendo a parcimónia.
- **Exatidão (accuracy):** Métricas como o MAPE (Mean Absolute Percentage Error) indicam a magnitude média do erro em percentagem. Um MAPE baixo sugere um modelo com boa capacidade preditiva.
- **Previsão (forecast):** Gera valores futuros com intervalos de confiança. Gráficos onde a linha de previsão segue a tendência histórica e os intervalos de confiança se alargam razoavelmente indicam uma previsão saudável.

PARTE 2: Modelos de Contagem (GLM)

Esta secção foca-se na modelação de variáveis resposta que representam contagens (números inteiros não negativos), onde a regressão linear clássica não é adequada.

1. Escolha da Distribuição (Poisson vs. Outras)

O ponto de partida é quase sempre a distribuição de Poisson, que assume uma propriedade restritiva: *Media = Variância*.

Verificação de Pressupostos

- **Razão de Dispersão:** Calcule $Var(Y)/Mean(Y)$. Se esta razão for significativamente maior que 1 (ex: > 1.5), há indícios de **Sobredispersão**.
- **Comparação Gráfica:** Plot do histograma dos dados observados contra a distribuição teórica de Poisson ajuda a visualizar discrepâncias, especialmente no número de zeros ou na cauda da distribuição.
- **Teste Formal (dispersiontest):**
 - **H0:** Equidispersão (Poisson é adequado).
 - **Decisão:** Se $p < 0.05$, rejeita-se a Poisson devido a sobredispersão.
 - **Solução:** Se rejeitado, deve-se optar por modelos que acomodem variância extra, como `family=quasipoisson` ou a distribuição Binomial Negativa (`glm.nb`).

2. Modelação e Seleção de Variáveis

O processo de construção do modelo envolve seleccionar as variáveis explicativas que realmente influenciam a contagem.

Método Backward Elimination

- Iniciar com um modelo saturado (todas as variáveis).
- Analisar os **P-values no Summary**: Se $p > 0.05$, a variável não é estatisticamente significativa.
- Remover a variável menos significativa e reajustar o modelo. Repetir até que todas as variáveis remanescentes tenham $p < 0.05$.
- **Deviance Residual**: No final, comparar a Deviance Residual com os graus de liberdade. Se forem valores próximos, o ajuste é razoável.

3. Diagnóstico Avançado (Pacote DHARMA)

Os resíduos em GLMs não são normais, dificultando o diagnóstico padrão. O pacote DHARMA resolve isto simulando resíduos padronizados.

Interpretação dos Testes DHARMA

- **KS Test (Kolmogorov-Smirnov):** Testa a uniformidade dos resíduos. Queremos $p > 0.05$ para confirmar que o modelo está bem especificado.
- **Dispersion Test:** Verifica novamente a dispersão nos resíduos simulados. Queremos $p > 0.05$.
- **Outlier Test:** Deteta se há mais observações extremas do que o esperado pelo modelo. Queremos $p > 0.05$.
- **QQ-Plot:** Os pontos devem alinhar-se aproximadamente na diagonal. Desvios sistemáticos (curvas em S ou afastamentos nas pontas) indicam má especificação da distribuição ou da função de ligação.

4. Identificação de Pontos Influentes

- **Distância de Cook:** Mede o impacto de remover uma observação individual no modelo.
- **Regra Prática:** Valores com distância de Cook superior a $4/n$ (onde n é o tamanho da amostra) são considerados influentes. Estes pontos devem ser investigados pois podem estar a distorcer os coeficientes.

5. Interpretação dos Resultados

A interpretação correta é crucial em GLMs devido à função de ligação logarítmica.

Interpretação dos Coeficientes (β)

- Os coeficientes brutos representam a mudança no *log* da contagem. Para interpretação prática, devem ser exponenciados.
- **IRR (Incidence Rate Ratio) = $\exp(\beta)$:** Representa o fator multiplicativo na contagem esperada.
 - Se $\exp(\beta) = 1.08$: "Por cada unidade adicional na variável X, a contagem esperada aumenta em 8%, mantendo as outras variáveis constantes."
 - Se $\exp(\beta) = 0.90$: "Por cada unidade adicional na variável X, a contagem esperada diminui em 10% ($1 - 0.90$)."
- **Deviance Explicada:** $R_{GLM}^2 = (D_{null} - D_{residual})/D_{null}$. Fornece uma medida semelhante ao R^2 , indicando a percentagem da variabilidade dos dados explicada pelo modelo.

6. Previsão

Ao prever com GLMs, deve-se ter atenção à escala da resposta.

- `predict(..., type="link")`: Retorna a previsão na escala linear (logaritmo da contagem).
- `predict(..., type="response")`: Retorna a previsão na escala original (número esperado de contagens). É esta a escala interpretável.

- **Intervalos de Confiança:** Devem ser calculados na escala do link ($\eta \pm 1.96 \times SE$) e depois transformados para a escala de resposta usando a exponencial, para garantir que os limites sejam sempre positivos (como as contagens).

Matéria Essencial Resumida

1 Processos Estocásticos

1.1 Definição e Conceitos Básicos

Um processo estocástico é uma coleção de variáveis aleatórias $\{X_t, t \in T\}$, onde T é um conjunto de índices (geralmente o tempo).

- **Espaço de Estados (S):** Conjunto de valores possíveis que a variável X_t pode assumir.
- **Estacionaridade:** Um processo é estritamente estacionário se a distribuição conjunta de $(X_{t_1}, \dots, X_{t_k})$ é a mesma que a de $(X_{t_1+h}, \dots, X_{t_k+h})$.
- **Estacionaridade Fraca (ou de 2ª ordem):**
 1. A média é constante: $E[X_t] = \mu$.
 2. A variância é finita e constante.
 3. A autocovariância depende apenas do desfasamento (lag) h : $Cov(X_t, X_{t+h}) = \gamma(h)$.

2 Séries Temporais (AR, MA, ARMA, ARIMA, SARIMA)

2.1 Componentes e Estacionaridade

Para modelar uma série temporal com modelos ARMA, a série deve ser estacionária.

- **Tendência:** Comportamento de longo prazo (crescente/decrescente). Deve ser removida (diferenciação d).
- **Sazonalidade:** Padrões que se repetem em intervalos fixos s .
- **Variância não constante:** Requer transformação (ex: logarítmica ou Box-Cox).

2.2 Modelos ARMA e ARIMA

2.2.1 AR(p) - Auto-Regressivo de ordem p

O valor atual depende dos p valores passados.

$$X_t = c + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \epsilon_t$$

Identificação (ACF/PACF):

- **ACF:** Decai exponencialmente ou em senoide amortecida.
- **PACF:** Corta (torna-se zero) após o lag p .

2.2.2 MA(q) - Média Móvel de ordem q

O valor atual depende dos q erros passados.

$$X_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}$$

Identificação (ACF/PACF):

- **ACF:** Corta (torna-se zero) após o lag q .
- **PACF:** Decai exponencialmente ou em senoide amortecida.

2.2.3 ARIMA(p, d, q)

Inclui diferenciação (d) para tornar a série estacionária.

- p : Ordem AR.
- d : Número de diferenciações (diferenças simples).
- q : Ordem MA.

2.3 SARIMA(p, d, q) $\times$ (P, D, Q) $_s$

Modelo para séries com sazonalidade de período s .

- P, D, Q : Ordens AR, Diferenciação e MA na parte sazonal.
- A análise da ACF/PACF deve ser feita nos lags múltiplos de s (ex: 12, 24, 36 para dados mensais).

2.4 Diagnóstico de Resíduos

Para o modelo ser válido, os resíduos (ϵ_t) devem ser ruído branco:

- Média zero e variância constante.
- **Não correlacionados:** Verificar ACF dos resíduos.
- **Teste de Ljung-Box:** H_0 : Os resíduos são independentes. (Queremos p-value > 0.05).
- **Normalidade:** Verificar QQ-Plot ou teste Shapiro-Wilk.

3 Modelos Lineares Generalizados (GLM)

Os GLMs estendem a regressão linear para respostas que não seguem a distribuição Normal.

$$g(E[Y]) = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k$$

onde $g(\cdot)$ é a função de ligação (*link function*).

3.1 Regressão de Poisson (Contagens)

Usada para dados de contagem (números inteiros não negativos).

- **Distribuição:** $Y \sim \text{Poisson}(\lambda)$.
- **Função de Ligação:** Logarítmica ($\ln(\lambda) = X\beta$).
- **Interpretação dos Coeficientes (β):**
 - Calcular a razão das taxas de incidência: $\text{IRR} = \exp(\beta)$.
 - Se $\exp(\beta) = 1.08$: "Um aumento de 1 unidade em X aumenta a contagem esperada em 8%".
 - Se $\exp(\beta) = 0.95$: "Um aumento de 1 unidade em X diminui a contagem esperada em 5%".
- **Sobredispersão:** Se $\text{Var}(Y) > E[Y]$, o modelo Poisson padrão subestima os erros padrão. Usar *Quasi-Poisson* ou *Binomial Negativa*.

3.2 Regressão Binomial / Logística (Binária)

Usada quando a resposta é binária (0 ou 1, Sucesso ou Fracasso).

- **Distribuição:** $Y \sim \text{Binomial}(n, p)$.
- **Função de Ligação:** Logit ($\ln(\frac{p}{1-p}) = X\beta$).
- **Interpretação dos Coeficientes:**
 - $\exp(\beta)$ representa o **Odds Ratio (OR)**.
 - Se $\exp(\beta) > 1$: A probabilidade de sucesso aumenta com X.
 - Se $\exp(\beta) < 1$: A probabilidade de sucesso diminui com X.

3.3 Avaliação e Previsão

3.3.1 Deviance e AIC

- **Null Deviance:** Ajuste de um modelo apenas com a constante (intercepto).
- **Residual Deviance:** Ajuste do modelo proposto. Quanto menor, melhor.
- **AIC:** Usado para comparar modelos (penaliza complexidade). Menor AIC é preferível.

3.3.2 Comandos em R

```
# Modelo Poisson
modelo_pois <- glm(contagem ~ x1 + x2, family = poisson, data = dados)

# Modelo Logístico (Binomial)
modelo_bin <- glm(sucesso ~ x1 + x2, family = binomial, data = dados)

# Previsão (escala da resposta original)
pred <- predict(modelo_pois, type = "response")
```