

Resumo TAD 2

Processos Fundamentais de PLN e Análise de Dados

Transformação e Análise de Dados

Os processos iniciais no PLN, essenciais na fase de **Transformação e Análise de Dados**, incluem:

- **Tipos de dados**, aquisição e avaliação de dados.
- Detecção e tratamento de **valores em falta** e **Outliers**.
- **Discretização**, controle de variáveis e normalização.
- **Balanceamento de dados**.

O PLN trabalha com uma vasta gama de **dados linguísticos**, como bulas de remédio, SMS, *tweets*, instruções de uso, fala, traduções (oral ou escrita), diálogos, obras literárias, frases isoladas, títulos, palavras ou expressões isoladas.

Dificuldades Centrais

A principal dificuldade no tratamento de dados linguísticos é a **ambiguidade**, que se manifesta em palavras, frases e sentenças (exemplos: ora/hora, manga/manga). Para processar um objeto da língua, é crucial conhecer:

- Os **princípios da sua constituição interna**.
- Os **fenômenos translinguísticos**.
- A **descrição sistemática da língua** (léxicos, gramáticas, tesouros, ontologias, etc.).

O tratamento da língua exige **Recursos e Ferramentas** que abordam Fonética, Fonologia, Prosódia, Morfologia, Sintaxe, Semântica, Pragmática e Discurso.

Normalização Linguística e Técnicas Clássicas

Normalização e Segmentação

- **Normalização Linguística:** Envolve a conversão para minúsculas, remoção opcional de acentos, expansão de contrações, tratamento de pontuação e **tokenização adequada ao português**.
- **Sentence Splitting:** A segmentação correta é crucial para o *parsing*, enfrentando desafios como **abreviações, datas e siglas**, e geralmente combina regras e heurísticas.
- **Stopwords:** Devem ser removidas em tarefas de **classificação**, mas mantidas em **parsing e Extração de Informação (IE)**.

Morfologia e Léxico

- **Stemming vs. Lematização:** **Stemming** é rápido e agressivo. **Lematização** é linguística e precisa, retornando a forma-base da palavra (exemplo: *lançou* → *lançar*).
- **Morfologia:** Estuda prefixo, sufixo, raiz, vogal temática e tema. Línguas como Ganda utilizam **prefixos inflexionais** (ex.: *omu* para singular e *aba* para plural). Outras, como Ilocano e Tagalog, mostram diferentes métodos de flexão e formação de tempos verbais.

- **Léxico:** É uma base de dados lexicais. Contém **itens lexicais** (palavras individuais ou agrupamentos com sentido individual, ex.: *lua de mel*, *grosso modo*) e **entradas lexicais** (detalhando as categorias e sentidos, ex.: a como artigo, preposição ou substantivo).
- **Organização do Léxico:** Pode ser por **formas** (*processo*, *processos*) ou por **bases** (*processar*, *transformar*).

Análise Sintática e Semântica

- **N-grams e Modelos de Frequência:** (Unigramas, bigramas, trigramas) são a base histórica para correção automática, sumarização e previsão.
- **Parsing Sintático:** Essencial para identificar **sujeito**, **objeto** e **modificadores**, crucial para IE, QA e sumarização. Modelos podem ser baseados em constituintes ou dependências.
- **Ambiguidade Linguística:** Divide-se em ambiguidade **lexical**, **sintática** e **referencial**.
- **Semântica Computacional:** Utiliza recursos como **WordNet**, **VerbNet** e **FrameNet**, focando em papéis temáticos (agente, paciente), mas com inferência lógica limitada.
- **Thesaurus e Recursos Lexicais:** (Sinónimos, antónimos, hipónimos, hiperónimos) são usados para expansão semântica e desambiguação, complementando ontologias (ex.: WordNet, TeP 2.0).

Extração de Informação (IE) e Avaliação

Contexto e Tarefas de IE

A IE tem como objetivo **retirar informação semântica do texto**, transformando **informação não estruturada em estruturada** para armazenamento em bases de dados. As tarefas principais de IE (Jurafsky & Martin) são:

- **Reconhecimento de Entidades Nomeadas (NER).**
- Detecção e classificação de **relações**.
- Processamento **temporal** e de **eventos**.
- **Preenchimento de um template.**

A **Resolução de Referências** é uma etapa relacionada, visando ligar pronomes e expressões referenciais às entidades corretas.

Recursos Especializados e Avaliação

- **Recursos Específicos:** Existem ontologias de domínio como a **Gene Ontology (GO)** (para padronização de genes) e **GENIA Ontology** (área biomédica), além do **UMLS** (Metatesauro, unifica vocabulários controlados usando CUIs e grafos).
- **Construção de Corpora:** Envolve coleta estruturada, limpeza e deduplicação, **anotação manual/assistida**, divisão (treino/validação/teste) e documentação.
- **Avaliação em PLN:** Deve ser feita por tarefa e domínio, utilizando métricas padrão: **Precision**, **Recall**, **F1**, *Coverage* e *accuracy*.

Desafios do Português

O português é desafiador devido à **flexão rica**, **contrações complexas**, **escassez de grandes datasets** e **ambiguidade pronominal**.

A Mudança de Paradigma: LLMs

Transição e Aceleração

- **Mudança de Paradigma:** Modelos tradicionais exigiam **pipelines longos e frágeis** (limpeza, léxico, regras, modelos estatísticos). Os **LLMs** (Large Language Models) introduzem **inteligência contextual integrada**, reduzindo complexidade e acelerando o desenvolvimento e a iteratividade.
- **LLMs como Aceleradores:** Geram menos dependência de *features* manuais e permitem prototipação rápida, aumentando a produtividade e reduzindo o custo e as etapas.
- **Evolução, Não Ruptura:** A transição tecnológica é uma **evolução**. Pipelines **híbridos** (regras + LLM) continuam úteis e a migração gradual é recomendada.

Estratégias e Fundamentos

- **Resolução de Problemas com LLMs:** Envolve definir objetivo/métrica, preparar dados e criar exemplos para abordagens *Zero-shot*, *Few-shot* ou *Fine-tuning*.
- **Estratégias LLM:** *Prompt design*, contexto estruturado e **Recuperação com RAG** (*Retrieval-Augmented Generation*).
- **Hibridização:** Combinação de regras determinísticas com LLM, uso de ***fallback* determinístico e validação estrutural**.
- **Importância dos Fundamentos:** Os LLMs não eliminam a linguística. O conhecimento dos fundamentos é vital para **diagnosticar erros** e garantir avaliação e controles adequados (ex.: Testes adversariais, A/B testing).

Ficha de Atividade: Resolução de Problemas Linguísticos

1. Análise de Ambiguidade (Relevante em Contexto de Avaliação)

A atividade foca na identificação de ambiguidade sintática e referencial, demonstrando a necessidade de conhecimento linguístico para o processamento. **Exemplo base:** "A menina viu o menino com o telescópio."

- **Interpretação 1 (Sintática):** O instrumento (o telescópio) pertence ao menino. (*com o telescópio modifica o menino.*)
- **Interpretação 2 (Sintática):** O instrumento (o telescópio) foi usado pela menina para ver o menino. (*com o telescópio modifica o verbo viu, sendo um adjunto adverbial de instrumento.*)

Análise de Frases da Ficha de Trabalho (Exemplos):

a. O homem observou a mulher no parque.

- **Interpretação 1:** O parque é o local onde o homem estava no momento da observação.
- **Interpretação 2:** O parque é o local onde a mulher estava sendo observada.

b. O polícia perseguiu o suspeito na moto.

- **Interpretação 1:** O polícia estava na moto enquanto perseguia o suspeito.
- **Interpretação 2:** O suspeito estava na moto sendo perseguido pelo polícia.

e. O João disse ao Pedro que ele precisava melhorar.

- **Interpretação 1 (Referencial):** O pronome *ele* refere-se a João. (João precisava melhorar.)
- **Interpretação 2 (Referencial):** O pronome *ele* refere-se a Pedro. (Pedro precisava melhorar.)

2. Pipeline de PLN Clássico (Tokenização e POS Tagging NLTK)

A tarefa exige a implementação de um pipeline simples, sem LLMs, utilizando exclusivamente **NLTK** para demonstrar a abordagem clássica de processamento linguístico, que depende de modelos treinados (*taggers* baseados em *corpora* como Floresta). **Etapas do Pipeline:**

1. **Função de Tokenização:** Utiliza `nltk.word_tokenize` para dividir a frase em *tokens* (palavras, pontuação).
2. **Etiquetagem Morfossintática (POS Tagging):** Atribuição da **categoria gramatical** (POS tag) a cada *token* utilizando um modelo *tagger* para português carregado.
3. **Saída:** Geração de uma lista de tuplos no formato `[(token, pos_tag), (...)]`.

Este exercício prático ilustra a fragilidade e a especificidade do *tagging* clássico, que está limitado pelo modelo de treino e pelo vocabulário do *tagger*.

3. Aplicação de LLMs em PLN

Esta atividade foca em aplicar LLMs (como o ChatGPT) para:

- **Reconhecer e analisar fenômenos linguísticos** (como as ambiguidades).
- Explorar **técnicas de PLN clássicas e modernas** (normalização, tokenização, *stemming*, lematização, criação de *corpus* estruturado).
- **Comparar a eficácia** das abordagens tradicionais vs. LLMs.
- Refletir sobre **limitações, riscos e boas práticas** dos LLMs.

A diferença de abordagem reside na capacidade do LLM de integrar o *parsing*, a lematização e a análise de ambiguidade em um único *prompt*, contrastando com o pipeline sequencial e baseado em regras/modelos estatísticos da abordagem clássica.

Processos Fundamentais de PLN e Análise de Dados

Transformação e Análise de Dados

A fase inicial do PLN abrange a **Transformação e Análise de Dados**, envolvendo diversos processos cruciais:

- **Tipos de dados**, aquisição e avaliação de dados.
- Detecção e tratamento de **valores em falta** e **Outliers**.
- **Discretização**, controle de variáveis e normalização.
- **Balanceamento de dados**.

O PLN lida com uma ampla variedade de dados linguísticos, como bulas de remédio, SMS, *tweets*, instruções, diálogos e obras literárias.

Dificuldades e Recursos Linguísticos

A dificuldade central no PLN é a **ambiguidade** (lexical, sintática e referencial). Para tratar a língua, são necessários recursos e ferramentas que abordam: Fonética, Fonologia, Prosódia, **Morfologia**, **Sintaxe**, **Semântica**, Pragmática e Discurso. É fundamental conhecer os princípios da constituição interna da língua, os fenômenos translinguísticos e a sua descrição sistemática (léxicos, gramáticas, tesouros, ontologias).

Ontologias e Representação de Conhecimento

Conceito e Arquitetura Lógica

- **Definição:** Uma ontologia é um **sistema formal baseado em lógica**, constituindo um artefato computacional **executável**.
- **Semântica:** Possui **semântica *model-theoretic***, o que significa que as interpretações possíveis devem satisfazer os axiomas definidos.
- **Raciocínio Automático:** Permite *reasoning* (raciocínio automático), incluindo **Subsumption** (A é subconjunto de B), **Consistency checking** e **Satisfatibilidade de classes**.
- **Arquitetura Lógica:**
 - **TBox** (*Terminological Box*): Vocabulário conceptual (classes e propriedades). Em PLN, **orienta a extração**.
 - **ABox** (*Assertional Box*): Instâncias ou factos, que são **automaticamente extraídos e povoados por PLN**.
 - **RBox** (*Rules Box*): Regras e restrições complexas.

Distinção e Aplicação em PLN

- **Ontologias vs. Recursos Lexicais:** Ontologias definem **relações formais, restrições, axiomas e inferência**. Recursos como Thesaurus focam em relações linguísticas (sinónimos, antónimos) e Taxonomias focam em estrutura hierárquica simples (*é-um*).
- **Uso em PLN:** Fornecem **base semântica** para desambiguação e interpretação contextual. São essenciais para **Information Extraction** e fornecem o *schema* para **grafos de conhecimento**.
- **Controlo de Qualidade:** A ontologia atua como camada de interpretação e **controlo de qualidade semântica**. O NER identifica entidades, e a ontologia **caracteriza e valida** as categorias (ex.: valida se a relação *assina*(Pessoa → Documento) é válida, sinalizando inconsistência se fosse *contrato assinou pessoa*).

Integração e Benefícios

A ontologia suporta diversos processos do PLN:

- **Normalização:** Mapeia variantes lexicais para o mesmo conceito ontológico.
- **Stemming/Lematização:** Facilita a ligação entre o verbo captado e o predicado ontológico.
- **POS Tagging:** Ajuda a identificar padrões sintáticos que correspondem a relações.

Benefícios: Reduz ambiguidades e inconsistências, facilita a integração de dados e **aumenta a explicabilidade** dos modelos.

Desafios e Relação com LLMs

- **Dificuldades na Construção:** Ambiguidade conceptual, conflitos entre especialistas, custo de manutenção e baixa adoção.
- **Ontologias vs. LLMs:** LLMs têm **alta cobertura** mas são propensos a **erros semânticos** (alucinações). Ontologias têm **baixa cobertura** mas **alta precisão semântica**.
- **Conclusão:** Ontologias são vitais para **estruturar dados**, alimentar *Knowledge Graphs*, garantir **consistência semântica** e permitir a **explicabilidade**, complementando os LLMs.

Técnicas Clássicas e o Paradigma LLM

Normalização e Processamento Morfológico

- **Normalização:** Inclui conversão para minúsculas, tratamento de pontuação e **tokenização coerente com o idioma**.
- **Stemming vs. Lematização:** Stemming é agressivo e pode gerar raízes inválidas. A **Lematização** é a forma-base ideal para **tarefas semânticas** por ser linguisticamente informada (ex.: "estudantes" → "estudante"; "estudar" → "estudar").
- **Stopwords:** Devem ser removidas na **classificação**, mas mantidas no *parsing* e **IE**.

Extração de Informação (IE)

IE transforma informação não estruturada em estruturada. Tarefas incluem **NER**, detecção de relações, processamento de eventos/temporal e preenchimento de *templates*. O pipeline exige **POS Tagging** e **Parsing Sintático** para identificar estruturas gramaticais.

O Novo Paradigma e Hibridização

- **Transição:** LLMs reduzem a complexidade dos **pipelines clássicos frágeis** (regras, léxico, estatística), fornecendo **inteligência contextual** e acelerando a prototipagem.
- **Estratégias LLM:** *Prompt design*, contexto estruturado e **RAG**.
- **Hibridização:** A combinação de regras determinísticas (para validade estrutural e *fallback*) com LLMs ainda é útil.

Resoluções da Ficha de Trabalho (Tópicos Relevantes para Avaliação)

Atividade 2: Análise de Ambiguidades (Exemplo: "O diretor viu o funcionário com os binóculos.")

Esta atividade demonstra a necessidade de desambiguação no PLN.

- **Ambiguidade Sintática:** Ocorre devido ao **attachment ambíguo** do sintagma preposicional "com os binóculos".
 - **Interpretação 1:** "com os binóculos" modifica o verbo "viu". Os binóculos são o **instrumento** utilizado pelo diretor para realizar a ação de ver.
 - **Interpretação 2:** "com os binóculos" modifica o sintagma nominal "o funcionário". Os binóculos estão em **posse** do funcionário (que foi visto).
- **Tratamento Clássico:** Um pipeline clássico tentaria lidar com a ambiguidade via **Parsing Sintático** (modelos estatísticos de *attachment*) e **Semântica Computacional** (aplicando FrameNet ou VerbNet para verificar os papéis temáticos do verbo "ver").
- **Estratégia LLM:** O LLM usa **raciocínio contextual** e seu vasto conhecimento estatístico para ponderar as interpretações e indicar a mais plausível com base na frequência de uso ou no contexto fornecido no *prompt*.

Atividade 3: Stemming, Lematização e Morfologia

Aplica-se às palavras "estudantes", "estudar", "estudioso", "estudo", "estudantil":

- **Stemming (Exemplos de Raiz Agressiva):** Geralmente resulta em uma raiz comum como *estud* ou *estudent*. As **perdas** causadas pelo stemming incluem a perda de informação morfológica e a distinção entre classes gramaticais (e.g., substantivo, verbo, adjetivo).
- **Lematização (Resultados Ideais):**
 - Estudantes → estudante (ou estudar)
 - Estudar → estudar (forma infinitiva)
 - Estudioso → estudioso (forma adjetival canónica)
 - Estudo → estudo (forma nominal)
 - Estudantil → estudantil
- **Forma-base Ideal para Tarefas Semânticas:** A **Lematização** é preferível, pois retorna a forma canónica (dicionário), mantendo a integridade da classe gramatical e o sentido, essencial para tarefas onde a semântica é prioritária.

Atividade 4: Corpus Orientado por Domínio (Estrutura)

Esta atividade exige a aplicação das tarefas de IE e PLN para estruturar dados. **Estrutura de Saída JSON (Modelo Conceptual):** O objetivo é criar uma estrutura baseada em triplas que alimenta um *Knowledge Graph* (KG) ou ABox de uma Ontologia.

```
[ { "frase": "O João investiu dinheiro em ações da Tesla.", "pos_tagging": [ "O/ART", "João/NPROPR", "
```

Esta estrutura ilustra o uso de **POS tagging** (clássico), **NER** (entidades) e a **Extração de Relações** (triplas), sendo o formato JSON o meio para transformar informação não estruturada em informação estruturada.

Atividade 7: Pipelines Híbridos (Exemplo: "A diretora analisou o relatório da empresa com atenção.")

Compara a abordagem determinística com a contextual.

- **Ambiguidade Sintática:** "da empresa" e "com atenção". A ambiguidade principal é o *attachment* de "da empresa" (relatório que pertence à empresa, ou análise feita sobre a empresa).
- **Abordagem A (Regras/Determinística):** Foca estritamente na sintaxe. Por exemplo, uma regra pode definir que um adjunto preposicional ("da empresa") tende a se ligar ao SN mais próximo ("relatório"). A abordagem é explícita em cada passo.
- **Abordagem B (LLM/Contextual):** O LLM utiliza raciocínio e probabilidade contextual.

- **Interpretação 1 (Plausível):** A diretora analisou o relatório que pertence à empresa, usando a atenção como forma de análise. (Atenção modifica o verbo 'analisou'.)
- **Interpretação 2 (Menos Plausível):** A diretora analisou o relatório da empresa, e a empresa opera com atenção. (Reinterpretação da posse ou modificação do SN.)
- **Conclusão da Comparação:** O LLM acerta ao resolver a ambiguidade implicitamente usando contexto, mas pode **exagerar ou inventar** (alucinar) o contexto ou a interpretação. Em situações reais que exigem **alta precisão e rastreabilidade** (e.g., validação de consistência financeira, segurança de sistemas), a confiança é maior nos **modelos tradicionais** ou em sistemas híbridos ancorados em **ontologias**, pois estas garantem **validade estrutural e lógica** que o LLM não garante.

Processos Fundamentais de PLN e Análise de Dados

Transformação e Análise de Dados

A fase inicial do PLN, referente à **Transformação e Análise de Dados**, engloba:

- **Tipos de dados**, aquisição e avaliação de dados (ex.: bulas de remédio, tweets, fala, obras literárias).
- Tratamento de **valores em falta** e **Outliers**.
- **Discretização**, controle de variáveis e normalização, e **balanceamento de dados**.

A dificuldade central do PLN é a **ambiguidade** (lexical, sintática e referencial). O tratamento da língua requer o conhecimento dos princípios de sua constituição interna, dos fenômenos translinguísticos e da descrição sistemática (léxicos, gramáticas, ontologias).

Normalização e Técnicas Clássicas

- **Normalização Linguística**: Conversão para minúsculas, tratamento de pontuação, expansão de contrações e **tokenização adequada ao idioma**.
- **Segmentação (*Sentence Splitting*)**: Crucial para o *parsing*, enfrentando desafios como abreviações, datas e siglas, e requerendo regras e heurísticas.
- **Stopwords**: Devem ser removidas em **classificação**, mas mantidas no *parsing* e **Extração de Informação (IE)**.
- **Stemming vs. Lematização**: Stemming é agressivo. A **Lematização** (redução à forma-base canônica) é a forma ideal para **tarefas semânticas**.
- **Análise Sintática: Parsing** (constituintes ou dependências) é essencial para identificar sujeito, objeto e modificadores, sendo base para IE e QA.

Léxico: Base de dados com **itens lexicais** (palavras ou agrupamentos com sentido, ex.: "lua de mel") e **entradas lexicais** (categorias/sentidos), que pode ser organizado por formas ou bases.

Extração de Informação (IE) e Avaliação

Tarefas e Aplicação da IE

IE transforma informação não estruturada em estruturada. As tarefas principais são: **Reconhecimento de Entidades Nomeadas (NER)**, detecção de relações, processamento temporal/eventos e preenchimento de *templates*.

Avaliação e Desafios

A avaliação utiliza métricas como **Precision**, **Recall**, **F1**, *Coverage* e *accuracy*. Os desafios do português incluem **flexão rica**, **contrações complexas**, **escassez de datasets** e **ambiguidade pronominal**.

Modelagem de Ontologias e Grafos de Conhecimento (KGs)

Definição e Arquitetura Lógica

Ontologias são sistemas formais baseados em lógica, com **semântica *model-theoretic*** e são **artefatos computacionais executáveis** que permitem **raciocínio automático** (subsumption, verificação de consistência).

- **TBox (*Terminological Box*)**: Vocabulário conceptual (classes e propriedades); **orienta a extração**.
- **ABox (*Assertional Box*)**: Instâncias/Fatos; **populada automaticamente pelo PLN**.
- **RBox (*Rules Box*)**: Regras e restrições complexas.

Ficha 08: Modelagem e Teste de Inferência em Protégé

Este exercício prático ilustra a construção simbólica para controle semântico.

1. Definição de Classes:

- **Pessoa:** Indivíduos que podem assinar ou contratar serviços.
- **Empresa:** Organizações que oferecem ou executam serviços.
- **Contrato:** Documento formal que estabelece vínculos.
- **Serviço:** Atividade prestada.

2. Relações (ObjectProperties):

- `assina(Pessoa → Contrato)`
- `fornece(Empresa → Serviço)`
- `contrata(Pessoa → Serviço)`

3. Axiomas de Subclasses e Domínio/Imagem:

- $\text{Pessoa} \sqsubseteq \text{Agente}$
- $\text{Contrato} \sqsubseteq \text{Documento}$

4. **Teste de Inferência:** Utilizar o *reasoner* (motor de inferência) para verificar a validade semântica e inconsistências. Exemplo de inconsistência: “**Contrato assinou João Silva**” (o *reasoner* sinaliza erro, pois a relação *assina* só aceita *Pessoa* como domínio, não *Contrato*).

Reflexão sobre Ontologias

A ontologia ajuda a **reduzir ambiguidades linguísticas** (ao forçar um único significado conceptual), **integrar dados textuais** de fontes diversas (via mapeamento para um *schema* unificado) e **aumentar a explicabilidade** dos resultados de PLN.

LLMs e Hibridização Neuro-Simbólica

Paradigmas e Desafios dos LLMs

- **Transição:** LLMs fornecem **inteligência contextual** e reduzem a dependência de *features* manuais, acelerando a prototipação.
- **Desvantagens:** LLMs têm conhecimento "congelado" e são propensos a **alucinações** e falta de conhecimento específico de domínio, o que afeta a performance.
- **Hibridização:** É a combinação de abordagens **neuro-simbólicas**. Utiliza LLMs (neuro) para tarefas de superfície (geração, sumarização) e sistemas simbólicos (ontologias, KGs) para **validade estrutural e raciocínio**.

Integração KG + LLM (Atividade Guiada 2)

A integração de KGs e Ontologias com LLMs é crucial para mitigar alucinações e aumentar a precisão semântica.

- **OG-RAG (*Ontology-Grounded RAG*):** É um método que ancora o processo de recuperação (RAG) em ontologias específicas de domínio, garantindo que o contexto recuperado seja semanticamente consistente, aumentando a precisão e a verificabilidade.
- **KG-Enhanced LLMs:** Os KGs estruturam o conhecimento e **mitigam alucinações**. LLMs podem ser aprimorados através de **Injeção de Conhecimento** (fatos do KG no *prompt*) ou ensinados a **atravessar o grafo** para raciocínio (*Knowledge Solver*).
- **LLM-Enhanced KGs:** LLMs ajudam na **construção automática** de KGs, extraindo entidades e relações e facilitando o mapeamento de ontologias.

- **Abordagens Conjuntas (*Joint*):** Modelos como *ERNIE* e *CokeBERT* fundem *embeddings* textuais (LLM) e de conhecimento (KG) para uma representação unificada, visando maior precisão.
- **Análise Crítica (Requisitos da Atividade):** O estudo de artigos (como o de Atribuição de Revisores) exige a análise da **Arquitetura** (ex.: RAG ontológico, extração *ontology-driven*), das **Técnicas de PLN** (extração, *linking*, *embeddings*) e do **Papel da Ontologia/KG** (estruturar, enriquecer, corrigir o LLM).

Ficha de Atividade: Análise Prática (Tópicos de Avaliação)

1. Análise de Ambiguidade (Sintática e Referencial)

A resolução da ambiguidade demonstra a diferença entre as abordagens clássica (dependente de *parsing* e regras de *attachment*) e LLM (dependente de contexto e probabilidade estatística). **Exemplo: "A menina viu o menino com o telescópio."**

- **Interpretação 1 (Instrumento):** O adjunto "com o telescópio" modifica o verbo "viu". (A menina usou o telescópio.)
- **Interpretação 2 (Posse):** O adjunto "com o telescópio" modifica o sintagma nominal "o menino". (O menino estava com o telescópio.)

Exemplo Referencial: "O João disse ao Pedro que ele precisava melhorar." O pronome "ele" pode referir-se a João ou a Pedro.

2. Pipeline de PLN Clássico (Tokenização e POS Tagging)

Demonstra a natureza sequencial e frágil dos sistemas pré-LLM, utilizando ferramentas como NLTK para gerar tuplas (*token*, *pos_tag*). A precisão é limitada pelo *tagger* e pelo *corpus* de treino.

3. Aplicação de LLMs em PLN (Comparação)

Enfatiza o uso de LLMs para **normalização**, **tokenização**, **stemming**, **lematização** e **análise de ambiguidade** em um único passo (*prompt*). O exercício prático de estruturar um mini-corpus em JSON (com POS tagging, entidades e triplas de relação) ilustra como o LLM pode automatizar tarefas de **IE** para posterior população de uma **ABox**.

4. Modelagem de Ontologia (Protégé)

(Ver seção 3.2 - Essencialmente, este exercício é a aplicação prática do raciocínio simbólico).

5. Desafios e Aplicações em Sistemas Inteligentes

Aplicações práticas: Uso de ontologias e KGs em **Recomendação** (filtragem de conteúdo, ligando preferências de utilizador a conceitos ontológicos), **Busca Semântica** (além da palavra-chave) e **QA avançada**. A combinação de LLMs e KGs é a chave para sistemas que requerem **alta precisão** e **explicabilidade**, uma vez que os KGs fornecem **caminhos de raciocínio** verificáveis que os LLMs puros não oferecem.