



Transformação e análise de dados – Trabalho Prático

Grupos:

- O trabalho é realizado individualmente ou em grupos de 2 alunos.

Enunciado

- Ver secção seguinte.

Entrega

- Os trabalhos serão entregues através do upload de um ficheiro `tad-XXXXX-YYYYY.zip` (onde `xxxxx` e `yyyyy` são os números de aluno no grupo), no Moodle.
- Deve entregar o(s) ficheiro(s) com o código fonte, um **relatório** (.pdf; máximo de 6 páginas) com a identificação do grupo e descrição do trabalho realizado, as opções tomadas sobre os dados e implementação assim como um balanço sobre a aprendizagem ou o eventual motivo para alguma parte do trabalho não ter sido implementada e um **video/captura de tela*** com tempo entre 8 e 12 minutos).

Prazo

- Ver Moodle.



Enunciado

Desenvolva um programa em Python para transformar e analisar dados de países relacionados com indicadores socioeconómicos de inflação, esperança de vida, mortalidade infantil, população, PIB, IDH e outros que julgar relevantes.

O programa deve processar dados brutos que apresentam desafios reais:

- formatos distintos (CSV, JSON, TXT),
- inconsistências,
- valores em falta,
- variações semânticas entre fontes,
- necessidade de integração multi-fonte.

O seu programa ser capaz de tratar as seguintes questões:

1. Coleta

Para a construção do *dataset*, deve-se realizar a coleta de dados disponíveis online e de fontes oficiais como ONU, Banco Mundial (BM) e OCDE, e institutos nacionais de estatística, como o INE em Portugal, o IBGE Países, que agregam dados sobre Economia, Sociedade, População, Saúde e Meio Ambiente para comparação global.

2. Extração

- Deve criar um módulo dedicado para:
- Ler dados CSV, JSON e TXT manualmente
- Validar a qualidade dos dados: tipos, faixas válidas, totais incoerentes, duplicados, codificação.
- Criar estruturas de dados internas adequadas (listas, dicionários, tuplos).

3. Transformação

Deve incluir:

- Integração multi-fonte: juntar indicadores provenientes de CSV + JSON.
- Limpeza e enriquecimento (ex.: tratamento de valores em falta).
- Criação de novas variáveis (ex.: taxa de envelhecimento, ratio PIB/população, score socioeconómico composto).
- Normalização de indicadores para comparabilidade.
- Registo das transformações (log simples em texto).



4. Análise Descritiva e Exploratória

Deve responder a perguntas essenciais, incluindo as inspiradas no enunciado original, mas agora expandidas:

4.1 Qual o país com:

- maior esperança de vida,
- menor mortalidade infantil,
- maior inflação média anual (últimos 10 anos),
- melhor score socioeconómico composto.

4.2 Quais países se encontram dentro de um intervalo de inflação [a, b].

4.3 Criar listas e séries ordenadas:

- países por mortalidade infantil (decrecente),
- países por inflação (crescente),
- países por variação demográfica.

4.4 Criar gráficos com matplotlib ou outra biblioteca para apresentar as informações acima.

Informações adicionais:

1. Vídeo:

O vídeo deve funcionar como uma demonstração do projeto desenvolvido. Deve incluir:

1.1 Explicação da Solução

breve contextualização do problema e dos dados;

visão geral da arquitetura criada (pipeline ETL + análise + modelo preditivo);

justificativa das decisões metodológicas adotadas;

explicação sobre processamento, integração e transformação dos dados.



1.2 Demonstração Técnica

- Execução real do pipeline, mostrando:
 - Extração dos diferentes formatos de ficheiros;
 - Transformação e limpeza;
 - Geração das séries e indicadores;
 - Visualizações criadas;
- Demonstração do código em funcionamento, apresentando outputs importantes.

1.3 Insights e Decisões

- apresentação clara dos resultados encontrados;
- interpretação dos indicadores mais relevantes;
- identificação de padrões, anomalias, riscos e oportunidades;
- recomendações estratégicas fundamentadas nos dados.

2. Recursos complementares

Poderá ser fornecido pelo professor, dados em formato csv, json, etc.

3. **Orientações adicionais**, caso necessárias, serão enviadas aos estudantes pelo respetivo fórum da disciplina.