



UNIVERSIDADE
DE ÉVORA

Transformação e Análise de Dados

Extração, Transformação e Carregamento de Dados Abertos
Económicos e Sociais

Jorge Couto

58656

Miguel Grilo

58387

Cadeira lecionada por Daniela Schmidt

Introdução

No âmbito da cadeira de Transformação e Análise de Dados, lecionada por Daniela Schmidt, foi-nos requisitado um projeto de extração, transformação e carregamento de dados económicos, sociais e demográficos mundiais. Não nos foram dadas fontes de dados, de modo a nos familiarizar com o trabalho usual de cientista de dados, tendo que procurar pelas próprias fontes de dados. Para além do processo ETL e da análise exploratória, realizamos também um modelo preditivo de regressão linear para predição do índice de HDI com base nos parâmetros obtidos ao longo do trabalho. Neste relatório explicamos o motivo por detrás de todos os nossos procedimentos ao longo do trabalho, para além de qualquer decisão influenciada pelo uso de Inteligência Artificial Generativa.

Extração

Procurando criar uma base de dados versátil e robusta, decidimos procurar diversas fontes de dados diferentes, juntando-as sobre um único *dataframe* unificado. Procurámos bases de dados de diferentes tipos, visando demonstrar tratamento cuidadoso dos dados com diferentes tipos de ficheiros de origem, e inclusive priorizamos a diversidade à completude, ignorando certas features de uma base de dados se as pudessemos extrair de outra base de dados. Por haver uma infinidade de ficheiros de dados económico-sociais trabalháveis, todos de diferentes origens, usamos recurso à Inteligência Artificial Generativa, para que nos auxiliasse na busca de ficheiros de dados apropriados para o tema em questão, de diferentes tipos e que requerissem pré-processamento cuidadoso. Embora procurássemos trabalhar com um ficheiro *excel* (.xlsx), *json* (.json) e de texto (.txt), acabámos por utilizar uma *api*, dois ficheiros *excel* e um ficheiro *json*. O motivo para tal deve-se à nossa incapacidade de encontrar um ficheiro de dados em formato de texto que julgássemos apropriado para a investigação em questão, com quaisquer ficheiros de texto encontrados já tendo dados que substituiriam outros ficheiros que já tínhamos connosco. Ademais, decidimos utilizar dois ficheiros *excel* porque, embora ambos do mesmo tipo, cada um requeria diferentes filosofias de preparação, estando, em um deles, os dados distribuídos de forma longa em uma única folha, sem metadados, enquanto o outro apresentava um grande volume de metadados para além de dados distribuídos de forma longa em várias folhas, uma para cada feature. Portanto, precisamos de ajustar o nosso método de leitura de dados para cada ficheiro. Também, por utilizarmos uma *api*, tornou-se necessária a sua instalação *à priori* da extração dos dados.

Os ficheiros de dados utilizado foram obtidos do *Human Development Reports* (1), *Stockholm International Peace Research Institute* (2), e do *Our World in Data* (3). A *api* utilizada foi a *wbgapi*, que permite obter dados do *World Bank*.

As bibliotecas usadas foram o *Pandas* (*dataframes* e processamento dos dados), *Numpy* (operações matemáticas), *wbgapi* (dados do banco mundial), *matplotlib*, *seaborn* (criação de gráficos), *re* (usada para limpeza de um dos ficheiros de dados), *json* (usado para leitura dos dados no formato *json*) e alguns componentes de *scikit-learn* (para standardização e modelagem).

Começando a explicar o código, decidimos importar, primeiramente, os dados do Banco Mundial. Apesar de ter diversas features, optamos pela simplicidade, importando apenas as features do PIB per capita, o PIB bruto em US\$, Inflação Anual, Esperança de Vida, Mortalidade Infantil e Emissões de CO2. Uma vez que procuraríamos analisar valores ao longo do tempo, definimos o período a ser removido como os anos entre 2014 a 2023, de modo a termos uma distribuição de 10 anos recentes. Não incluímos o ano de 2024 na nossa extração pela maioria dos dados desse ano serem, ainda, omissos, o que mesmo com tratamento de valores omissos traria grande ruído à nossa análise. Contudo, notámos, para além de colunas agregadas que removemos, que os dados apresentavam-se em um formato largo. O formato largo é usual no armazenamento

de dados, sendo cada ano representado por uma coluna separada. Isso, contudo, oferece uma complexidade acrescida no nosso *dataframe*. Antes de continuarmos alteramos o formato dos dados, usando o *melt()* para tornar todas as colunas começadas por “YR” em uma única feature, a qual modificamos para ser um valor inteiro com nome *Year*. Depois, uma vez que os indicadores no *World Bank* apresentam nomes de difícil interpretação, alteramos esses nomes para aqueles que definimos. Finalmente, fixando as *features* indicadoras, utilizamos o comando *pivot_table()* para dar uma coluna diferente a cada indicador.

Depois, passamos para a leitura do nosso ficheiro *.xlsx* “simples”. A sua leitura foi direta, precisando apenas do comando *read_excel()*. Contudo, uma vez que também estava em formato largo, precisamos de, depois, transformar o *dataframe* de forma similar ao anterior. Antes disso, no entanto, selecionamos as colunas de HDI e GII, as únicas colunas explicativas que decidimos importar do ficheiro de dados. Embora fosse uma fonte de dados completa, julgámos várias das features como redundantes ou não tão interessantes para a nossa análise. Com estes dados também precisamos de filtrar os anos entre 2014 e 2023, uma vez que os dados possuíam o ano de 2013 também. Antes de passarmos à leitura do próximo ficheiro de dados, decidimos juntar todos os dados em um único *dataframe* global, que seria aquele onde unificaríamos todos os dados. Para isso, fixamos a coluna *economy* e *Year*, que utilizamos como chaves de junção. Optamos por importar também o nome do país, pois embora já o tivéssemos na base de dados, quisemos corrigir quaisquer modificações ao analisar, para o mesmo código ISO3, os nomes dos países, corrigindo-os para o mesmo nome caso fossem diferentes. Esse procedimento foi realizado em uma revisão do código, uma vez que percebemos que poderíamos perder informação com essa junção.

Foi, então, que lemos o nosso ficheiro *.xlsx* “complexo”. Para além de estar em um formato largo, cada feature tinha a sua própria folha *Excel*, e cada folha apresentava uma quantidade diferente de metadados que precisavam de ser limpos para a extração. Criamos uma função para a leitura automática dos dados, definindo o nome da folha para permitir a leitura apenas de algumas folhas seletas, e não definindo header para permitir ao código “saltar” os metadados, procurando logo a partir de que linha começar o cabeçalho para, aí sim, ler corretamente os dados. Dentro da função decidimos aplicar logo as transformações necessárias habituais, entre elas a mudança do formato, de largo para longo, a remoção de sub-regiões e, também, a limpeza de caracteres especiais (onde usamos a biblioteca *re*). Os nossos dados apresentam vários símbolos diferentes nos nomes dos países e nas linhas dos dados, tornando-se necessária a sua limpeza para garantir que o código não falhasse na leitura de muitos dos nossos dados. Usando a função, que já aplicava tudo de uma só vez, a leitura dos dados tornou-se trivial, e podemos logo unificá-los na nossa base de dados. Optamos por ler apenas as variáveis que mais julgamos interessantes, no caso o gasto militar em percentagem do PIB e o gasto militar per capita. Vale-se notar que mesmo depois de junção tivemos que fazer algum processamento, uma vez que precisamos de remover linhas agregadas, como continentes inteiros ou regiões de continentes. É importante notar que, para este ficheiro de dados, não utilizamos a técnica da igualdade de nomes, uma vez que ele não possui a identificação ISO3 de cada país, apenas o nome. Embora pudessemos verificar, país por país, se o nome é igual ou diferente ao da nossa base de dados unida, acreditamos que esse trabalho não seria rentável, uma vez que as chances de, em distração ou cansaço, deixarmos alguma diferença escapar seriam altas. Tentámos implementar uma automatização de verificação de igualdade dos nomes, verificando linha a linha. Contudo, não tivemos êxito, uma vez que cada base de dados possui diferentes países (nomeadamente o *World Bank*, muito mais completo que as outras bases de dados), tornando o processo de automatização difícil...

Finalmente, passamos para a leitura do ficheiro *json*. Utilizando a biblioteca do mesmo nome, lemos o ficheiro de dados, guardando-os em uma variável de dados brutos. Percorremos os dados brutos, verificando, na chave ‘data’, o intervalo de tempo que procuramos estudar (entre 2014 e 2023). Para esse intervalo de tempo, adicionamos o código do país e o nome à linha, guardando tudo em uma lista de dicionários. Convertendo essa lista de dicionários em um *dataframe*, precisamos apenas de selecionar as variáveis que mais nos interessavam e renomear algumas das colunas para a junção fácil, antes de unir as

bases de dados, finalizando a nossa extração.

Transformação

Embora já tivéssemos realizado alguma transformação para a união dos dataframes, foi aqui que tratamos dos problemas fundamentais dos dados, no caso os outliers e valores omissos. Com auxílio de Inteligência Artificial Generativa achamos correto começar pelo tratamento dos Outliers, uma vez que na nossa limpeza de valores iríamos preencher quaisquer valores nulos, então assim reduziríamos ruído. Criamos um boxplot para cada coluna explicativa, verificando os outliers, e notámos como apenas duas variáveis (HDI e GII) não tinham outliers. A esperança de vida tinha, também, pouquíssimos outliers, embora os seus outliers fossem extremos e ilógicos (como um país com uma esperança de vida de 19 anos). Para o tratamento de outliers da esperança de vida definimos um “teto mínimo” de 45 anos, um valor que obtivemos por investigação da esperança de vida usual nos países menos desenvolvidos nos anos atuais (geralmente descendo até ao valor dos 50 anos, mas dificilmente abaixando dos 50. Decidimos, ainda assim, definir um teto mínimo de 45). Depois, verificamos, para todos os valores, se algum deles era inferior aos 45 anos definidos. Se fosse, o outlier seria tornado em valor omissos, sendo resolvido no futuro, com a nossa função (ainda a ser definida) de tratamento de valores omissos.

Ao longo do tratamento dos outliers surgiu-nos a dúvida sobre se os outliers, embora demasiados, deveriam ser tratados. Afinal, embora pudessem ser valores extremos, valores reais entre eles poderiam mostrar variância importante e valores pertinentes para estudo. Por isso, recorremos ao auxílio de Inteligência Artificial Generativa, que recomendou à transformação logaritmica de variáveis numéricas não percentuais (e que não fossem taxas, também). Contudo, optamos por usar uma transformação logaritmica de $(1+x)$, para garantir que não haveriam problemas no caso da existência de valores iguais a 0 ou negativos. Também, ao invés de substituímos as variáveis transformadas, optamos por criar uma nova coluna para cada transformação, no caso de ainda ser pertinente a observação do valor original.

Para o tratamento de outliers das taxas e variáveis percentuais utilizamos a técnica de capping. Isso é, definimos um limite, e qualquer valor ultrapassando esse limite seria reduzido para o próprio limite. Decidimos usar um valor de 99% (quantil de 0.99), uma vez que testamos 95% mas achamos que o capping era demasiado severo. Também, para esta técnica não criamos nossas colunas, ao invés disso substituindo, sim, a variável original pelos novos valores.

Depois, procedemos ao tratamento de valores omissos. Para a observação de valores omissos verificamos, para cada país (com 10 entradas no total, uma para cada ano de 2014 a 2023) quantos valores omissos haviam, criando gráficos para mostrar. A nossa ideia para o tratamento dos valores omissos deveu-se no preenchimento de valores omissos pela média dessa coluna. Contudo, uma vez que a média geral ofereceria uma variância imensa, decidimos definir a média como a média do próprio país: Caso o país tivesse pelo menos um valor não omissos na coluna em questão, a substituição seria pela média do próprio país. Caso o país não tivesse nenhum valor omissos, a média seria por agrupamento de vários países. O agrupamento que decidimos foi realizado com base na variável *incomeLevel* (nível de rendimento) do país, permitindo que países ricos não gerassem valores omissos para países pobres e vice-versa, de modo a tentar reduzir variância.

Com essa função, conseguimos limpar quaisquer valores omissos, terminando a limpeza inicial. Quisemos, então, criar uma variável para o nível de HDI, de modo a categorizar cada país como tendo um HDI baixo, mediano, alto ou muito alto. Para essa variável utilizamos a técnica do *Equal Width*, lecionada em aula. Utilizamos quatro quantis para cada categoria.

Depois, tornamos o *incomeLevel*, que surgia como sendo do tipo *object*, em uma variável do tipo *category*.

No final da nossa transformação, criamos outra coluna, desta vez contínua, para o Score Socioeconómico Composto. Embora a sua definição costume variar de fonte para fonte, compreendemos que é consenso geral que o Score Socioeconómico Composto é a avaliação geral do país em nota contínua, de 0 a 1. Portanto, definimos o score socioeconómico composto como uma média, entre 0 e 1, de todas as nossas *features* contínuas. Utilizamos as variáveis transformadas para o cálculo do Score, e para garantir que nenhuma variável tinha precedência sobre as outras por diferenças nas escalas estandardizamos. Utilizamos o *MinMaxScaler* para definir a escala entre “0” e “1”, criando um dataframe separado para os valores ajustados (afinal, não queríamos esses valores no nosso dataframe original), onde ficariam as colunas a ser usadas, agora escaladas. Antes da criação da coluna do score, invertemos também a escala de algumas das *features*, nomeadamente o GII, a Mortalidade Infantil, a Inflação Anual e o Ghg per Capita. O motivo por detrás dessa inversão deve-se à natureza lógica de cada uma das variáveis, onde um valor superior é inerentemente pior. Por exemplo, o GII é o índice que representa a disparidade social em cada sexo, e quanto maior o valor maior essa disparidade, enquanto o Ghg per Capita define quantos gases de efeito de estufa são libertos por ano. Vale-se notar que esta definição não é absoluta, pois de acordo com algumas fontes o gasto militar maior é inerentemente pior para um país, pois menos dinheiro acaba sendo gasto na saúde e educação, e o Energy per Capita também, pois mais energia implicaria, também, mais energias fósseis. Contudo, acreditamos que um gasto militar maior representa uma maior força de defesa, aumentando a proteção geral do país (resultando em maior segurança), e o Energy per Capita representa o consumo de energia geral, não apenas de energias fósseis mas também de energias renováveis e nucleares. Enfim, com a escala invertida calculamos o Score Socioeconómico Composto pela média de todas as *features*, colocando-o no nosso dataframe original. Com isso, demos por encerrada a transformação, passando para a Análise Exploratória

Análise Exploratória

A análise exploratória foi breve e relativamente simples. Limitamo-nos a responder às questões dadas pela Professora no Enunciado do trabalho para além de algumas questões que nos surgiram. Em questões como “qual o país com maior..” ou “qual o país com menor..”, limitamo-nos a responder qual era o país que teve o maior (ou menor) valor histórico nos 10 anos do nosso dataframe, a não ser que explicita a média, em qual caso compararíamos todas as médias para verificar a maior. A lógica tornou-se, portanto, semelhante à lógica de SQL. Para questões intervalares definimos os intervalos pelos quantis, verificando a lista de países e valores (por cada ano) dentro desse intervalo, e para ordenação utilizamos o *ascending*, inicialmente agrupando todos os países com base na média e, depois, ordenando ou ascendente para os menores valores ou descendente para os maiores valores. Uma vez que a questão da Análise Exploratória é direta, e maior parte das questões têm natureza semelhante, acreditamos que não seja boa prática explicitar cada célula de código individual, por questões de limite de espaço neste relatório.

Modelagem

Embora inicialmente acreditando que modelagem não seria necessária, notamos como, no enunciado, era pedido para explicar o nosso pipeline, incluindo um modelo preditivo, no vídeo gravado. Portanto, para garantir, optamos por construir um modelo de regressão linear para prever o valor de HDI com base nas demais variáveis (salvo as variáveis categóricas, que teriam que ser tornadas contínuas, e as derivadas, nomeadamente o score socioeconómico composto). Definimos todas essas variáveis como as colunas de X, e definimos também o “HDI” como a coluna Y. Dividimos os nossos dados em conjunto de treino e teste usando uma divisão 75%/25%, e permitindo randomização na escolha das linhas para treino e teste. Então, inicializamos o modelo de RLM e treinamo-lo com os dados de treino. Com o modelo treinado, fizemos predições no conjunto de teste, avaliando a qualidade do modelo com recurso ao R quadrado, que representa quanta variância de Y é explicada por X, porcentualmente. O ajuste é ótimo, sendo 95.54% da variância do HDI explicada. Avaliando a significância de cada coeficiente do modelo, notamos como o gasto militar em

porcentagem do PIB é altamente importante na explicação do HDI, sendo inversamente proporcional ao HDI, e o GII também. As demais variáveis possuem uma significância de 3% ou inferior, chegando a Inflação Anual mesmo ao 0.024% apenas. Com gráficos de dispersão verificamos o ajuste do modelo de forma gráfica. Concluimos, assim, que o modelo estava bem ajustado para os dados, uma vez que a reta seguia fielmente a distribuição dos resíduos, e os resíduos seguiam uma distribuição aproximadamente normal. Assim, demos por encerrado o nosso trabalho.

Conclusão

Este trabalho permitiu-nos compreender, de forma prática, os procedimentos ETL por detrás da ciência de dados. Conseguimos notar grande dificuldade, em específico, na extração dos dados, precisando de auxílio de Inteligência Artificial Generativa na procura dos dados por uma enorme acessibilidade a centenas de conjuntos de dados diferentes. Esperamos que, depois de experienciarmos diretamente a transformação bruta de dados, estejamos preparados para um cenário de trabalho real, com dados voláteis de diversas fontes e volumes, precisando todos de limpeza e transformação adequada e delicada.

É importante avisar que não colocamos logs convencionais no nosso trabalho. Ao invés de adicionarmos um output em print a explicar o que foi feito, adicionámos em comentário o que cada transformação representava e o que cada célula fazia. Também não criamos muitos gráficos na análise exploratória, uma vez que as questões, a nosso ver, eram representáveis sem recurso a gráfico. Contudo, utilizamos gráficos em questões relativas a valores omissos, outliers e na análise dos resíduos da modelagem.

Fontes

- (1) <https://hdr.undp.org/data-center/documentation-and-downloads>
- (2) <https://www.sipri.org/databases/milex>
- (3) <https://github.com/owid/co2-data>