

# Ameaças Sintéticas:

## A Eficácia de LLMs na Evasão de Filtros de Phishing

---

Miguel Grilo I58387, Tiago Palaio I62276, João Santos I62472

Universidade de Évora | Introdução à Investigação (2026)

# | Porquê a Seleção Deste Tema?

-  **Atualidade e Urgência (2025/2026):** A ascensão rápida dos LLMs alterou radicalmente as táticas dos ataques digitais, tornando obsoletas muitas das medidas de segurança tradicionais em menos de 24 meses.
-  **Modelos de Treino Desatualizados:** O paradigma atual de engenharia social foca-se em ensinar os utilizadores a detetar "erros ortográficos". A IA cria prosa perfeita, neutralizando a capacidade da deteção humana.
-  **Assimetria e Escala de Ataque:** A automação com IA diminuiu imenso o custo de criar e-mails altamente personalizados (Spear-Phishing), permitindo ataques cirúrgicos à escala global de mensagens spam.

# O que são LLMs e o Cenário de Ameaça

## Definição Técnica e Funcionamento

Modelos de Inteligência Artificial treinados em volumes gigantescos de dados textuais. Utilizam arquiteturas de **Deep Learning** para prever e criar o texto mais provável e convincente num determinado contexto.

⚙️ Por exemplo: **Gemini, Claude**.

## Good vs Evil:

O artigo destaca que as medidas éticas das ferramentas públicas (como o Gemini) são frequentemente contornadas, mas o verdadeiro perigo reside nos **LLMs Dedicados**:

- 🐛 **WormGPT e Modelos Modificados:** Ferramentas criadas especificamente para ataques maliciosos e onde foram removidas todas as restrições éticas.
- ✂️ **Baits Perfeitos:** Capacidade de copiar, com grande nível de rigor, o tom corporativo, criando e-mails de phishing sem qualquer "red flag" tradicional.

# Engenharia Social e Phishing: O Fator Humano



**Engenharia Social:** A arte de manipular pessoas para que executem ações voluntárias (como clicar em links ou ceder credenciais), explorando gatilhos psicológicos como a "autoridade", a "urgência" ou a "curiosidade".

**Phishing:** O vetor mais comum da engenharia social. Baseia-se no envio de comunicações fraudulentas em massa que imitam marcas ou instituições legítimas.

## 🔗 A Conexão com o Artigo

O nosso estudo foca-se no **Spear-Phishing** (ataques feitos à medida dirigidos a alvos específicos, como o ambiente universitário/institucional).

*"Ao usar IA, os atacantes contornam os sinais clássicos de alerta do Phishing tradicional, maximizando a eficácia da Engenharia Social sem aumentar o esforço humano."*

# Contexto: O Novo Panorama da Ameaça

## Escala e Automação

A acessibilidade dos **Large Language Models (LLMs)** permite a criação de conteúdo malicioso com uma facilidade sem precedentes, reduzindo drasticamente a resistência à infiltração de atacantes.

## Engenharia Social 2.0

A IA não só automatiza como refina o processo de ataque. Mensagens personalizadas e convincentes são criadas em massa, eliminando os erros ortográficos e o tom contextual que antes denunciavam ataques.

# | A Revolução na Economia do Ataque

16h

TEMPO HUMANO  
(TRADICIONAL)

5min

TEMPO VIA IA  
GENERATIVA

94%

AUMENTO DOS ATAQUES EM 2024  
VS 2023

*"A automatização reduz os custos laborais, permitindo ataques sofisticados a custos de spam genérico."*

---

# Metodologia Experimental

Avaliação empírica estruturada da resiliência dos filtros contemporâneos face a ameaças sintéticas de nova geração.

---

# | Resultados Detalhados de Evasão

| Identificador              | Tipologia / Origem        | Destino Final    | Status           |
|----------------------------|---------------------------|------------------|------------------|
| Mail 1-7; 9-20             | Humano (Tradicional) / IA | Caixa de Entrada | Sucesso (Evasão) |
| Mail 8                     | Humano (Tradicional)      | Lixo Eletrônico  | Bloqueado        |
| Taxa Global de Evasão: 95% |                           |                  |                  |

\*O Mail 8 apresentava desvios gramaticais evidentes, acionando as heurísticas convencionais.



# A Eficácia Absoluta da IA Generativa



■ Mail gerado por IA: 100% Evasão

■ Mail escrito por humano: 75% Evasão

---

*A IA neutraliza os filtros ao adotar um tom neutro, gramática impecável e formalidade institucional.*

# | Conclusões e Caminho Futuro

- ⚠ **Filtros Obsoletos:** Heurísticas baseadas em "red flags" (erros ortográficos, urgência extrema) são agora ineficazes.
- 🛡 **Defesas Híbridas:** Necessidade urgente de transição para modelos que integrem análise comportamental profunda.
- 🧠 **IA vs IA:** Apenas mecanismos de triagem realizadas pela própria IA podem realizar averiguação semântica em tempo real.
- 🎓 **Literacia Digital:** O paradigma de "procurar erros" para detetar phishing está ultrapassado.

# Questões e Discussão

Obrigado pela vossa atenção.

**Artigo:** Ameaças Sintéticas: A Eficácia de LLMs na Evasão de Filtros de Phishing

Introdução à Investigação | Universidade de Évora | 2026