

Home

Introdução

Gestão &
Engenharia de
Dados

Fundamentação
Matemática &
Metodológica

Diálogo &
Gestão
Multi-turno

Conclusão

Assistente de Pesquisa Inteligente para E-Commerce

IMPACT Commerce

José Barbosa
Cristina Silva

Miguel Grilo | 58387
Licenciatura em IACD


UC Laboratório de IACD
Universidade de Évora

A Evolução do E-Commerce

Transição de Paradigma: Fim da limitação a componentes estáticos (grelhas de produtos e filtros de navegação rígidos).

Novas Interfaces: Exigência de interfaces de pesquisa intuitivas que simulem a experiência fluida e personalizada de uma loja física.

O Desafio Tecnológico: Apesar dos avanços da IA generativa, a compreensão profunda e imediata da linguagem natural do utilizador continua a ser um obstáculo no comércio digital.




Disparidade Semântica e Limitações do Modelo Convencional

A Falha da Pesquisa Exata: Os motores baseados em palavras-chave falham perante intenções subjetivas ou ambíguas.

Exemplo Prático: A *query* "quero algo casual para o verão" não encontra correspondência direta nas *tags* de uma base de dados rígida.

A Solução Adotada (NLP): Integração de técnicas avançadas de Processamento de Linguagem Natural numa arquitetura modular em camadas (Api, Application e Custom) utilizando a infraestrutura da *Azure Cloud*.



Preparação de Dados: O Catálogo

Base de Dados Realista: Utilização de um catálogo simulado com dados, estruturas e árvores de metadados modelo.

Sensibilidade Linguística: Catálogo totalmente focado no mercado Português (PT-PT), garantindo que o assistente compreende as nuances linguísticas locais.

Engenharia de Estruturas: Utilização do componente **ProductSearchDocumentMapper** para decompor objetos JSON complexos em campos otimizados para o *Azure AI Search*.



Normalização e Prevenção de Alucinações

Mapeamento Semântico: Conversão de termos de linguagem natural em valores padronizados no sistema (ex: a palavra "pequeno" é convertida diretamente para o tamanho S).

Injeção de CatalogRules: Regras rígidas injetadas diretamente no contexto do LLM.

Controlo de Vocabulário: Restrição das entidades extraídas aos valores efetivamente existentes no inventário, mitigando quase na totalidade as alucinações (inventar marcas ou cores inexistentes).




O Paradigma da Pesquisa Híbrida

Fusão de Metodologias: Combinação da **Precisão Léxica** (texto) com a **Compreensão Conceptual** (vetores).

A Força do Texto: Indispensável para recuperar correspondências exatas cruciais, como IDs de produtos, marcas específicas ou modelos.

A Força da Semântica: Capacidade de associar conceitos abstratos ("roupa quente") aos produtos corretos (casacos de lã, kispos), resolvendo automaticamente o problema dos sinónimos.



Avaliação Lexical: O Algoritmo BM25

$$Score(D, Q) = \sum_{i=1}^n IDF(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot (1 - b + b \cdot \frac{|D|}{Avgdl})}$$

Evolução do TF-IDF: O BM25 introduz melhorias essenciais no *Azure AI Search*:

- Saturação da frequência do termo (controlada por k_1).
- Normalização do peso pelo comprimento do documento (fator b).

Configuração de Pesquisa: Utilização de **SearchMode.All** (conjunção lógica AND) e aplicação de expansão *fuzzy* e *wildcard* (**termo*~**) para tolerância a erros tipográficos.



Espaço Latente: Similaridade de Cosseno e HNSW

$$\cos(\theta) = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} = \frac{\sum_{i=1}^n A_i B_i}{\sqrt{\sum_{i=1}^n A_i^2} \sqrt{\sum_{i=1}^n B_i^2}}$$

Geração de Embeddings: Utilização do modelo **text-embedding-3-small** para converter produtos em vetores densos.

Cálculo de Proximidade: Foco no ângulo (θ) entre os vetores (orientação) em detrimento da magnitude (comprimento do texto).

Viabilidade em Escala: Uso do algoritmo **HNSW** (Hierarchical Navigable Small World) para procura aproximada e eficiente de vizinhos (ANN).



Convergência de Métricas: Reciprocal Rank Fusion

$$RRFscore(d \in D) = \sum_{r \in R} \frac{1}{k + r(d)}$$

O Problema de Escala: Impossibilidade de somar a pontuação probabilística do BM25 com a distância geométrica do Cosseno de forma direta.

O Método: Avaliar os documentos pela sua posição relativa nos *rankings* individuais. Documentos presentes consistentemente no topo sobem na resposta final.

Constantes e Filtros: Constante de suavização gerida pelo Azure ($k = 60$) e aplicação do limiar **ProductMinScore**.



O Núcleo Cognitivo: gpt-4.1-nano e Self-Attention

$$Attention(Q, K, V) = softmax \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

O Motor: O **gpt-4.1-nano** atua como maestro do sistema devido à sua baixíssima latência na extração de entidades em tempo real.

Arquitetura Transformer: O mecanismo de *Self-Attention* avalia importância relativa e o contexto linguístico das palavras em milissegundos, ultrapassando os limites da pesquisa sequencial.




Tradução de Intenções: De Natural para Estruturado

Prompt Engineering (Zero-Shot): Uso de instruções *SystemPrompt* altamente estruturadas.

Tradução Funcional: O LLM converte a ambiguidade da entrada do utilizador num output JSON previsível e rigoroso.

A Dualidade de Output:

- Geração de um Vetor Semântico (o conceito global da pesquisa).
- Geração de Filtros OData (as restrições técnicas e comerciais do catálogo).



Gestão de Contexto Conversacional

Otimização de Recursos em Duas Fases:

- **Phase 1:** Validação de intenção (interceta saudações e *queries* fora do domínio, poupando chamadas ao motor de busca).
- **Phase 2:** Gestão profunda de *multi-turn* suportada pelo **context_summary**.

Exemplo de Retenção: Se um utilizador pesquisar "T-shirts" e a seguir pedir "Mostra em Azul", o sistema preserva o objeto original e concatena o novo parâmetro sem perder o contexto.

I want T-shirts

Only the
blue ones

Context
Summary

Precisão e Rigor: OData vs Semântica

O Equilíbrio Perfeito: Separação entre a intenção principal (Texto + Vetor) e as restrições rígidas (`search_attributes`).

Filtros Determinísticos OData (`eq`): Aplicados a parâmetros absolutos como preço máximo, público-alvo ou género, onde o vetor semântico pode ser demasiado vago.

Tratamento de Marcas (`search.ismatch`): Uso de *full-text match* específico em vez de `eq` fechado, absorvendo as variações lexicais inerentes à escrita de nomes de marcas pelos utilizadores.




Conclusão e Visão Arquitetural

Modularidade e Escalabilidade: Separação limpa entre a lógica de negócio e a infraestrutura de dados suportada pelo Azure. O sistema pode crescer sem refatoração profunda.

Superioridade Comprovada: O modelo híbrido garante a recuperação determinística de regras de negócio sem perder a intuição humana na navegação.

O Protótipo em Suma: Uma ferramenta robusta que redefine a navegação em E-Commerce, unindo a criatividade do LLM ao rigor absoluto do índice de pesquisa.



Home

Introdução

Gestão &
Engenharia de
Dados

Fundamentação
Matemática &
Metodológica

Diálogo &
Gestão
Multi-turno

Conclusão

Thank You

Miguel Grilo | 58387
Licenciatura em IACD

UC Laboratório de IACD
Universidade de Évora