

Assistente de Pesquisa Inteligente para E-Commerce

Implementação, Resultados
e Avaliação Crítica

Miguel Grilo | 58387
Verónica Vitorino | 57699
Licenciatura em IACD

UC Laboratório de IACD
Universidade de Évora

EVOLUÇÃO FACE AO WORKSHOP 1

Comparação entre
Teoria e Implementação:

W1

Workshop 1 (Teoria): BM25, Cosseno, RRF e Transformer como fundamentos; LLM extrai JSON com filtros OData; Catálogo com CatalogRules; Modelo gpt-4.1-nano (conceito).

W2

Workshop 2 (Implementação): Azure AI Search com BM25Similarity e HNSW; Pipeline 3 camadas com orquestração; QueryReformulatorPrompt; Modelo gpt-5.4-mini em produção.

PIPELINE DE INGESTÃO

3 Projetos .NET 8: Ecommerce.ChatAssistant.Api (Azure Functions) | Ecommerce.ChatAssistant.Application (LLM, embeddings, pesquisa) | Ecommerce.ChatAssistant.Custom (prompts, filtros, constantes)

- 1 JSON submetido ao endpoint HTTP index-data e guardado num blob json-data-receiver
- 2 Timer process-data (1 min) processa o blob via ProductSearchDocumentMapper.BuildEmbeddedContent
- 3 Validação estrutural (ProcessDataHelper): chaves obrigatórias, integridade de variantes, tipos de dados
- 4 Embeddings em lotes de 100 via EmbeddingService (round-robin, 5 deployments text-embedding-3-small, dim 1536)
- 5 Documentos indexados no índice commerce-index-pt-pt do Azure AI Search
- 6 Blob movido para completed ou error conforme resultado

PIPELINE DE CHAT

Phase 1: Barreira de segurança/intenção (saudações, out-of-scope)

Phase 2: Pipeline completo NLP + pesquisa híbrida (apenas queries transacionais)

1 Reformulação

QueryReformulatorService devolve JSON: reformulated_query, search_attributes (género, marca, preço, categoria, cor, tamanho), flags needs_more_context / facet_lookup

2 Embedding

EmbeddingService vetoriza a query; se reformulação inválida, degrada para modo texto com operadores fuzzy/wildcard Lucene (*~)

3 Pesquisa Híbrida

HybridSearchService submete texto + vetor ao Azure AI Search. Filtros OData: eq para absolutos (gender, season); search.ismatch para lexicais (brand, color); normalização de sinónimos (pattern); intersecção de intervalos (preço)

4 Score Mínimo

Filtragem por ProductMinScore = 0.008, retendo até 100 candidatos

5 Validação LLM

SearchRelevanceValidatorService devolve IDs relevantes; máx. 20 produtos apresentados. Se ≥ 20 relevantes, emite pergunta de refinamento

PIPELINE DE CHAT

Decisão Final e Broad Search

ChatFunction encapsula a decisão final. Pesquisas amplas controladas por teto de visualização (ChatMaxProductsDisplayed = 20). SearchRelevanceValidatorService detecta broad search e gera pergunta de refinamento via RefinementQuestionSystemPrompt, focada na extração de um único atributo em falta.

Fluxo de Exploração (Facet Lookup)

Consultas exploratórias (ex: "que tamanhos têm para calças?"). LLM infere intenção, extrai facet_field e ativa flag facet_lookup. FacetSearchService interroga o índice com filtros de contexto vigentes, devolvendo apenas valores de facet disponíveis.

Resiliência e Memória Multi-turno

Context_summary atualizado a cada turno (sem reenvio de histórico completo). Cascata de fallback: ContextSummary > Context do Request > ReformulatedQuery anterior > Query original. CurrentContext injetado como prefixo no texto submetido ao Azure AI Search, forçando a representação vetorial a carregar a "memória semântica" da conversa para o HNSW.

CONFIGURAÇÃO DO ÍNDICE

Perfil de Scoring (productBoost)

Pesos diferenciados: título (peso 20) e descrição (peso 10). Garante que correspondências no título do produto têm o dobro da relevância face à descrição, priorizando resultados com match direto no nome do artigo.

Pesquisa Vetorial (HNSW)

Algoritmo HNSW com efSearch = 300 e métrica cosseno. Configuração otimizada para recall elevado em tempo de query, mantendo a qualidade semântica da recuperação vetorial.

Separação de Campos (Léxico vs. Vetorial)

Campo embedding (vetorial) separado do campo searchText (léxico), preservando a independência de ambos os paradigmas estabelecidos no Workshop 1. Permite evolução independente de cada estratégia de recuperação.

CARACTERIZAÇÃO DO CATÁLOGO

2004

Produtos de moda
em português (PT-PT)

11

Marcas no
catálogo de
demonstração

~500 vs ~174

Casual (dominante)
vs
Calçado (nicho)

Observação sobre viés de IDF/BM25

A distribuição heterogénea de categorias produz viés de IDF/BM25: termos frequentes em categorias dominantes (casual) obtêm menor peso discriminativo, enquanto termos de categorias de nicho (calçado) recebem maior relevância relativa no ranking.

ANÁLISE QUALITATIVA POR TIPO DE CONSULTA

1

Consultas Semânticas

Exemplo: "algo quente e casual para o inverno"

Pesquisa híbrida superior à textual: embedding da query reformulada recupera artigos (casacos polares, fleece) sem sobreposição lexical com a consulta original.

2

Consultas Lexicais (marca/referência)

Exemplo: "GANT polo"

BM25 + scoring profile (peso título = 20) domina o ranking, devolvendo resultados precisos independentemente do caminho vetorial.

3

Consultas Estruturadas

Exemplo: "casaco feminino azul até 80€"

Filtros OData gerados pelo LLM são determinantes: sem eles, o índice devolve candidatos fora da faixa de preço ou género, aumentando o ruído.

4

Consultas de Exploração

Exemplo: "que cores há em sapatilhas?"

Fluxo facet lookup ativa FacetSearchService em vez do pipeline de pesquisa, devolvendo valores disponíveis no catálogo sem listar produtos.

PROPOSTA DE AVALIAÇÃO QUANTITATIVA

Limitação Principal

Ausência de conjunto de teste anotado com ground truth. Identificado como trabalho futuro prioritário.

Protocolo Proposto

- 30-50 consultas em português (PT-PT), cobrindo os 4 tipos identificados (semânticas, lexicais, estruturadas, exploração)
- Anotação binária (relevante / não relevante) dos produtos no top-10
- Métricas: Precision@5, Precision@10, MRR (Mean Reciprocal Rank), nDCG@10
- Comparação de configurações: híbrida vs. só texto, com/sem filtros OData, com/sem validador LLM
- Ponto de partida: coleção Postman disponível no repositório

Precision@5

Precision@10

MRR

nDCG@10

CENÁRIOS DE TESTE

1 — Semântico

Query: "Quero algo quente e casual para o inverno"

LLM reformula para casaco/polar; embedding gerado; pesquisa híbrida devolve vestuário exterior relevante

2 — Lexical/Marca

Query: "GANT polo azul"

BM25 + scoring profile dominam; filtro OData de cor aplicado; validador confirma relevância

3 — Estruturado

Query: "Casaco feminino até 80 euros"

LLM extrai gender=Feminino, max_price=80; filtro OData composto reduz candidatos

4 — Facet Lookup

Query: "Que cores há disponíveis em sapatilhas?"

LLM ativa facet_lookup; FacetSearchService devolve lista de cores sem listar produtos

5 — Contexto Insuficiente

Query: "Preciso de um presente"

LLM ativa needs_more_context; sistema pede clarificação sem executar pesquisa

CONSULTA SEMÂNTICA

Utilizador: "Quero algo quente e casual para o inverno, masculino, até 100 euros"

Reformulação LLM (QueryReformulatorService)

reformulated: "quente casual inverno homem"

search_attributes: gender=[Homem], season=[Outono/Inverno], max_price=100

intent: product_search | needs_more_context: false

context_summary: "O utilizador procura roupa quente e casual para inverno, masculino, até 100 euros."

Resposta do Assistente

"Selecionei para si opções quentes e casuais para o inverno, com perfil masculino e dentro do orçamento até 100 euros. Posso afinar a pesquisa por casacos, camisolas ou sweatshirts — prefere alguma destas peças?"

15

Total Resultados

0.0345

@search.score (Top 1)

75,50 EUR

Preço Top 1

Casaco

Categoria

Top 1: "Casaco Polar em Fleece" — 75,50 EUR (Respeita o limite de 100€)

Comportamento Semântico

O sistema recuperou produtos de inverno ("Polar", "Fleece") através da proximidade geométrica dos vetores aos conceitos "quente" e "inverno", contornando a ausência destas palavras-chave exatas no título e descrição do produto.

DEMONSTRAÇÃO DO SISTEMA:
FLUXO DE CONVERSA

FILTROS
ESTRUTURADOS

FACET
LOOKUP

Utilizador: "Casaco feminino azul até 80 euros"

Filtro OData Gerado

```
status eq '1'  
and gender eq 'Feminino'  
and price le 80.0  
and search.in(color, 'Azul,Navy,Blue', ',')
```

COM Filtros OData

Total de Resultados: 3

Top 1: "GANT Casaco Liso"

Preço: 51,04 EUR

@search.score: 0.0322

Respeita o orçamento exigido

SEM Filtros OData

Total de Resultados: 8

Top 1: "GANT Casaco Xadrez"

Preço: 88,36 EUR

@search.score: 0.0325

Ignora o limite de 80€ exigido

Os filtros OData eliminam ruído e garantem que os resultados respeitam as restrições explícitas do utilizador

Utilizador: "Que cores há disponíveis em sapatilhas?"

Deteção de Intenção pelo LLM

```
intent: facet_lookup  
facet_field: color  
category: Sapatilhas
```

Resposta — Valores de Facet Disponíveis

Amarelo | Antracite | Azul | Azul-marinho | Bege | Bordeaux
| Branco | Castanho | Cinzento | Dourado | Laranja | Lilás |
Preto | Rosa | Verde | Verde-azeitona | Vermelho

Comportamento Distinto

O sistema não devolve produtos — apenas os valores disponíveis para o atributo solicitado. O FacetSearchService interroga diretamente o índice com filtros de contexto, proporcionando uma experiência conversacional orientada à descoberta do inventário.

LIMITAÇÕES

- 1 Dependência de Plataforma**
Serviços geridos Azure (Search, OpenAI, Storage) — impossibilita reprodução offline e introduz custo por pedido
- 2 Latência Dupla**
Duas chamadas LLM por pedido aumentam latência e custo; fallback preserva disponibilidade mas sacrifica precisão
- 3 Heurísticas Não Calibradas**
ProductMinScore = 0.008 e limite de 20 produtos são heurísticas empíricas, não otimizadas estatisticamente
- 4 Normalização de Texto**
embedded_content em minúsculas pode atenuar nuances léxicas na representação vetorial
- 5 Escala do Catálogo**
~2000 itens limita generalização — marcas desbalanceadas introduzem viés de popularidade no IDF

VIÉS IDENTIFICADOS

- 1 Viés de Popularidade**
Categorias dominantes no índice penalizam termos frequentes via IDF, podendo desfavorecer produtos de nicho em categorias menos representadas.
- 2 Scoring Profile**
O peso elevado do título (20) penaliza produtos com títulos pouco descritivos face a produtos com descrições ricas — artigos com nomes genéricos ficam sub-representados.
- 3 Viés do LLM**
O LLM pode inferir incorretamente atributos de género ou faixa etária a partir de linguagem ambígua (e.g., "para o meu filho") sem ativar needs_more_context.

CONCLUSÃO

O sistema constitui uma instância concreta do paradigma de recuperação de informação híbrida aplicado ao e-commerce em língua portuguesa — um domínio sub-representado na literatura de IR.

Potencial para contribuição original através de:

- Benchmarks públicos em português para IR em e-commerce
- Análise de qualidade de embeddings multilíngues em contexto comercial

Trabalho Futuro Prioritário: Avaliação Quantitativa com Ground Truth Anotado

