

A Interação Dinâmica entre Computação de Proximidade, Redes Sem Fios e Inteligência Artificial: Uma Análise do Estado da Arte e Projeções para a Era 6G

Miguel Grilo¹ and Tiago Ramalho²

Escola de Ciências e Tecnologias, Universidade de Évora, Portugal
Nº 58387 e Nº 58514 (respetivamente)
UC: Sistemas Móveis e Aplicações
{158387, 158514}@alunos.uevora.pt

Resumo A convergência entre Edge Computing, redes 5G-Advanced/6G e Inteligência Artificial está a redefinir o processamento móvel. Este trabalho analisa o estado da arte das infraestruturas MEC, o papel das Unidades de Processamento Neural (NPU) e os mecanismos de offloading computacional [3]. Discute-se o papel do Federated Learning na preservação da privacidade e apresentam-se projeções lineares baseadas na Lei de Moore e nos roteiros da 3GPP.

Keywords: Edge Computing · 5G-Advanced · On-device AI · MEC · Federated Learning.

1 Introdução

A evolução da computação distribuída atravessou, na última década, uma transformação paradigmática. Historicamente, a Computação em Nuvem estabeleceu-se como a infraestrutura dominante, dependendo de centros de dados centralizados para o treino e inferência de modelos de IA. No entanto, a proliferação exponencial de dispositivos IoT gerou um volume de tráfego que as arquiteturas centralizadas não conseguem gerir com eficiência [1].

Esta saturação motivou a transição para a Edge Computing ou Computação de Proximidade — um paradigma que desloca o processamento para a periferia da rede, aproximando os recursos computacionais da fonte de dados. A necessidade de respostas em tempo real para aplicações como a Realidade Estendida (XR) evidenciou a limitação da Latência. Através do Multi-access Edge Computing (MEC), as capacidades de computação são integradas na rede de acesso rádio (RAN), reduzindo o Round-Trip Time (RTT) e garantindo a Qualidade de Serviço (QoS) necessária para decisões em milissegundos [2].

2 Estado da Arte: Redes 5G-Advanced e Hardware Móvel

O panorama tecnológico atual é sustentado pela maturidade das redes 5G e pela emergência do 5G-Advanced [4].

2.1 Infraestrutura de Rede e Capacidades

As especificações do 5G-Advanced introduziram o mecanismo LTM (Layer 1/Layer 2-triggered mobility), desenhado para reduzir a latência de handover e interrupções de sinal, essencial para sessões contínuas de IA [4]. A Release 19 atua como ponte para o 6G, focando-se na integração nativa de IA na interface aérea para otimização de recursos e gestão de feixes (beam management) [5,8].

Tabela 1. Evolução das Características de Rede (4G, 5G e 6G) [12]

Parâmetro	4G	5G	6G
Latência	~50 ms	1 ms (URLLC)	0.1 ms
Largura de Banda	Up to 1 Gbps	Up to 10 Gbps	Up to 1 Tbps
AI Integration	Minimal	Integrated	Native AI-driven

2.2 Processadores Móveis e Unidades de Processamento Neural (NPUs)

As NPUs (Neural Processing Units) tornaram-se o coração dos terminais móveis (telemóvel), sendo otimizadas especificamente para operações de álgebra linear e tensores com alta eficiência energética. Ao contrário dos CPUs de uso geral, as NPUs utilizam arquiteturas de Matrizes Sistólicas — uma rede de processadores ligados que permitem que os dados fluam através de múltiplos passos de computação sem regressar constantemente à memória principal — e SRAM local de alta largura de banda para minimizar o consumo energético. O desempenho destas unidades é quantificado em TOPS (Trillions of Operations Per Second).

Os processadores de 2025, como o Snapdragon 8 Elite (Gen 5), apresentam uma NPU Hexagon com desempenho 37% superior à geração anterior [6]. A eficácia desta NPU depende da Quantização, o processo de reduzir a precisão dos pesos para acelerar a computação. O Snapdragon 8 Elite suporta nativamente uma vasta gama de precisões, incluindo INT2, INT4, INT8, INT16, FP8 e FP16, permitindo uma execução eficiente de modelos de IA generativa com uma melhoria de 16% na performance por watt [6]. Esta arquitetura, que inclui aceleração de matriz por hardware, viabiliza a utilização de assistentes de IA agentes diretamente no dispositivo.

Estudos recentes [7] demonstram que o Snapdragon 8 Elite, equipado com a NPU Hexagon e suporte nativo para precisão mista (INT4 e INT8), consegue

executar o modelo Llama 3.2 3B Instruct a aproximadamente 10 tokens por segundo (o número de unidades básicas de texto geradas por segundo pela IA).

3 Interação e Decisão: On-device AI vs. Edge Offloading

O Offloading Computacional consiste em delegar tarefas para servidores MEC para mitigar limitações de bateria ou hardware [3]. A decisão baseia-se em:

1. **Estado da Bateria:** A execução local na NPU é eficiente, mas a transmissão via 5G mmWave pode ser mais onerosa se o volume de dados for elevado.
2. **Qualidade do Canal:** Se a largura de banda for reduzida, o tempo de transmissão anula os benefícios de processamento do servidor potente.
3. **Complexidade da Tarefa:** Definida pelos ciclos de CPU e pelo tamanho dos bits de entrada.

4 Privacidade e Federated Learning em Redes periféricas

O Federated Learning (FL) ou Aprendizagem Federada permite o treino colaborativo de modelos de IA sem a necessidade de centralizar dados sensíveis, mantendo-os nos dispositivos dos utilizadores [3].

4.1 O Ciclo de Vida do Treino Federado

Em ambientes móveis e periféricos, o processo de treino segue cinco etapas cíclicas iterativas:

1. **Inicialização:** O servidor central (MEC ou Cloud) define o modelo global inicial w_0 .
2. **Seleção de Clientes:** Utiliza-se o algoritmo FedCS (Federated Client Selection) para selecionar um subconjunto de telemóveis disponíveis, com base no estado da bateria e qualidade da ligação à rede.
3. **Distribuição (Multicast):** O servidor transmite os parâmetros do modelo para os dispositivos selecionados.
4. **Treino Local:** Cada telemóvel utiliza os seus dados locais para atualizar o modelo, gerando gradientes ou pesos locais w_i^t .
5. **Agregação:** Os dispositivos enviam apenas as atualizações para o servidor MEC. O algoritmo FedAvg (Federated Averaging) [3] combina estas atualizações para formar o novo modelo global: $w_{t+1} = \sum_{k=1}^K \frac{|D_i|}{|D|} w_i^t$.

4.2 Mecanismos Avançados de Privacidade e Segurança

Embora o FL evite o envio de dados brutos, ataques de inversão de gradiente podem tentar reconstruir dados originais a partir das atualizações do modelo. Para mitigar este risco, aplicam-se camadas adicionais de segurança:

- **Privacidade Diferencial (DP):** Adiciona-se ruído estatístico aos gradientes antes da transmissão, garantindo que a contribuição de um utilizador individual não possa ser isolada.
- **Secure Multi-party Computation (SMC):** Protocolos criptográficos que permitem ao servidor agregar dados cifrados sem nunca visualizar os valores individuais.
- **Criptografia Homomórfica:** Permite realizar operações matemáticas (como a soma de gradientes) diretamente em dados cifrados.

4.3 Otimização de Tráfego e Recursos de Rede

A integração do FL com a computação de proximidade otimiza drasticamente os recursos da rede 5G/6G [3]. Como apenas os parâmetros do modelo (frequentemente comprimidos através de técnicas de sparsification ou redução de esparsidade) são transmitidos, o consumo de largura de banda no uplink é reduzido em até 90% comparado com o envio de dados brutos. Além disso, ao realizar a agregação no nó MEC local, evita-se a latência de propagação até à nuvem, permitindo atualizações de modelo mais frequentes e precisas.

5 Previsões Futuras: Projeções Lineares Rumo ao 6G

As projeções para o final da década baseiam-se em tendências estabelecidas pela Lei de Moore e pelos roteiros técnicos da ITU (IMT-2030).

5.1 O Ecossistema 6G: Metas e Novos Cenários de Uso

O roteiro IMT-2030 da ITU-R define que o 6G não será apenas uma evolução da velocidade, mas uma rede com inteligência intrínseca e capacidades sensoriais [11]. O 6G introduzirá cenários de uso disruptivos definidos pela Recomendação ITU-R M.2160 [11]:

- **Integrated Sensing and Communication (ISAC):** A rede funcionará como um sensor/radar gigante, detetando objetos, velocidade e imagem do ambiente sem necessidade de sensores externos dedicados [8].
- **AI and Communication (AIAC):** O 6G terá uma arquitetura "AI-native", onde a inteligência não é apenas uma aplicação (bolted-on), mas parte integrante da interface aérea e da gestão de recursos da rede.
- **Holographic-Type Communication (HTC):** Transmissão de conteúdos volumétricos 3D em tempo real, exigindo sincronização sub-milissegundo entre múltiplas modalidades sensoriais.

6 Conclusão

A convergência analisada demonstra que a eficiência da IA móvel depende da orquestração inteligente entre NPUs locais e infraestruturas MEC. O Federated Learning estabelece-se como o pilar da privacidade [3], enquanto os avanços lineares nos nós garantem o poder computacional necessário. Com a chegada do 6G, a fusão entre comunicações e sensoriamento (ISAC) criará um sistema nervoso digital global, onde a distinção entre dispositivo e rede será virtualmente inexistente.

Nota

Tal como solicitada a menção, reconhecemos a utilização de Inteligência Artificial neste trabalho como auxiliar de pesquisa e estruturação de conteúdos, auxiliando na identificação de fontes relevantes e na clarificação de conceitos técnicos.

Referências

1. Wang, Xubin, et al. "Empowering Edge Intelligence: A Comprehensive Survey on On-Device AI Models." *ACM Computing Surveys*, vol. 57, no. 9, Apr. 2025, pp. 1–39. Crossref, <https://doi.org/10.1145/3724420>
2. Luo, H., et al.: AI Reasoning for Wireless Communications and Networking: A Survey and Perspectives. 2025, <https://arxiv.org/abs/2509.09193>
3. Abreha HG, Hayajneh M, Serhani MA. Federated Learning in Edge Computing: A Systematic Survey. *Sensors (Basel)*. 2022 Jan 7;22(2):450. doi: 10.3390/s22020450. PMID: 35062410; PMCID: PMC8780479.
4. Lin, X. (2022). An Overview of 5G Advanced Evolution in 3GPP Release 18. *IEEE Communications Standards Magazine*, 6, 77-83.
5. 3GPP. "Release 19." 3GPP, 2025, <https://www.3gpp.org/specifications-technologies/releases/release-19>
6. Snapdragon 8 Elite Gen 5 Product Brief. Qualcomm, 2025, <https://www.qualcomm.com/content/dam/qcomm-martech/dm-assets/documents/Snapdragon-8-Elite-Gen-5-product-brief.pdf>
7. Jaskurzyński, Michał. "Running LLMs On-Device with Qualcomm Snapdragon 8 Elite." *Grape Up*, 2024, <https://grapeup.com/blog/running-llms-on-device-with-qualcomm-snapdragon-8-elite>
8. e&. ISAC 6G Whitepaper: Integrated Sensing and Communication. 2025, <https://eand.ae/content/dam/eand/assets/docs/general/isac-6g-whitepaper.pdf>
9. Christa, Manuel. "14A Should Herald Intel's Return to the Foundry Top." *All About Industries*, 5 May 2025, <https://all-about-industries.com/14a-should-introduce-intels-return-to-the-top-of-foundry-a-61ae4406c3a0993db5ebe0a19d6b7e8f/>
10. "TSMC's 2nm Chips: The Results Are Out." *36Kr*, 30 Dec. 2025, <https://eu.36kr.com/en/p/3617863779501317>
11. International Telecommunication Union. "IMT-2030: Technical Requirements for the 6G Future." ITU, Mar. 2026, <https://www.itu.int/hub/2026/03/imt-2030-technical--requirements-for-the-6g-future>
12. Tsegaye, et al. (2025). Deep Neural Networks in Smart Grid Digital Twins: Evolution, Challenges, and Future Outlooks. *IEEE Access*. 13. 114845 - 114864. 10.1109/ACCESS.2025.3585967.